



## **UNIVERSIDAD NACIONAL DE INGENIERÍA**

Facultad de Ingeniería Industrial y de Sistemas  
Unidad de Posgrado · Maestría en Inteligencia Artificial

### **ENTREGABLE SEMANA 2**

Curso: MIA-14 · Trabajo de Investigación II · Sección B · 2026-2

#### **PROCESO**

Diseño reproducible del flujo experimental:  
pipeline de aprendizaje supervisado para la detección y priorización de eventos adversos

#### **TESIS**

*Detección Automatizada y Priorización de Eventos Adversos en Notas Clínicas  
mediante un Flujo de Procesamiento (Pipeline) de NLP y Aprendizaje Automático —  
Aplicación de la Matriz de Priorización del Modelo GEMSES sobre MIMIC-IV*

**Autor:** Carlos Pérez Pérez

**Docente:** Dr. Ing. Glen Dario Rodríguez Rafael

**Fecha de entrega:** 25 de septiembre de 2026

**Tipo de tesis:** aprendizaje supervisado (clasificación de texto clínico), con dos adaptaciones: la etiqueta de entrenamiento es de *supervisión débil* (códigos CIE-10 causales) y la evaluación se cierra con un panel de expertos y con un corpus en español con etiqueta humana.

**Continuidad.** El título de la tesis se mantiene desde el proyecto aprobado en Trabajo de Investigación I (cerrado el 14 de julio de 2026). Este documento presenta el flujo experimental tal como se ejecutó y mejoró desde entonces (Fases 3v2 a 13), incorporando lo aprendido en el curso de Procesamiento de Lenguaje Natural (auditoría adversarial de 26 hallazgos) y en la aplicación del mismo enfoque a los reportes de seguridad del paciente de EsSalud dentro del sistema GEM-VigIA.

# 1. Diagrama del flujo principal

Flujo experimental reproducible · Detección y priorización de eventos adversos en epicrisis (MIMIC-IV) con NLP supervisado + Matriz GEMSES




Figura 1: Pipeline reproducible en seis etapas, con la salida de cada una, los controles contra fugas y el estado de reproducibilidad.

## 2. Entradas, componentes y salida de cada etapa

| Etapas     | Recibe                                                                           | Qué hace                                                                                                                  | Produce (artefacto reproducible)       |
|------------|----------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------|----------------------------------------|
| 1. Ingesta | MIMIC-IV v3.1 + MIMIC-IV-Note v2.2 (acuerdo de uso PhysioNet), leídos con DuckDB | Extrae las epicrisis ( <i>discharge summaries</i> ) con identificador de paciente, de hospitalización y códigos de egreso | 331 793 epicrisis de 145 914 pacientes |

| Etapa                                 | Recibe                                     | Qué hace                                                                                                                                                                                                                                                                                                | Produce (artefacto reproducible)                                                        |
|---------------------------------------|--------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------|
| <b>2. Preprocesamiento y etiqueta</b> | Epicrisis + diagnósticos codificados       | Tier A: 223 códigos CIE-10 causales + 21 equivalencias OMS→CM → etiqueta A1 no circular; emparejamiento de época CIE-9/CIE-10 en los negativos; NegEx y regex Tier B solo como baseline                                                                                                                 | Corpus de modelado de 70 000 epicrisis con prevalencia real 0.2012                      |
| <b>3. Partición y features</b>        | Corpus de modelado                         | Partición por paciente (GroupShuffleSplit), test 20 %, semilla 42, con verificación de pacientes disjuntos; TF-IDF de palabras (1–2-gramas, 60 000 rasgos, mínimo 3 documentos) + TF-IDF de caracteres (3–5, 20 000 rasgos, mínimo 5), escala sublineal; el vocabulario se ajusta <b>solo con train</b> | Conjunto de datos final en formato Parquet; matrices dispersas                          |
| <b>4. Entrenamiento</b>               | Matrices TF-IDF                            | Cascada de dos etapas: E1 detección evento sí/no con LinearSVC balanceado; E2 naturaleza del evento, 6 clases multietiqueta, OneVsRest(LinearSVC), entrenada solo con positivos y con su propia partición por paciente; prueba de abstención con 6 textos triviales                                     | Modelo final serializado (10.7 MB, fuera de git por el acuerdo de uso)                  |
| <b>5. Evaluación</b>                  | Test reservado; panel experto; corpus ERSP | Métricas con IC95 por <i>bootstrap</i> (200 réplicas) por nota y por paciente; cascada extremo a extremo; sistema contra consenso de expertos                                                                                                                                                           | JSON de resultados finales; JSON de métricas corregidas; JSON de sistema contra experto |
| <b>6. Salida</b>                      | Detecciones por nota                       | Matriz de Priorización GEMSES (Anexo 03 de la Directiva N.º 7-OGCyH-ESSALUD-2020):<br>$G = 0.40 \cdot c + 0.20 \cdot d + 0.15 \cdot e + 0.25 \cdot f \rightarrow \text{percentiles}$<br>P25/P50/P75 → banda Verde/Amarillo/Rojo y responsable                                                           | Tablero de priorización (prototipo)                                                     |

**Fuente de datos, unidad de análisis y variable objetivo.** La unidad de análisis es la epicrisis (una por hospitalización). La variable objetivo de E1 es binaria (¿la hospitalización tuvo un evento adverso codificado como causal?) y la de E2 es la *naturaleza* del evento según la Tabla de Codificación (Anexo 02 de la misma Directiva), reducida a 6 clases con n suficiente. No hay valores faltantes numéricos ni escalamiento: el texto es la única entrada del modelo y TF-IDF ya normaliza; la fusión con variables tabulares prevista en el proyecto original no se ejecutó y queda fuera del alcance.

**Regla de partición.** Se respeta la unidad *paciente*: ningún paciente aparece a la vez en train y test. En la Fase 4 se comprobó que el split por paciente no degrada el rendimiento (F1-macro  $0.492 \pm 0.018$ ) y desde entonces es obligatorio. Desarrollo y ajuste se hacen con validación cruzada de 5 pliegues dentro del train; el test se toca una sola vez; el panel experto y el corpus ERSP actúan como evaluación externa.

### 3. Proceso de obtención de la base de datos MIMIC-IV

MIMIC-IV no se descarga libremente: PhysioNet (MIT) exige acreditación personal, formación en ética de investigación y un acuerdo de uso de datos. El proceso completo, con fechas y tiempos, fue el siguiente.

Proceso de obtención de la base de datos MIMIC-IV · requisitos cumplidos y tiempos (abril-mayo 2026)




Figura 2: Proceso de obtención de MIMIC-IV: pasos, requisitos cumplidos y tiempos.

| Paso                                    | Fecha          | Qué se hizo                                                                                                                                                                              | Requisito que cubre                                                 |
|-----------------------------------------|----------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------|
| 0. Decisión de la fuente                | 27–28 abr 2026 | Sin acceso a historias clínicas de EsSalud, MIMIC-IV pasa de plan B a dataset principal                                                                                                  | Viabilidad del proyecto                                             |
| 1. Registro en PhysioNet                | 28 abr 2026    | Cuenta con nombre real y afiliación académica                                                                                                                                            | Identidad y afiliación verificables                                 |
| 2. Certificación ética CITI             | 28 abr 2026    | Curso «Data or Specimens Only Research» (MIT Affiliates), nota 95/100 (mínimo 90); segundo curso «Ética en Investigación» bajo EsSalud, nota 96/100. Ambos vigentes hasta el 28 abr 2029 | Formación en protección de sujetos humanos y HIPAA                  |
| 3. Solicitud de acceso y acuerdo de uso | 28 abr 2026    | Solicitud de <i>credentialed access</i> y firma del <i>Credentialed Health Data Use Agreement</i> v1.5.0 para MIMIC-IV v3.1                                                              | No reidentificar, no redistribuir, no compartir texto, citar el DOI |

| Paso                                        | Fecha          | Qué se hizo                                                                                                                                                                                                                | Requisito que cubre                   |
|---------------------------------------------|----------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------|
| 4. Acceso confirmado a MIMIC-IV v3.1        | 28 abr 2026    | Módulos hosp e icu: 364 627 pacientes, 546 028 hospitalizaciones, 94 458 estancias en UCI (DOI 10.13026/kpb9-mt58)                                                                                                         | Acceso otorgado                       |
| 5. Acuerdo específico de MIMIC-IV-Note v2.2 | 10–11 may 2026 | Las notas clínicas tienen su propio acuerdo de uso (DOI 10.13026/1n74-ne17); descarga de 4 archivos comprimidos = 1.96 GB (epicrisis 1.14 GB; radiología 781 MB; dos archivos de metadatos)                                | Acceso al texto libre                 |
| 6. Entorno y primera lectura                | 11 may 2026    | Python 3.13.5 + DuckDB 1.5.2 leen los archivos comprimidos sin cargarlos a memoria; consulta de verificación: 331 793 epicrisis, 100 % del tipo <i>discharge summary</i> , consistente con el artículo oficial del dataset | Lectura reproducible                  |
| 7. Integridad del dataset completo          | 14 may 2026    | Descarga y descompresión de los 33 archivos de MIMIC-IV v3.1; verificación SHA-256 contra el listado oficial: 33/33 íntegros; datos en disco local y excluidos del control de versiones                                    | Integridad y cumplimiento del acuerdo |

**Tiempos.** Registro, cursos de ética, acuerdo de uso y acceso a MIMIC-IV: **1 día** (28 de abril de 2026). Desde el acceso principal hasta el acuerdo de notas y la descarga de 1.96 GB: **13 días**. Desde la decisión del dataset hasta el corpus completo verificado: **17 días** (27 de abril al 14 de mayo). **Costo:** S/ 0; el acceso es gratuito con acreditación.

**Requisitos adicionales que el proyecto se impuso:** segunda certificación ética bajo EsSalud (no exigida por PhysioNet, añadida por la afiliación institucional del autor); declaración explícita de conflicto de interés (autor del Modelo GEMSES y ex directivo de la instancia de EsSalud que emite la Directiva); acceso al texto de MIMIC-IV restringido al investigador principal, único acreditado; y exclusión de todo dato, modelo entrenado y copia de trabajo del repositorio de código.

## 4. Baseline, familia de modelos y alternativas ya descartadas

- **Baseline mínimo:** reglas regex Tier B + NegEx, precisión 65.7 % (IC95 54.0–75.8, n = 70, validación experta de mayo), y TF-IDF + regresión logística (Fase 4).
- **Familia elegida:** modelo lineal sobre TF-IDF (LinearSVC balanceado), en cascada. Es el modelo vigente desde la Fase 9 (29-jul-2026).
- **Alternativas probadas y refutadas** con la misma partición y semilla (hipótesis HE2): ClinicalBERT congelado F1-macro 0.19; Bio\_ClinicalBERT y BioBERT con ajuste fino en GPU 0.21–0.35 (2.9–4.0 h) frente a 0.459 del lineal en 48 s; BioClinical ModernBERT con ventana de 1024 tokens 0.428 tras 42.5 h de GPU; Llama 3.2 3B *zero-shot* kappa 0.0 (clasificó todos los casos como positivos). Causa medida: la ventana de 256 tokens cubre el 9 % de una epicrisis (mediana 3 148 tokens). Se documenta como resultado negativo; solo se reabría con Longformer o BigBird y GPU dedicada.

## 5. Criterio preliminar de evaluación

Toda comparación entre modelos se hace con la misma partición (semilla 42, por paciente) y se reporta siempre la cascada, porque el pipeline completo rinde menos que sus etapas.

| Nivel                    | Criterio                                                                                                              | Situación al 25-set-2026                                                    |
|--------------------------|-----------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|
| <b>Métrica principal</b> | F1-macro de la <b>cascada completa</b> con IC95 por paciente (no la etapa aislada)                                    | 0.363 en cascada frente a 0.536 de E2 aislada                               |
| Secundarias              | E1: sensibilidad, especificidad, AUC y VPP a prevalencia real; E2: F1-micro; abstención                               | sens 0.762, esp 0.770, AUC 0.843, VPP 0.455; F1-micro 0.745; abstención 6/6 |
| <b>Bueno</b>             | Supera el baseline de reglas y kappa sistema-experto $\geq 0.61$ (umbral fijado en la hipótesis general del proyecto) | kappa 0.531 (n = 68, solo infección): <b>no alcanzado</b>                   |
| Aceptable                | Supera el baseline lineal en cascada y F1 $> 0.5$ en toda clase con n $\geq 100$                                      | Cumplido en Infección y Procedimiento; Sistema/Organización (n = 66) F1 0.0 |
| Fuera de alcance         | Clases con n insuficiente: Sistema/Organización, Sangre/Hemoderivados, Nutrición                                      | Declaradas no viables, no se intenta corregirlas                            |

## 6. Reproducibilidad

- **Versiones fijas:** MIMIC-IV v3.1 (DOI 10.13026/kpb9-mt58), MIMIC-IV-Note v2.2 (DOI 10.13026/1n74-ne17), Python 3.13.5, DuckDB 1.5.2; versión de scikit-learn **por fijar** en el archivo de dependencias.
- **Semillas:** 42 en la partición, en el muestreo del corpus y en el *bootstrap*.
- **Registro de experimentos:** un archivo JSON de resultados por fase, más bitácoras fechadas por sesión. Cada cifra del borrador de tesis lleva un comentario con el archivo del que proviene, verificado por script.
- **Artefactos:** modelo final serializado, conjunto de datos final (Parquet), JSON de resultados finales y JSON de métricas corregidas. Modelo y datos quedan fuera de git por el acuerdo de uso; el repositorio de la tesis es privado desde el 28-jul-2026.
- **Estado actual y brecha:** todavía no existe un archivo de dependencias con versiones fijadas, ni una plantilla de variables de entorno, ni un orquestador que encadene las fases, ni la estructura data/raw y data/processed; hay 46 scripts, uno por fase; la sección “Cómo reproducir” del README apunta al notebook exploratorio y no a la cascada; los *checkpoints* de los transformers no se conservaron (solo son reproducibles reentrenando). El Sprint 1 del curso se dedica a cerrar esta brecha, con un criterio de aceptación medible: que un tercero con credencial PhysioNet regenere la Fase 9 con un solo comando y obtenga sens 0.7623, esp 0.7699 y AUC 0.8426 con tolerancia  $\pm 0.005$ .

## 7. Riesgos técnicos previsibles y cómo se detectan o mitigan

| Riesgo                                 | Dónde se detectó (frente)                                                                 | Mitigación incorporada al diseño                                                                                       |
|----------------------------------------|-------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------|
| Fuga por circularidad regex → etiqueta | Tesis / PLN: enmascarar los disparadores solo baja 1.35 puntos                            | Etiqueta A1 derivada de códigos CIE-10 causales, no del regex                                                          |
| Confusor de época CIE-9/CIE-10         | Tesis, Fase 7: AUC 0.973 → 0.840 al emparejar                                             | Emparejamiento de época en los negativos; se descarta la cifra 0.973                                                   |
| Fuga por paciente                      | PLN (auditoría adversarial)                                                               | Partición por paciente con verificación automática                                                                     |
| Fuga por estilo de redacción           | GEM-VigLA: el triaje reclamo/denuncia daba 98.4 %, y 91.5 % solo con palabras funcionales | Ablaciones de control; no se usan metadatos de quién redacta                                                           |
| Mezcla de centros asistenciales        | GEM-VigLA sobre el mismo corpus<br>ERSP: 0.77 estratificado frente a 0.42 por centro      | El OE5 se re-mide con partición por centro antes de citarse; 0.7675 solo como cota superior                            |
| Datos insuficientes por clase          | Tesis, Fases 4 y 9                                                                        | Clases con n < 100 declaradas no viables                                                                               |
| Referencia de etiqueta débil           | Panel experto limitado a infección; kappa 0.531 < 0.61                                    | Decisión de alcance (20-set): A1 como estándar plata principal, panel como validación secundaria; limitación declarada |

| Riesgo                                       | Dónde se detectó (frente)                                                             | Mitigación incorporada al diseño                                                                                                   |
|----------------------------------------------|---------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------|
| Costo y latencia                             | Transformers 2.9–42.5 h de GPU frente a 48 s                                          | Familia lineal; transformers cerrados como resultado negativo                                                                      |
| Restricciones del entorno y datos personales | Acuerdo de uso PhysioNet; el corpus ERSP contiene datos personales                    | Modelo y datos fuera del control de versiones; repositorio privado; copias de trabajo del ERSP anonimizadas antes de cualquier uso |
| Pérdida de resultados intermedios            | Tesis: se perdieron las filas por nota del primer tramo (260 000) al morir el proceso | Orquestador con <i>checkpoint</i> por fase (Sprint 1)                                                                              |