



UNIVERSIDAD NACIONAL DE INGENIERÍA

Facultad de Ingeniería Industrial y de Sistemas
Unidad de Posgrado · Maestría en Inteligencia Artificial

ENTREGABLE SEMANA 2

Curso: MIA-14 · Trabajo de Investigación II · Sección B · 2026-2

PROCESO

Diseño reproducible del flujo experimental:
pipeline de aprendizaje supervisado para la detección y priorización de eventos adversos

TESIS

*Detección Automatizada y Priorización de Eventos Adversos en Notas Clínicas
mediante un Flujo de Procesamiento (Pipeline) de NLP y Aprendizaje Automático —
Aplicación de la Matriz de Priorización del Modelo GEMSES sobre MIMIC-IV*

Autor: Carlos Pérez Pérez

Docente: Dr. Ing. Glen Dario Rodríguez Rafael

Fecha de entrega: 25 de septiembre de 2026

Tipo de tesis: aprendizaje supervisado (clasificación de texto clínico). La etiqueta de entrenamiento se obtiene por *supervisión débil (weak supervision)*: no la asigna un anotador leyendo cada epicrisis, sino que se deriva automáticamente de los códigos CIE-10 causales registrados en la misma hospitalización (etiqueta A1). Esto permite entrenar con 70 000 epicrisis sin anotación manual masiva; el costo es que la etiqueta tiene ruido, y por eso su calidad se verifica con dos referencias externas ya construidas: un panel de expertos sobre una muestra de epicrisis y un corpus en español con etiqueta humana (ERSP de EsSalud). No se prevé procesar ni anotar más datos: el diseño trabaja con el corpus y las referencias ya existentes.

Continuidad. El título de la tesis se mantiene desde el proyecto aprobado en Trabajo de Investigación I (cerrado el 14 de julio de 2026). Este documento presenta el flujo experimental tal como se ejecutó y mejoró desde entonces (construcción del corpus completo, modelo final, validación con expertos y comparación con transformers y un modelo de lenguaje), incorporando lo aprendido en el curso de Procesamiento de Lenguaje Natural (auditoría adversarial de 26 hallazgos) y en la aplicación del mismo enfoque a los reportes de seguridad del paciente de EsSalud dentro del sistema GEM-VigIA.

1. Diagrama del flujo principal

Flujo experimental reproducible · Detección y priorización de eventos adversos en epicrisis (MIMIC-IV) con NLP supervisado + Matriz GEMSES




Figura 1: Pipeline reproducible en seis etapas, con la salida de cada una, los controles contra fugas y el estado de reproducibilidad.

2. Entradas, componentes y salida de cada etapa

Etapa	Recibe	Qué hace	Produce (artefacto reproducible)
1. Ingesta	MIMIC-IV v3.1 + MIMIC-IV-Note v2.2 (acuerdo de uso PhysioNet), leídos con DuckDB	Extrae las epicrisis (<i>discharge summaries</i>) con identificador de paciente, de hospitalización y códigos de egreso	331 793 epicrisis de 145 914 pacientes
2. Preprocesamiento y etiqueta	Epicrisis + diagnósticos codificados	Tier A: 223 códigos CIE-10 causales + 21 equivalencias OMS→CM → etiqueta A1 no circular; emparejamiento de época CIE-9/CIE-10 en los negativos; NegEx y regex Tier B solo como baseline	Corpus de modelado de 70 000 epicrisis con prevalencia real 0.2012
3. Partición y features	Corpus de modelado	Partición por paciente (GroupShuffleSplit), test 20 %, semilla 42, con verificación de pacientes disjuntos; TF-IDF de palabras (1–2-gramas, 60 000 rasgos, mínimo 3 documentos) + TF-IDF de caracteres (3–5, 20 000 rasgos, mínimo 5), escala sublineal; el vocabulario se ajusta solo con train	Conjunto de datos final en formato Parquet; matrices dispersas
4. Entrenamiento	Matrices TF-IDF	Cascada de dos etapas: E1 detección evento sí/no con LinearSVC balanceado; E2 naturaleza del evento, 6 clases multietiqueta, OneVsRest(LinearSVC), entrenada solo con positivos y con su propia partición por paciente; prueba de abstención con 6 textos triviales	Modelo final serializado (10.7 MB, fuera de git por el acuerdo de uso)
5. Evaluación	Test reservado; panel experto; corpus ERSP	Métricas con IC95 por <i>bootstrap</i> (200 réplicas) por nota y por paciente; cascada extremo a extremo; sistema contra consenso de expertos	JSON de resultados finales; JSON de métricas corregidas; JSON de sistema contra experto
6. Salida	Detecciones por nota	Matriz de Priorización GEMSES (Anexo 03 de la Directiva N.º 7-OGCyH-ESSALUD-2020): $G = 0.40 \cdot c + 0.20 \cdot d + 0.15 \cdot e + 0.25 \cdot f \rightarrow$ percentiles P25/P50/P75 $\rightarrow$ banda Verde/Amarillo/Rojo y responsable	Tablero de priorización (prototipo)

Fuente de datos, unidad de análisis y variable objetivo. La unidad de análisis es la epicrisis (una por hospitalización). La variable objetivo de E1 es binaria (¿la hospitalización tuvo un evento adverso codificado como causal?) y la de E2 es la *naturaleza* del evento según la Tabla de Codificación (Anexo 02 de la misma Directiva), reducida a 6 clases con n suficiente. No hay valores faltantes numéricos ni escalamiento: el texto es la única entrada del modelo y TF-IDF ya normaliza; la fusión con variables tabulares prevista en el proyecto original no se ejecutó y queda fuera del alcance.

Regla de partición. Se respeta la unidad *paciente*: ningún paciente aparece a la vez en train y test. En la comparación inicial de modelos se comprobó que el split por paciente no degrada el rendimiento (F1-macro 0.492 ± 0.018) y desde entonces es obligatorio. Desarrollo y ajuste se hacen con validación cruzada de 5 pliegues dentro del train; el test se toca una sola vez; el panel experto y el corpus ERSP actúan como evaluación externa.

3. Proceso de obtención de la base de datos MIMIC-IV

MIMIC-IV no se descarga libremente: PhysioNet (MIT) exige acreditación personal, formación en ética de investigación y un acuerdo de uso de datos. El proceso completo, con fechas y tiempos, fue el siguiente.




Figura 2: Proceso de obtención de MIMIC-IV: pasos, requisitos cumplidos y tiempos.

Paso	Fecha	Qué se hizo	Requisito que cubre
0. Decisión de la fuente	27–28 abr 2026	Sin acceso a historias clínicas de EsSalud, MIMIC-IV pasa de plan B a dataset principal	Viabilidad del proyecto
1. Registro en PhysioNet	28 abr 2026	Cuenta con nombre real y afiliación académica	Identidad y afiliación verificables
2. Certificación ética CITI	28 abr 2026	Curso «Data or Specimens Only Research» (MIT Affiliates), nota 95/100 (mínimo 90); segundo curso «Ética en Investigación» bajo EsSalud, nota 96/100. Ambos vigentes hasta el 28 abr 2029	Formación en protección de sujetos humanos y HIPAA

Paso	Fecha	Qué se hizo	Requisito que cubre
3. Solicitud de acceso y acuerdo de uso	28 abr 2026	Solicitud de <i>credentialed access</i> y firma del <i>Credentialed Health Data Use Agreement</i> v1.5.0 para MIMIC-IV v3.1	No reidentificar, no redistribuir, no compartir texto, citar el DOI
4. Acceso confirmado a MIMIC-IV v3.1	28 abr 2026	Módulos hosp e icu: 364 627 pacientes, 546 028 hospitalizaciones, 94 458 estancias en UCI (DOI 10.13026/kpb9-mt58)	Acceso otorgado
5. Acuerdo específico de MIMIC-IV-Note v2.2	10–11 may 2026	Las notas clínicas tienen su propio acuerdo de uso (DOI 10.13026/1n74-ne17); descarga de 4 archivos comprimidos = 1.96 GB (epicrisis 1.14 GB; radiología 781 MB; dos archivos de metadatos)	Acceso al texto libre
6. Entorno y primera lectura	11 may 2026	Python 3.13.5 + DuckDB 1.5.2 leen los archivos comprimidos sin cargarlos a memoria; consulta de verificación: 331 793 epicrisis, 100 % del tipo <i>discharge summary</i> , consistente con el artículo oficial del dataset	Lectura reproducible
7. Integridad del dataset completo	14 may 2026	Descarga y descompresión de los 33 archivos de MIMIC-IV v3.1; verificación SHA-256 contra el listado oficial: 33/33 íntegros; datos en disco local y excluidos del control de versiones	Integridad y cumplimiento del acuerdo

Tiempos. Registro, cursos de ética, acuerdo de uso y acceso a MIMIC-IV: **1 día** (28 de abril de 2026). Desde el acceso principal hasta el acuerdo de notas y la descarga de 1.96 GB: **13 días**. Desde la decisión del dataset hasta el corpus completo verificado: **17 días** (27 de abril al 14 de mayo). **Costo:** S/ 0; el acceso es gratuito con acreditación.

Requisitos adicionales que el proyecto se impuso: segunda certificación ética bajo EsSalud (no exigida por PhysioNet, añadida por la afiliación institucional del autor); declaración explícita de conflicto de interés (autor del Modelo GEMSES y ex directivo de la instancia de EsSalud que emite la Directiva); acceso al texto de MIMIC-IV restringido al investigador principal, único acreditado; y exclusión de todo dato, modelo entrenado y copia de trabajo del repositorio de código.

4. Baseline, familia de modelos y alternativas ya descartadas

- **Baseline mínimo:** reglas regex Tier B + NegEx, precisión 65.7 % (IC95 54.0–75.8, n = 70, validación experta de mayo), y TF-IDF + regresión logística (comparación inicial de modelos).
- **Familia elegida:** modelo lineal sobre TF-IDF (LinearSVC balanceado), en cascada. Es el modelo vigente desde el 29 de julio de 2026.
- **Alternativas probadas y refutadas** con la misma partición y semilla (hipótesis HE2): ClinicalBERT congelado F1-macro 0.19; Bio_ClinicalBERT y BioBERT con ajuste fino en GPU 0.21–0.35 (2.9–4.0 h) frente a 0.459 del lineal en 48 s; BioClinical ModernBERT con ventana de 1024 tokens 0.428 tras 42.5 h de GPU; Llama 3.2 3B *zero-shot* kappa 0.0 (clasificó todos los casos como positivos). Causa medida: la ventana de 256 tokens cubre el 9 % de una epicrisis (mediana 3 148 tokens). Se documenta como resultado negativo; solo se reabría con Longformer o BigBird y GPU dedicada.

5. Criterio preliminar de evaluación

Toda comparación entre modelos se hace con la misma partición (semilla 42, por paciente) y se reporta siempre la cascada, porque el pipeline completo rinde menos que sus etapas.

Nivel	Criterio	Situación al 25-set-2026
Métrica principal	F1-macro de la cascada completa con IC95 por paciente (no la etapa aislada)	0.363 en cascada frente a 0.536 de E2 aislada
Secundarias	E1: sensibilidad, especificidad, AUC y VPP a prevalencia real; E2: F1-micro; abstención	sens 0.762, esp 0.770, AUC 0.843, VPP 0.455; F1-micro 0.745; abstención 6/6
Bueno	Supera el baseline de reglas y kappa sistema-experto ≥ 0.61 (umbral fijado en la hipótesis general del proyecto)	kappa 0.531 (n = 68, solo infección): no alcanzado
Aceptable	Supera el baseline lineal en cascada y F1 > 0.5 en toda clase con n ≥ 100	Cumplido en Infección y Procedimiento; Sistema/Organización (n = 66) F1 0.0
Fuera de alcance	Clases con n insuficiente: Sistema/Organización, Sangre/Hemoderivados, Nutrición	Declaradas no viables, no se intenta corregirlas

6. Reproducibilidad

- **Versiones fijas:** MIMIC-IV v3.1 (DOI 10.13026/kpb9-mt58), MIMIC-IV-Note v2.2 (DOI 10.13026/1n74-ne17), Python 3.13.5, DuckDB 1.5.2; versión de scikit-learn **por fijar** en el archivo de dependencias.
- **Semillas:** 42 en la partición, en el muestreo del corpus y en el *bootstrap*.
- **Registro de experimentos:** un archivo JSON de resultados por fase, más bitácoras fechadas por sesión. Cada cifra del borrador de tesis lleva un comentario con el archivo del que proviene, verificado por script.
- **Artefactos:** modelo final serializado, conjunto de datos final (Parquet), JSON de resultados finales y JSON de métricas corregidas. Modelo y datos quedan fuera de git por el acuerdo de uso; el repositorio de la tesis es privado desde el 28-jul-2026.
- **Estado actual y brecha:** todavía no existe un archivo de dependencias con versiones fijadas, ni una plantilla de variables de entorno, ni un orquestador que encadene las fases, ni la estructura data/raw y data/processed; hay 46 scripts, uno por fase; la sección “Cómo reproducir” del README apunta al notebook exploratorio y no a la cascada; los *checkpoints* de los transformers no se conservaron (solo son reproducibles reentrenando). El Sprint 1 del curso se dedica a cerrar esta brecha, con un criterio de aceptación medible: que un tercero con credencial PhysioNet regenere el modelo final y sus métricas con un solo comando y obtenga sens 0.7623, esp 0.7699 y AUC 0.8426 con tolerancia ± 0.005 .

7. Riesgos técnicos previsibles y cómo se detectan o mitigan

Riesgo	Dónde se detectó (frente)	Mitigación incorporada al diseño
Fuga por circularidad regex → etiqueta	Tesis / PLN: enmascarar los disparadores solo baja 1.35 puntos	Etiqueta A1 derivada de códigos CIE-10 causales, no del regex
Confusor de época CIE-9/CIE-10	Tesis, análisis del confusor de época: AUC 0.973 → 0.840 al emparejar	Emparejamiento de época en los negativos; se descarta la cifra 0.973
Fuga por paciente	PLN (auditoría adversarial)	Partición por paciente con verificación automática
Fuga por estilo de redacción	GEM-VigIA: el triaje reclamo/denuncia daba 98.4 %, y 91.5 % solo con palabras funcionales	Ablaciones de control; no se usan metadatos de quién redacta
Mezcla de centros asistenciales	GEM-VigIA sobre el mismo corpus ERSP: 0.77 estratificado frente a 0.42 por centro	El OE5 se re-mide con partición por centro antes de citarse; 0.7675 solo como cota superior

Riesgo	Dónde se detectó (frente)	Mitigación incorporada al diseño
Datos insuficientes por clase	Tesis, comparación de modelos y modelo final	Clases con $n < 100$ declaradas no viables
Referencia de etiqueta débil	Panel experto limitado a infección; $\kappa 0.531 < 0.61$	Decisión de alcance (20-set): A1 como estándar plata principal, panel como validación secundaria; limitación declarada
Costo y latencia	Transformers 2.9–42.5 h de GPU frente a 48 s	Familia lineal; transformers cerrados como resultado negativo
Restricciones del entorno y datos personales	Acuerdo de uso PhysioNet; el corpus ERSP contiene datos personales	Modelo y datos fuera del control de versiones; repositorio privado; copias de trabajo del ERSP anonimizadas antes de cualquier uso
Pérdida de resultados intermedios	Tesis: se perdieron las filas por nota del primer tramo (260 000) al morir el proceso	Orquestador con <i>checkpoint</i> por fase (Sprint 1)