



UNIVERSIDAD NACIONAL DE INGENIERÍA

Facultad de Ingeniería Industrial y de Sistemas
Unidad de Posgrado · Maestría en Inteligencia Artificial

MATRIZ DE CONSISTENCIA

Curso: MIA-14 · Trabajo de Investigación II · Sección B · 2026-2

PROCESO

Coherencia entre problema, objetivos, hipótesis, variables y metodología del proyecto de tesis

TESIS

*Detección Automatizada y Priorización de Eventos Adversos en Notas Clínicas
mediante un Flujo de Procesamiento (Pipeline) de NLP y Aprendizaje Automático
— Aplicación de la Matriz de Priorización del Modelo GEMSES sobre MIMIC-IV*

Autor: Carlos Pérez Pérez

Docente: Dr. Ing. Glen Dario Rodríguez Rafael

Fecha: Octubre de 2026

Matriz de consistencia de la investigación

Problema	Objetivos	Hipótesis	Variables e indicadores	Metodología
Problema general. ¿En qué medida un pipeline integrado de procesamiento de lenguaje natural y aprendizaje automático supervisado, aplicado sobre notas clínicas no estructuradas del dataset MIMIC-IV, permite detectar eventos adversos y aplicar la Matriz de Priorización del Modelo GEMSES —incluyendo la asignación automática del Nivel de Gestión y del responsable institucional— con una concordancia significativamente mayor a la clasificación manual experta tradicional?	Objetivo general. Diseñar, implementar y validar un sistema basado en procesamiento de lenguaje natural y aprendizaje automático que detecte eventos adversos a partir de notas clínicas no estructuradas de MIMIC-IV y los priorice automáticamente aplicando la Matriz de Priorización del Modelo GEMSES —incluyendo el cálculo automatizado del Nivel de Gestión y la asignación del responsable institucional—, con miras a su transferencia metodológica a sistemas sanitarios de habla hispana y, en particular, a la red asistencial de EsSalud.	Hipótesis general. Un pipeline integrado de procesamiento de lenguaje natural y aprendizaje automático supervisado, aplicado sobre notas clínicas no estructuradas de MIMIC-IV, permite detectar eventos adversos y aplicar automáticamente la Matriz de Priorización del Modelo GEMSES con una concordancia (kappa de Cohen) de al menos 0.61 —sustancial según Landis y Koch (1977)— respecto a la clasificación manual experta, demostrando la viabilidad de operacionalizar el modelo sobre datos clínicos reales de forma reproducible y transferible.	Variable independiente: arquitectura del modelo de clasificación (clásico TF-IDF/LinearSVC frente a transformer BioBERT/ClinicalBERT). Variables dependientes: concordancia con el experto (kappa de Cohen y PABAK, global y por etiqueta, con IC 95 %); desempeño de clasificación (F1 ponderado formulado en el proyecto y F1-macro adoptado por el desbalance de clases; sensibilidad, especificidad y AUC en la detección); nivel de gestión asignado (Verde/Amarillo/Rojo). Variables intervinientes: desbalance de clases (proporción de notas por naturaleza del Anexo 02); negaciones en el texto (menciones negadas filtradas por NegEx); cobertura del mapeo CIE-10 (número de códigos curados).	Tipo: aplicada y tecnológica; enfoque cuantitativo. Nivel: descriptivo-correlacional. Diseño: no experimental, transversal (un único corte de MIMIC-IV v3.1 y MIMIC-IV-Note v2.2). Método: deductivo y de desarrollo tecnológico, en tres fases: analítica, de síntesis y de validación. Población: 331 793 epicrisis de MIMIC-IV-Note v2.2 de 145 914 pacientes del Beth Israel Deaconess Medical Center (2008–2019), con 545 497 hospitalizaciones en el módulo hospitalario.
PE1. ¿La supervisión débil basada en códigos ICD-10 y patrones de texto, depurada con NegEx, produce un corpus etiquetado con cobertura suficiente de las naturalezas de evento del Anexo 02?	OE1. Construir un corpus etiquetado de eventos adversos a partir de notas clínicas no estructuradas de MIMIC-IV, utilizando como marco los 188 eventos detectables (de los 231 del Anexo 02 de la Directiva N.º 7-OGCyH-ESSALUD-2020), clasificados en cuatro niveles de detección: (A) ICD-10 + NLP, (B) patrones de texto libre, (C) variables estructuradas calculadas y (D) auditoría de completitud de historia clínica.	HE1. La supervisión débil basada en códigos ICD-10 y patrones de texto, depurada con NegEx, produce un corpus etiquetado con cobertura suficiente de las naturalezas de evento del Anexo 02 para entrenar modelos supervisados.	Naturalezas del Anexo 02 cubiertas por el corpus; número de notas candidatas por nivel de detección (A, B, C, D); menciones negadas filtradas por NegEx; cobertura del mapeo CIE-10 (149 códigos formulados, ampliados a 272 entradas tras la homologación CIE-10 OMS → CIE-10-CM).	Técnica: observación documental automatizada sobre datos secundarios; supervisión débil (reglas sobre códigos CIE-10 y patrones de texto) depurada con NegEx. Instrumentos: tabla Anexo 02 ↔ CIE-10 (272 filas, 223 códigos únicos) y equivalencias CIE-10 OMS → CIE-10-CM; lectura de las 331 793 epicrisis con DuckDB.
PE2. ¿En qué medida los modelos transformer biomédicos superan a los modelos clásicos (TF-IDF con regresión logística y LinearSVC) en la clasificación de eventos adversos en texto libre?	OE2. Implementar y comparar al menos tres modelos de procesamiento de lenguaje natural para la detección y clasificación de eventos adversos en texto libre, incluyendo transformers biomédicos (BioBERT, Bio+Clinical BERT) y modelos clásicos de referencia (TF-IDF con regresión logística y LinearSVC).	HE2. Los modelos transformer biomédicos (BioBERT, Bio+Clinical BERT), tras ajuste fino, superan en F1 ponderado a los modelos clásicos de referencia (TF-IDF con regresión logística y LinearSVC).	F1 ponderado y F1-macro por modelo; precisión y recall por clase; sensibilidad, especificidad y AUC en la detección binaria.	Muestra de modelado: 70 000 epicrisis (37 692 positivas), con dos negativos por positivo emparejados por época de codificación; partición por paciente, semilla 42. Modelos: TF-IDF con regresión logística y LinearSVC; BioBERT, Bio_ClinicalBERT y BioClinical ModernBERT con ajuste fino; Llama 3.2 3B en local como control. Análisis: F1-macro con IC 95 % por bootstrap agrupado por paciente (2 000 remuestreos); misma partición y semilla para todos los modelos.

Problema	Objetivos	Hipótesis	Variables e indicadores	Metodología
PE3. ¿La automatización de la fórmula de priorización GEMSES reproduce el Nivel de Gestión (Verde/Amarillo/Rojo) y el responsable institucional sin intervención manual?	OE3. Automatizar la priorización GEMSES aplicando a cada evento detectado la cadena Nivel de Riesgo = Frecuencia × Impacto, con los pesos de impacto del Anexo 02 y las cuatro dimensiones del Modelo GEMSES (Tiempo, Calidad, Costos y Satisfacción del paciente), y determinar automáticamente el Nivel de Gestión (Verde/Amarillo/Rojo) y el responsable institucional.	HE3. La automatización de la fórmula de priorización GEMSES reproduce el Nivel de Gestión (Verde/Amarillo/Rojo) y el responsable institucional sin intervención manual.	Nivel de Riesgo (Frecuencia × Impacto); Nivel de Gestión asignado (Verde/Amarillo/Rojo); responsable institucional asignado; ponderación de las dimensiones Tiempo, Calidad, Costos y Satisfacción.	Instrumento: Matriz de Priorización del Modelo GEMSES (Anexos 02 y 03 de la Directiva N.º 7-OGCyH-ESSALUD-2020; Pérez Pérez, 2021). Procedimiento: cálculo automatizado de la cadena Frecuencia × Impacto → Nivel de Gestión → Responsable para cada evento detectado.
PE4. ¿Cuál es el desempeño comparativo del pipeline frente a la revisión manual de dos evaluadores expertos sobre una muestra estratificada de notas?	OE4. Validar la precisión del pipeline comparando sus resultados con la revisión manual independiente de dos evaluadores expertos sobre una muestra estratificada de 350 notas clínicas, evaluando el acuerdo inter-evaluador y la concordancia del sistema con el consenso de ambos.	HE4. El acuerdo entre los dos evaluadores expertos es sustancial y la concordancia entre el pipeline y su consenso alcanza un kappa de Cohen ≥ 0.61 sobre la muestra estratificada.	Kappa inter-evaluador; kappa pipeline–consenso con IC 95 % bootstrap BCa; acuerdo observado; PABAK; índices de prevalencia y sesgo.	Muestra: prevista de 350 notas estratificadas por naturaleza; ejecutada como muestra ciega de 250 casos del estrato de infección (semilla 42) más 30 controles negativos (semilla 77). Instrumentos: manual de anotación v2 y aplicación de revisión ciega; dos anotadores independientes. Análisis: kappa de Cohen con intervalo BCa (10 000 remuestreos) y PABAK; interpretación según Landis y Koch (1977).
PE5. ¿Es transferible el método a notas clínicas en español y qué retos lingüísticos, taxonómicos y de localización deben abordarse para su implementación en EsSalud?	OE5. Documentar el método de transferencia del pipeline a sistemas sanitarios de habla hispana, identificando los retos lingüísticos, taxonómicos y de localización que deberán abordarse para su implementación en EsSalud u otras instituciones equivalentes.	HE5. El método es transferible a notas clínicas en español apoyándose en recursos como BETO y MedLexSp.	Protocolo de transferencia documentado; retos lingüísticos, taxonómicos y de localización identificados; desempeño de la clasificación sobre el corpus en español.	Corpus de transferencia: base ERSP de EsSalud, 8 799 registros en español codificados contra los Anexos 02 y 03; 6 336 registros únicos tras retirar textos cortos y deduplicar. Análisis: misma familia de modelos y métricas que en OE2, sobre las tareas evento/incidente, naturaleza y severidad.