UNIVERSIDAD NACIONAL DE INGENIERÍA

UNIDAD DE POSGRADO – FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

INFORME PARCIAL

PROYECTO DE INVESTIGACIÓN II

PLAN DE TESIS Y PROTOCOLO DE INVESTIGACIÓN

Título de tesis: Detección Automatizada y Priorización de Eventos Adversos en Notas Clínicas mediante un Flujo de Procesamiento (*Pipeline*) de NLP y Aprendizaje Automático — Aplicación de la Matriz de Priorización del Modelo GEMSES sobre MIMIC-IV

Programa: Maestría en Inteligencia Artificial

Estudiante: Carlos Pérez Pérez

Docente del curso: Dr. Ing. Glen Dario Rodríguez Rafael

Lima, noviembre de 2026

Índice

PARTE I. PLAN DE TESIS 5
Datos generales 5
CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA 5
1.1 Diagnóstico 5
1.1.1 Identificación y descripción del problema de estudio 6
1.1.2 Antecedentes bibliográficos 6
1.1.3 Formulación del problema 9
1.2 Justificación y alcances 10
1.2.1 Justificación 10
1.2.2 Alcances 10
CAPÍTULO II. OBJETIVOS 12
2.1 Objetivo general 12
2.2 Objetivos específicos 12
CAPÍTULO III. MARCO TEÓRICO 13
3.1 Bases teóricas 13
3.1.1 Evento adverso, notificación y codificación 13
3.1.2 Procesamiento de lenguaje natural y aprendizaje automático 14
3.1.3 Evaluación de la detección 15
3.1.4 Priorización de la gestión con la Matriz GEMSES 16
3.2 Definición de términos 17
3.3 Hipótesis y variables 18
3.3.1 Hipótesis 18
3.3.2 Variables 19
CAPÍTULO IV. METODOLOGÍA 20
4.1 Tipo de investigación 20
4.2 Nivel de investigación 20

4.3 Métodos de trabajo 20
4.4 Población y muestra 21
4.5 Tipo de diseño 22
4.6 Técnicas e instrumentos de recolección de datos 22
4.7 Técnicas e instrumentos de análisis y procesamiento de datos 23
4.8 Etapas de intervención del estudio 25
CAPÍTULO V. ADMINISTRACIÓN DEL PLAN DE TESIS 26
5.1 Cronograma 26
5.2 Presupuesto 26
5.3 Financiamiento 27
PARTE II. PROTOCOLO DE INVESTIGACIÓN Y AVANCE EXPERIMENTAL 28
6. Datos y material de estudio 28
6.1 Origen, condiciones de uso y trazabilidad 28
6.2 Estructura, diccionario de datos y análisis exploratorio 29
6.3 Ética, privacidad y seguridad 30
6.4 Preprocesamiento y control de fuga de información 31
7. Protocolo experimental 32
7.1 Preguntas de evaluación y criterios de éxito 33
7.2 Diseño de particiones y validación 33
7.3 Métricas y análisis estadístico 34
7.4 *Baseline* y variantes 35
7.5 Ingeniería de atributos o componentes 36
7.6 Optimización y presupuesto de búsqueda 37
7.7 Reproducibilidad y registro de experimentos 38
8. Resultados parciales y evidencia 40
8.1 Estado de implementación del *pipeline* 40
8.2 Comparación cuantitativa del *baseline* y variantes 41

8.3 Ablaciones y análisis de sensibilidad 45
8.4 Sobreajuste, errores y robustez 46
8.5 Interpretación y amenazas a la validez 48
9. Conclusiones del avance y próximos pasos 50
9.1 Conclusiones sustentadas por evidencia 50
9.2 Riesgos y plan de mitigación 51
9.3 Trabajo futuro para el siguiente sprint 53
REFERENCIAS 54
ANEXOS 58
Anexo A. Matriz de consistencia 58
Anexo B. Cronograma detallado 60
Anexo C. Diccionario de datos 61
Anexo D. Registro de corridas 62
Anexo E. Evidencia de ejecución, repositorio y figuras 64
Anexo F. Enlace a la última rama del repositorio 68

PARTE I. PLAN DE TESIS

Datos generales

Campo	Información
Título del plan de tesis	Detección Automatizada y Priorización de Eventos Adversos en Notas Clínicas mediante un Flujo de Procesamiento (*Pipeline*) de NLP y Aprendizaje Automático — Aplicación de la Matriz de Priorización del Modelo GEMSES sobre MIMIC-IV
Autor	Carlos Pérez Pérez
Asesora	XXXXXXXXXXXXX
Unidad de posgrado y programa	Unidad de Posgrado de la Facultad de Ingeniería Industrial y de Sistemas, Maestría en Inteligencia Artificial
Lugar o institución	Universidad Nacional de Ingeniería, Lima, Perú. Los datos proceden de MIMIC-IV (versión IV de Medical Information Mart for Intensive Care), base de datos de la historia clínica electrónica del Beth Israel Deaconess Medical Center (Boston, Estados Unidos). Se accede a ella mediante PhysioNet, con credencial y acuerdo de uso de datos
Duración estimada	14 meses, del 1 de marzo de 2026 al 30 de abril de 2027

CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA

1.1 Diagnóstico

Brennan et al. (1991) definen el evento adverso como la lesión causada por el manejo médico y, al revisar 30 121 historias clínicas de 1984 en 51 hospitales del estado de Nueva York, estimaron que ocurrió en el 3.7 % de las hospitalizaciones. En una revisión sistemática de ocho estudios, de Vries et al. (2008) reportan una incidencia mediana de 9.2 % de eventos adversos intrahospitalarios, con una mediana de 43.5 % de eventos prevenibles.

Sin embargo, la notificación voluntaria capta una fracción pequeña de esos eventos. La Office of Inspector General (OIG, 2012) estimó que, de los eventos de los beneficiarios de Medicare egresados en octubre de 2008, los sistemas de notificación de los hospitales captaron solo el 14 %.

En el Seguro Social de Salud del Perú, la Directiva de Gerencia General N.° 7-OGCyH-ESSALUD-2020 organiza el registro, la notificación y la gestión de los eventos relacionados con la seguridad del paciente (ERSP) en cinco fases (Seguro Social de Salud [EsSalud], 2020, num. 17.1). En la notificación, la Oficina de Calidad de la IPRESS (institución prestadora de servicios de salud), o quien haga sus veces, valida cada ficha y determina si corresponde a un ERSP (num. 19.1).

Luego, el sistema informático determina el nivel de gestión de cada grupo de eventos con la Matriz de Priorización del Anexo N.° 03, en función del índice de frecuencia y del impacto

(EsSalud, 2020, num. 17.1 y 19.10 a 19.12). Según el num. 5.13, dicha matriz es una herramienta de priorización del modelo de Gestión Moderna de los Servicios de Salud (GEMSES).

1.1.1 Identificación y descripción del problema de estudio

A partir del diagnóstico, se identifica que el sistema agrupa los ERSP notificados según su identificador de evento y, cada 15 días, determina su nivel de gestión con la Matriz de Priorización (EsSalud, 2020, num. 19.9 y 19.10). De ello se deriva que los eventos que no se notifican no llegan a priorizarse, lo cual constituye el problema de gestión que motiva la tesis. Al respecto, la Oficina de Calidad podrá implementar otros mecanismos para promover el registro de los ERSP (num. 18.3), y una revisión de epicrisis podría ser uno de ellos, cuya viabilidad depende de cuántas deban leerse por evento hallado (ver sección 4.7).

La tesis estudia ese problema con las epicrisis de MIMIC-IV (Johnson, Bulgarelli, et al., 2023). Es preciso tomar en consideración que esta base no contiene las notificaciones de los eventos, sino los códigos de diagnóstico de cada hospitalización, por lo que el registro que se contrasta es la codificación hospitalaria. Por otra parte, ninguna epicrisis tiene una anotación clínica del evento, de manera que el modelo se entrena con una etiqueta débil construida con los códigos de causa explícita y se valida después con una revisión ciega de las epicrisis que marca sin código.

En síntesis, el problema de estudio es que el subregistro de los eventos adversos, que depende del reporte voluntario y de la codificación (Classen et al., 2011; OIG, 2012), impide conocer su magnitud y priorizar su gestión.

1.1.2 Antecedentes bibliográficos

Los antecedentes se presentan en orden cronológico, primero los internacionales y luego los latinoamericanos y nacionales. Los cinco previos a 2021 se incluyen como clásicos.

En el ámbito internacional, Melton y Hripcsak (2005) aplicaron el sistema de procesamiento de lenguaje natural (PLN, o NLP por sus siglas en inglés) MedLEE a 57 452 epicrisis para detectar eventos adversos. La notificación tradicional detectó 322 eventos, con una sensibilidad de 0.09, mientras que el sistema alcanzó una sensibilidad de 0.28, una especificidad de 0.985 y un valor predictivo positivo (VPP) de 0.45, e identificó 594 eventos que esa notificación no había captado. Al igual que la tesis, este estudio lee la epicrisis para hallar lo que el registro no capta.

Murff et al. (2011) compararon, en 2 974 pacientes quirúrgicos de seis centros médicos de la Veterans Health Administration, el PLN aplicado a la historia clínica electrónica con los indicadores de seguridad del paciente basados en la codificación del alta. El PLN tuvo mayor sensibilidad para la insuficiencia renal aguda que requirió diálisis (82 % frente a 38 %), la neumonía (64 % frente a 5 %) y la sepsis (89 % frente a 34 %), aunque con menor especificidad. De esta manera, el texto captó complicaciones que la codificación omitió, que es el contraste que plantea la tesis.

Classen et al. (2011) aplicaron tres métodos a los mismos pacientes y hallaron eventos adversos en un tercio de las hospitalizaciones. La notificación voluntaria y los indicadores de seguridad del paciente de la AHRQ (Agency for Healthcare Research and Quality) no detectaron el 90 % de esos eventos. En cambio, la herramienta de disparadores (*Global Trigger Tool*) halló al menos diez veces más eventos graves confirmados que ambos métodos.

Henry et al. (2020) resumen la tarea compartida n2c2 de 2018, en la cual los equipos extrajeron de epicrisis los eventos adversos por medicamentos y otros conceptos, así como sus relaciones. Los mejores sistemas alcanzaron un F1 de 0.8905 de extremo a extremo, pero el desempeño fue mucho menor en los eventos adversos, que a menudo se perdían porque el contexto local no bastaba para identificarlos. Por ello, la tesis lee la epicrisis completa.

Zheng et al. (2022) revisaron en forma sistemática ocho estudios que aplicaron PLN a las notas clínicas para identificar a los pacientes con hipoglucemia, y todos usaron PLN basado en reglas. Como ejemplo, reportan una prevalencia de 12.4 % con los códigos de la Clasificación Internacional de Enfermedades (CIE), de 25.1 % con un algoritmo de PLN y de 32.2 % al combinar ambos. Por consiguiente, el texto clínico captó eventos que los códigos no registraron, lo cual sustenta buscar eventos en las epicrisis sin código.

Whitaker et al. (2022) exploraron, en un sistema de salud académico, si el aprendizaje automático con PLN identifica las reacciones alérgicas a la transfusión. Para ello, tomaron las 146 reacciones notificadas entre 86 764 transfusiones y una muestra aleatoria de 605 transfusiones sin reacción notificada. Con el umbral de 0.9, la revisión clínica de los casos de validación dio una sensibilidad de 67.9 %, una especificidad de 97.5 % y un VPP de 84 %, que se estimó en 4.5 % al extrapolarlo a la incidencia del total de transfusiones.

Yasrebi-de Kom et al. (2023) revisaron en forma sistemática 25 artículos con modelos de predicción de eventos adversos por medicamentos en adultos hospitalizados, basados en

datos estructurados de la historia clínica. La mayoría usó etiquetas que solo describían un síntoma adverso, sin evaluar la causalidad, y ningún modelo tuvo validación externa.

Cheligeer et al. (2024) desarrollaron un modelo BERT (*Bidirectional Encoder Representations from Transformers*) preentrenado con notas clínicas para detectar las caídas intrahospitalarias en las notas de evolución de 4 323 adultos de tres hospitales de Calgary, Canadá, con la revisión de enfermeras entrenadas como referencia. Entre sus variantes, una alcanzó 97.7 % de sensibilidad y 15.6 % de VPP, y otra, 85.7 % de VPP y 27.9 % de sensibilidad. Asimismo, el método superó a tres algoritmos clásicos de aprendizaje automático y a uno basado en códigos CIE, de modo que, como la tesis, contrasta el texto con los códigos.

Modi et al. (2024) revisaron en forma sistemática, según la declaración PRISMA (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*) 2020, la extracción de eventos adversos por medicamentos de las notas clínicas. De 5 537 artículos de 2015 a 2023 analizaron 82, entre los cuales el enfoque más frecuente fue el aprendizaje profundo, con 32 estudios, y ocho usaron modelos grandes de lenguaje. A diferencia de ese enfoque, la tesis adopta un modelo lineal sobre el texto completo, por las razones del Capítulo III.

Ferrara et al. (2024) revisaron en forma sistemática, según PRISMA, el impacto de la inteligencia artificial en la gestión del riesgo clínico en 36 artículos, y concluyen que esta requiere supervisión humana y no reemplaza por completo las capacidades humanas.

De Micco et al. (2025), en una revisión sistemática según PRISMA 2020, reportan que el aprendizaje automático y el PLN son prometedores para detectar eventos adversos, predecir errores de medicación, evaluar el riesgo de caídas y prevenir lesiones por presión. Sin embargo, señalan desafíos sociotécnicos, de implementación y de estandarización.

Tsuchiya et al. (2025) validaron un modelo de PLN para identificar el síndrome mano-pie inducido por capecitabina en el texto clínico de la historia electrónica del Hospital de la Universidad de Tokio (2004 a 2021). En la validación con 2 606 documentos clínicos de 62 pacientes, anotados por dos expertos, el modelo alcanzó en el nivel de paciente una precisión de 0.875, una sensibilidad de 1.000 y un F1 de 0.933.

En el ámbito latinoamericano, el Estudio Iberoamericano de Eventos Adversos (IBEAS) revisó a 11 379 pacientes hospitalizados en 58 hospitales de Argentina, Colombia, Costa Rica, México y el Perú (Aranaz-Andrés et al., 2011). Estimó una prevalencia puntual de 10.5 %, con un intervalo de confianza al 95 % (IC 95 %) de 9.91 % a 11.04 %, de pacientes

con al menos un evento adverso. Asimismo, más del 28 % de esos eventos causó discapacidad, otro 6 % se asoció con la muerte del paciente y casi el 60 % se consideró prevenible.

Camacho-Rodríguez et al. (2022) revisaron en forma sistemática, con metaanálisis, 30 estudios de cultura de seguridad del paciente, uno de ellos del Perú, realizados en hospitales de cinco países latinoamericanos. La percepción positiva global fue de 48 % (IC 95 %: 44.53 % a 51.60 %), y las dimensiones menos positivas fueron la respuesta no punitiva al error y la dotación de personal. Dado que la respuesta no punitiva al error fue una de las dimensiones menos positivas, la tesis busca detectar los eventos sin depender de la notificación.

En el ámbito nacional, el 8 de noviembre de 2026 se buscó en PubMed, en el título o resumen, *Peru* con *natural language processing*, *machine learning*, *text mining* o *artificial intelligence* y con *adverse event*, *adverse events*, *patient safety*, *medical error* o *medical errors*. Ni dicha búsqueda ni una variante más amplia devolvieron artículos sobre el tema. Asimismo, el 11 de noviembre de 2026, las frases “eventos adversos”, “seguridad del paciente” y “procesamiento de lenguaje natural” devolvieron 90, 24 y 13 registros en el repositorio institucional de la UNI, ninguno sobre la detección de eventos adversos en el texto clínico.

En síntesis, los antecedentes muestran que el texto clínico capta eventos que la notificación y la codificación no registran, y que la detección automatizada orienta una revisión clínica que confirme los casos (Whitaker et al., 2022), bajo supervisión humana (Ferrara et al., 2024). Asimismo, dejan tres brechas que la tesis aborda: medir con revisión ciega cuántas detecciones sin código son eventos, dejar un protocolo replicable con epicrisis peruanas en un estudio posterior y vincular la detección con la priorización de la Directiva.

1.1.3 Formulación del problema

El problema general se formula de la siguiente manera:

¿En qué medida un *pipeline* de procesamiento de lenguaje natural y aprendizaje automático, aplicado a las epicrisis de MIMIC-IV, mejora, frente a la revisión al azar de las epicrisis sin código, la detección de los eventos adversos no registrados en la codificación hospitalaria?

De él se derivan dos problemas específicos (PE):

1) PE1. ¿En qué medida el contenido textual de la epicrisis aporta capacidad discriminativa adicional a la de las variables clínicas y administrativas de contexto para detectar los eventos adversos?
2) PE2. ¿El modelo concentra las epicrisis con eventos no registrados más que las epicrisis sin código que no marca?

1.2 Justificación y alcances

1.2.1 Justificación

La investigación se justifica en cuatro planos:

1) Teórico. Aporta evidencia sobre el entrenamiento con una etiqueta débil construida con códigos de diagnóstico, cuyo error corresponde a lo que la literatura describe como ruido de la etiqueta (Frénay y Verleysen, 2014) o supervisión imprecisa (Zhou, 2018). Asimismo, cuantifica el aporte del texto a la discriminación respecto de las variables de contexto, del cual depende el valor de todo modelo que use el texto clínico.
2) Práctico. Deja un criterio para decidir qué epicrisis revisar primero, en lugar de revisarlas al azar, que una Oficina de Calidad podría adaptar previa validación con epicrisis locales en español. Asimismo, lleva los eventos confirmados a la Matriz de Priorización de la Directiva, con lo cual resulta un nivel de gestión potencial.
3) Metodológico. Deja un protocolo reproducible, con partición por paciente, reglas de decisión previas, revisión ciega con controles al azar e IC por paciente.
4) Social. Los eventos no registrados no se gestionan, y en el IBEAS casi el 60 % de los eventos se consideró prevenible (Aranaz-Andrés et al., 2011). Por ello, detectarlos contribuye a la seguridad del paciente y a la humanización de la atención.

1.2.2 Alcances

La tesis se desarrolla en la Unidad de Posgrado de la Facultad de Ingeniería Industrial y de Sistemas (FIIS) de la Universidad Nacional de Ingeniería, en Lima. Los datos estructurados proceden de MIMIC-IV v3.1, que reúne a los pacientes que ingresaron a una unidad de cuidados intensivos (UCI) o al servicio de emergencia del Beth Israel Deaconess Medical Center, en Boston, entre 2008 y 2022 (Johnson et al., 2024). Las epicrisis proceden de MIMIC-IV-Note v2.2, que reúne las de los pacientes que ingresaron al hospital y al servicio de emergencia del mismo centro (Johnson, Pollard, et al., 2023).

La unidad de análisis es la epicrisis, escrita en inglés, y el modelo detecta al alta si la hospitalización tuvo al menos un evento adverso, sin predecirlo durante la estancia. Asimismo, el evento concreto lo identifica la revisión ciega, y la priorización GEMSES se aplica solo a los eventos que esta confirme. Las limitaciones del diseño son las siguientes:

1) La etiqueta de entrenamiento se construye con los códigos de diagnóstico y no con una lectura clínica, por lo cual el desempeño frente a ella mide la concordancia con la codificación y no con los eventos reales.
2) Solo 100 de las 241 epicrisis de la revisión ciega tendrán una segunda lectura independiente, por lo cual en las demás la referencia será la lectura del investigador, quien desarrolló el modelo, aunque lee sin conocer su marca. Si al 30 de noviembre de 2026 el segundo evaluador no tiene credencial propia, se invitará a otro evaluador clínico con credencial. Si al 31 de diciembre ninguno la tiene, esa lectura será la referencia en las 241, el kappa interevaluador no se informará y las conclusiones descansarán en ella, sin confirmación independiente.
3) La tabla de diagnósticos de MIMIC-IV no indica si la condición estaba presente al ingreso, por lo que la etiqueta excluye las que pueden venir de él.
4) Los datos proceden de un solo hospital de los Estados Unidos y están en inglés. Por ello, tanto la partición de prueba como las 98 931 epicrisis fuera del corpus son una evaluación interna, y la transferencia a las epicrisis peruanas en español requiere una validación externa propia. Además, esas 98 931 excluyen a los pacientes del corpus, por lo cual sus estimaciones no se extrapolan a toda la base.
5) Los experimentos de desarrollo usaron una sola semilla, por lo cual la primera hipótesis específica (HE1) exige estabilidad en otras cinco particiones por paciente.
6) El impacto impreso en el Anexo N.° 02 coincide con los pesos del num. 19.11 en solo 1 de los 231 eventos, el que tiene todos sus componentes en cero, y en 198 si la insatisfacción pondera 0.20. Por ello, esa columna solo se usa como sensibilidad.
7) Los modelos entrenados no se publican, pues su vocabulario proviene de las notas y el acceso a los datos no puede compartirse (PhysioNet, s. f., cláusula 3).
8) La revisión ciega solo anota el evento cuyo nexo con la atención está documentado (C3 o C4), aunque la Directiva admite el daño asociado indirectamente (num. 5.3), por lo cual puede subestimar los eventos respecto de la definición normativa.

9) El corpus tiene 53.8 % de epicrisis con evento, frente a una prevalencia de la etiqueta de 27.6 %, y el modelo usa pesos balanceados, de modo que su puntaje no es una probabilidad calibrada. Por ello, su uso operativo exige recalibrarlo.

10) MIMIC-IV no registra costos ni la satisfacción y desplaza las fechas, por lo cual la Matriz GEMSES se aplica en forma exploratoria, con un impacto parcial y sin el semestre de la Directiva. Asimismo, la estancia y el paso por la UCI, de los que se derivan los indicadores del impacto, son variables de contexto y no separan el efecto del evento del de la enfermedad. Por otra parte, como el índice de frecuencia es relativo a todos los eventos confirmados, el nivel de cada grupo depende también de los demás. Además, cada control confirmado pesa casi nueve veces más que una detección (924.4 frente a 104.2), por lo cual el nivel de un grupo puede depender de uno o dos casos.

11) Con 151 detecciones, 90 controles y un VPP de 0.35, la potencia de la segunda hipótesis específica (HE2) es de 0.80 para una diferencia de 0.164 y de 0.37 para una de 0.10. Por ello, si no se cumple, se descarta una diferencia de 0.10 o mayor solo si el límite superior de su IC es menor que esa cifra, y en otro caso el resultado es no concluyente.

12) La HE1 no es ciega respecto de su dirección. En la prueba ya se conocían el área bajo la curva ROC (*receiver operating characteristic*) o ROC-AUC de 0.864 de la línea de base, con las palabras, la de 0.760 del análisis exploratorio, sin texto, y la de 0.8706 del modelo adoptado. Así, al fijar el umbral de 0.05 ya se conocía la magnitud aproximada de la diferencia, y la decisión confirmatoria recae en la HE2.

CAPÍTULO II. OBJETIVOS

2.1 Objetivo general

Mejorar, frente a la revisión al azar de las epicrisis sin código, la detección de los eventos adversos no registrados en la codificación hospitalaria mediante un *pipeline* de procesamiento de lenguaje natural y aprendizaje automático aplicado a las epicrisis de MIMIC-IV.

2.2 Objetivos específicos

Del objetivo general se derivan dos objetivos específicos (OE):

1) OE1. Superar, con el texto de la epicrisis, la capacidad discriminativa de las variables clínicas y administrativas de contexto en la detección de los eventos adversos.
2) OE2. Lograr que las epicrisis sin código que el modelo marca contengan eventos no registrados en mayor proporción que las que no marca.

Cada objetivo específico responde al problema específico del mismo número y se contrasta con la hipótesis específica del mismo número, cuyo criterio de decisión (ver sección 3.3.1) define si el objetivo se cumple o no.

Asimismo, cada objetivo se vincula con una etapa del estudio (ver Tabla 4) y con la evidencia que permitirá verificar si se cumplió:

1) OE1 (etapa 5). La diferencia global de ROC-AUC, frente a la etiqueta de la codificación, entre el modelo con texto y contexto y el modelo de contexto, con su IC 95 % por paciente y su estabilidad en cinco particiones adicionales.
2) OE2 (etapas 6 y 7). Las proporciones de epicrisis con evento en las detecciones (p1) y en los controles (p0), su diferencia con el IC 95 % de Newcombe y su razón. Como resultado descriptivo, p1 es el VPP de las detecciones, que se informa con su IC 95 % de Wilson, con el kappa intraevaluador y, si hay segunda lectura, con el interevaluador.

En cuanto al VPP, Melton y Hripcsak (2005) reportan 0.45, y Musy et al. (2018), una mediana de 40 % en los disparadores, con un rango de 0 % a 100 % entre estudios. Como ninguno se limita a las detecciones sin código, el VPP de las detecciones es un resultado descriptivo, sin hipótesis ni umbral de decisión.

Por otra parte, los eventos que se confirmen se llevan a la Matriz GEMSES (etapa 8) para estimar su nivel de gestión potencial. Dicha aplicación es exploratoria y no se formula como objetivo, dado que no tiene un criterio de decisión con el cual pueda no cumplirse.

CAPÍTULO III. MARCO TEÓRICO

3.1 Bases teóricas

3.1.1 Evento adverso, notificación y codificación

La Directiva N.° 7-OGCyH-ESSALUD-2020 define el evento adverso como una lesión o resultado indeseado, no intencional, en la salud del paciente, asociado directa o indirectamente con la atención de salud (EsSalud, 2020, num. 5.3). Según la misma directiva, puede deberse a errores o a la reacción imprevisible del organismo del paciente.

Dicha definición se adopta en la tesis, y el manual de anotación la operacionaliza con tres condiciones: un daño de gravedad E o mayor, un nexo C3 o C4 con la atención y el carácter no intencional. La gravedad se mide con las categorías del National Coordinating Council for Medication Error Reporting and Prevention (NCC MERP), donde E es el daño temporal que requirió intervención (Musy et al., 2018), y el nexo, con la escala del propio manual.

Ambos cortes son decisiones del estudio, no de la Directiva. El nexo se exige porque la mayoría de los 25 estudios revisados por Yasrebi-de Kom et al. (2023) usó etiquetas que solo describían un síntoma adverso, sin evaluar la causalidad.

En cuanto a la codificación, Stausberg y Hasford (2010) advierten que identificar los eventos adversos por medicamentos con códigos CIE-10 dará tanto falsos positivos como falsos negativos. Asimismo, Hohl et al. (2014) revisaron 41 estudios que usaron códigos CIE-10 con ese fin y encontraron que solo dos reportaron su sensibilidad. Por consiguiente, los códigos sirven como etiqueta de entrenamiento, pero no como medida de los eventos reales.

3.1.2 Procesamiento de lenguaje natural y aprendizaje automático

En la tesis, la epicrisis se representa con TF-IDF (frecuencia de término por frecuencia inversa de documento), que pondera cada término según su frecuencia en la nota y su rareza en el conjunto, en dos bloques, el de palabras (A) y el de bigramas (B). A ellos se suma un bloque de contexto (C), con 18 variables de la hospitalización y el largo de la nota, y todos se ajustan solo con los datos de entrenamiento.

Sobre esos atributos, una regresión logística entrega un puntaje de 0 a 1, que se usa con el corte de 0.5, fijado antes del sorteo de la revisión ciega. Con solo las palabras, alcanzó una ROC-AUC de 0.864, frente a 0.843 del modelo anterior de la tesis, una máquina de vectores de soporte lineal (LinearSVC) que no entrega probabilidades.

En la etapa previa se ajustaron tres *transformers* biomédicos en otra tarea, la naturaleza del evento, en una sola corrida y con ventanas de 256 o 1 024 *tokens*. Como tomaron de 2.9 a 42.5 horas en una GPU (unidad de procesamiento gráfico) de 4 GB, frente a 48 segundos del modelo léxico, por factibilidad se usa un modelo lineal sobre el texto completo.

Dado que ninguna epicrisis tiene una anotación clínica, el modelo se entrena con una etiqueta débil. Zhou (2018) describe la supervisión imprecisa (*inaccurate supervision*), una forma de supervisión débil cuyas etiquetas no siempre corresponden a la verdad.

Frénay y Verleysen (2014) advierten que el ruido de la etiqueta es un problema importante en clasificación. Con base en ambos trabajos, el modelo se entrena con la variante D2, sin epicrisis de etiqueta dudosa, y sus detecciones se validan a ciegas.

La variante D2 se sostiene en la definición de la etiqueta dudosa (ver Tabla 1), que es un criterio de codificación, y no en su PR-AUC (área bajo la curva de precisión y sensibilidad). Así, una positiva dudosa puede no ser un evento de la atención, y una negativa dudosa puede ser un evento que la tabla del proyecto no reconoce.

Adoptar D2 supone aceptar ese criterio, que el experimento no demuestra. En la etapa 4, en validación cruzada sin etiqueta dudosa, D2 alcanzó una PR-AUC de 0.8534, frente a 0.8431 de D0, entrenada con todos los datos, comparación que favorece a D2, entrenada sin esas epicrisis. En cambio, en la misma validación cruzada con todas las epicrisis y la etiqueta original, D2 obtiene 0.8477 frente a 0.8732, por lo cual su PR-AUC es un dato descriptivo.

3.1.3 Evaluación de la detección

La ROC-AUC se interpreta como la probabilidad de que un caso positivo elegido al azar obtenga un puntaje mayor que uno negativo (Hanley y McNeil, 1982), por lo cual se usa en la HE1 para comparar dos modelos. En cambio, con datos desbalanceados, la curva de precisión y sensibilidad ofrece una imagen más informativa del desempeño que la curva ROC (Saito y Rehmsmeier, 2015). Por ello, la PR-AUC es la métrica central del desarrollo, pues la tarea se centra en la clase positiva, con una prevalencia de 27.6 % en la etiqueta.

El VPP es la proporción de las epicrisis marcadas que tienen evento y, según su fórmula, $VPP = S \cdot \pi / [S \cdot \pi + (1 - E) \cdot (1 - \pi)]$, depende de la sensibilidad (S), la especificidad (E) y la prevalencia (π). Esa dependencia se observa en el VPP de Whitaker et al. (2022), que bajó de 84 % a 4.5 % al extrapolarlo a la incidencia de reacciones.

Por ello, el VPP frente a la etiqueta se calcula con su prevalencia, de 27.6 %, y el de las detecciones sin código, con la revisión ciega.

Por el enriquecimiento del corpus y los pesos balanceados, el puntaje del modelo no es una probabilidad calibrada, de modo que antes de su uso operativo se recalibrará con el ajuste a las nuevas probabilidades a priori de Saerens et al. (2002). Asimismo, su calibración frente a la etiqueta se evaluará según Van Calster et al. (2019) en la prueba, ponderada a la prevalencia de la etiqueta. En cambio, el riesgo de un evento no registrado se describirá por tramos del puntaje en las 241 epicrisis revisadas, con los pesos del diseño.

Para estimar una proporción binomial, Brown et al. (2001) recomiendan el intervalo de Wilson o el de Jeffreys con muestras pequeñas y el de Agresti y Coull con muestras mayores. Asimismo, para la diferencia entre dos proporciones independientes, Newcombe (1998) propone un intervalo que combina los de Wilson de ambas proporciones, que la HE2 usa sin corrección por continuidad, y por coherencia, el VPP se estima con el de Wilson.

3.1.4 Priorización de la gestión con la Matriz GEMSES

La Directiva define la Matriz de Priorización como una herramienta de priorización del modelo GEMSES que permite gestionar los riesgos de manera proactiva y reactiva, tomando en consideración los indicadores clave de riesgo o KRI (EsSalud, 2020, num. 5.13). Según el mismo numeral, la matriz utiliza el índice de frecuencia de los ERSP por proceso y el impacto para obtener el nivel de riesgo de los eventos y así definir el nivel de gestión según el índice de gestión. Por su parte, el modelo GEMSES se desarrolla en Pérez Pérez (2021).

Según el num. 19.11, el índice de frecuencia es la suma de los ERSP con el mismo identificador de evento en el proceso, dividida entre la suma de todos los ERSP del último semestre en el proceso. El impacto suma cuatro indicadores, cada uno valorado como nulo (0), bajo (1), medio (3), alto (6) o muy alto (9) y ponderado. Son la prolongación de la estancia hospitalaria (0.40), las complicaciones intrahospitalarias (0.20), los sobrecostos asociados a la no calidad (0.15) y la insatisfacción del paciente o la imagen institucional (0.25).

A su vez, el valor de riesgo es el producto del índice de frecuencia por el impacto, y el índice de gestión es el valor de riesgo de cada ERSP dividido entre la suma de los valores de riesgo. Con ese resultado, los ERSP se agrupan en tres niveles de gestión (num. 19.12). El nivel I (verde, percentil 25, bajo impacto) corresponde a los servicios; el nivel II (amarillo, percentil 50, mediano impacto), al servicio o al departamento, y el nivel III (rojo, percentil 75, alto impacto), al director de la IPRESS.

La Matriz GEMSES se aplica a los eventos que confirme la revisión ciega, aunque no se hayan notificado, y traduce la detección en un nivel de gestión potencial. Dicha aplicación es exploratoria, pues estima una prioridad y no valida la Matriz ni la efectividad de GEMSES.

Para aplicarla a MIMIC-IV, todas las epicrisis se asignan al proceso de Hospitalización (num. 19.6), dado que cada una resume una hospitalización, lo cual es una simplificación, pues un evento quirúrgico o de emergencia podría pertenecer a otro proceso. Por ello, el servicio al ingreso, como aproximación al servicio al cual pertenece el ERSP (num. 19.7), se informa

como atributo y como sensibilidad. Asimismo, MIMIC-IV desplaza las fechas de cada paciente (Johnson, Bulgarelli, et al., 2023), de modo que el semestre no puede reconstruirse y se usa todo el periodo, con los grupos de años de anclaje como sensibilidad.

En cuanto al impacto, solo dos indicadores pueden aproximarse en MIMIC-IV. Así, la prolongación de la estancia se estima con la diferencia entre los días de estancia y la mediana de su servicio al ingreso, y las complicaciones, con el traslado a la UCI después del ingreso. En cambio, los costos y la satisfacción no se imputan (ver limitación 10), de modo que el impacto es parcial, con el impacto impreso en el Anexo N.° 02 como sensibilidad.

El modelo GEMSES y la tesis comparten autoría (Pérez Pérez, 2021). Por ello, la regla del nivel, que el num. 19.12 no detalla, el proceso y el periodo se fijan en este plan, y los cortes del impacto se prerregistrarán antes de abrir los resultados de la revisión ciega.

Con base en los percentiles del num. 19.12, el nivel III corresponde a los grupos de eventos confirmados cuyo índice de gestión supera el percentil 75, el II a los que solo superan el percentil 50 y el I a los demás. Los percentiles, calculados por interpolación lineal, y la suma de los valores de riesgo abarcan todos los grupos del proceso, el percentil 25 no separa niveles y cada nivel se acompaña del número de casos sin ponderar.

3.2 Definición de términos

En la Tabla 1 se definen los términos del plan, a partir de la Directiva y del diseño de la tesis.

Tabla 1. Definición de términos

Término	Definición
Epicrisis	Nota de alta que resume la hospitalización; es el texto que lee el modelo.
Evento adverso	Lesión o resultado indeseado, no intencional, en la salud del paciente, asociado directa o indirectamente con la atención de salud (EsSalud, 2020, num. 5.3).
ERSP	Evento relacionado con la seguridad del paciente; incluye el evento adverso, el evento centinela y el incidente (EsSalud, 2020, num. 5.1).
Evento adverso no registrado	Evento confirmado en la revisión ciega en una hospitalización sin ningún código de evento adverso.
Etiqueta débil	Etiqueta construida con los códigos de diagnóstico, sin lectura clínica: vale 1 si la hospitalización tiene un código de causa explícita y 0 si no lo tiene.
Etiqueta dudosa	Negativa con un código de causa fuera de la tabla del proyecto, o positiva solo por una caída sin el hospital como lugar o por una úlcera CIE-9 sin código de presión.
Variante D2	Datos de entrenamiento sin las negativas ni las positivas de etiqueta dudosa.
Pipeline	Flujo reproducible de pasos que convierte la epicrisis en un puntaje de evento de 0 a 1.
Detección y control	Detección es la epicrisis sin código con puntaje de 0.5 o más; control, la epicrisis sin código que el modelo no marca, sorteada para la HE2.
Revisión ciega	Lectura de las epicrisis sin saber cuáles marcó el modelo, con el manual de anotación.
Manual de anotación (*codebook* v2)	Reglas de la revisión, que exigen el carácter no intencional y, como decisiones del estudio, un daño de gravedad E o mayor en la escala NCC MERP y un nexo C3 o C4 con la atención.

Término	Definición
Kappa intraevaluador	Concordancia más allá del azar entre la revisión y la re-revisión ciega de 30 epicrisis por el mismo evaluador.
Kappa interevaluador	Concordancia más allá del azar entre las lecturas ciegas del investigador y de un segundo evaluador clínico, en 100 epicrisis.
Prevalencia de la etiqueta	Proporción de las hospitalizaciones con epicrisis y diagnóstico que tienen código de evento adverso: 27.6 %.
Anexo N.° 02	Tabla de codificación de los ERSP, con 231 eventos en 12 naturalezas y sus impactos.
Equivalencia validada	Contraste de los códigos CIE-10 de la etiqueta con los eventos del Anexo N.° 02, validado código por código el 29 de octubre de 2026.

Fuente: elaboración propia a partir de la Directiva y del diseño de la tesis.

3.3 Hipótesis y variables

3.3.1 Hipótesis

La hipótesis general (HG) sostiene que el *pipeline* mejora la detección de los eventos adversos no registrados en la codificación hospitalaria, lo cual se considera cumplido si se cumplen a la vez dos condiciones:

1) El contenido textual de la epicrisis aporta capacidad discriminativa incremental respecto de las variables de contexto (HE1).
2) La proporción de epicrisis con evento entre las epicrisis sin código que el modelo marca es mayor que entre las que no marca (HE2).

La HE1 es condición de la HG porque, sin el aporte del texto, bastaría un modelo sin PLN, y la HE2 verifica la marca del modelo frente a los eventos no registrados.

Como se aprecia en la Tabla 2, cada hipótesis específica tiene un criterio de decisión, y en ambas, exigir que el límite inferior del IC 95 % supere cero corresponde aproximadamente a una prueba unilateral con un nivel de significancia de 0.025. El criterio de la HE2 se fijó en la matriz de consistencia del 2 de noviembre de 2026, antes de abrir los resultados de la revisión ciega. En cambio, la HE1 no es ciega respecto de su dirección (ver limitación 12), por lo cual la decisión confirmatoria de la HG recae en la HE2.

Tabla 2. Hipótesis específicas y criterios de decisión

Hipótesis específica	Criterio de decisión
HE1. La incorporación del contenido textual de la epicrisis aporta capacidad discriminativa incremental para identificar hospitalizaciones asociadas con eventos adversos, respecto de un modelo basado exclusivamente en las características clínicas y administrativas de contexto. Se contrasta frente a la etiqueta de la codificación, en las 12 321 epicrisis de prueba sin etiqueta dudosa, entre el modelo adoptado (A+B+C, variante D2) y el modelo de contexto (bloque C, que incluye el largo de la nota, entrenado con las mismas filas).	La diferencia global de ROC-AUC en la prueba es de al menos 0.05, y el límite inferior de su IC 95 % por paciente es mayor que cero en la prueba y en cada una de cinco particiones más. Los estratos, la configuración candidata y la etiqueta original se informan como sensibilidad.
HE2. La proporción de epicrisis con al menos un evento adverso confirmado en la revisión ciega es mayor entre las detecciones sin código que entre las epicrisis sin código que el modelo no marca.	En las 151 detecciones y los 90 controles sorteados, el límite inferior del IC 95 % de Newcombe de la diferencia es mayor que cero.

Fuente: elaboración propia a partir de la matriz de consistencia (ver Anexo A).

3.3.2 Variables

En la Tabla 3 se presentan las variables con su definición operacional y sus indicadores. La variable independiente (VI) es el *pipeline* de detección frente a sus comparadores. Por su parte, la variable dependiente (VD) tiene dos dimensiones, dado que la etiqueta de los códigos permite medir la discriminación en todo el corpus, mientras que la presencia del evento solo se confirma en las epicrisis que se revisan a ciegas.

En cuanto a la escala de medición, la VI es nominal, las variables intervinientes son nominales u ordinales, los indicadores de la VD son continuos y el nivel de gestión es ordinal.

Tabla 3. Variables, dimensiones e indicadores

Variable	Dimensión o definición operacional	Indicador	Hipótesis
VI: *pipeline* de detección frente a sus comparadores	Dimensiones: método de detección, con el modelo adoptado (A+B+C, D2), el modelo de contexto (bloque C) o la revisión al azar de las epicrisis sin código, y marca del modelo	Configuración del modelo (A+B+C o solo C); detección (puntaje de 0.5 o más) o no detección	HG, HE1 y HE2
VD: detección de los eventos adversos	Dimensión 1: discriminación frente a la etiqueta débil de la codificación	Diferencia global de ROC-AUC con IC 95 % por paciente, también en cinco particiones más; estratos como sensibilidad	HE1
VD: detección de los eventos adversos	Dimensión 2: epicrisis con eventos adversos no registrados confirmados en la revisión ciega	Proporción con evento en detecciones (p1) y controles (p0), su diferencia (IC de Newcombe) y su razón; VPP (IC de Wilson), descriptivo	HE2

Variable	Dimensión o definición operacional	Indicador	Hipótesis
Variables intervinientes	Tipo de paciente y largo de la nota, controlados por estratificación	Servicio al ingreso; grupo de edad (18 a 44, 45 a 64, 65 a 79 y 80 o más años); decil de largo de la nota	HE1 (sensibilidad)
Variable descriptiva	Nivel de gestión GEMSES potencial de los grupos de eventos confirmados	Frecuencia ponderada, impacto parcial y nivel verde, amarillo o rojo de cada grupo	Ninguna

Fuente: elaboración propia a partir de la matriz de consistencia (ver Anexo A).

CAPÍTULO IV. METODOLOGÍA

4.1 Tipo de investigación

La investigación es aplicada, porque emplea métodos de PLN y aprendizaje automático en un problema de gestión, y cuantitativa, porque contrasta hipótesis con criterios numéricos.

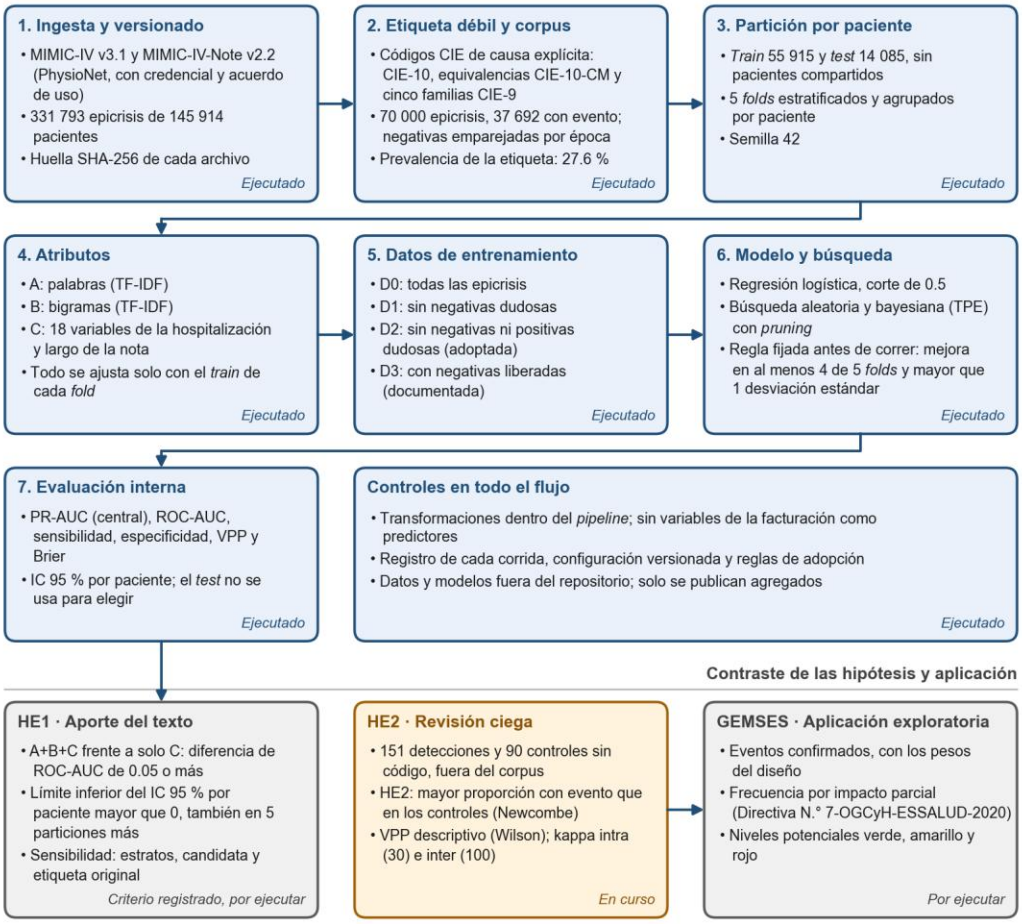
4.2 Nivel de investigación

El nivel es correlacional en la HE1 y la HE2, que relacionan la información del modelo con su discriminación, y su marca con la presencia del evento. Asimismo, es descriptivo en el VPP y en la aplicación de la Matriz GEMSES, que estiman una proporción y ordenan grupos.

4.3 Métodos de trabajo

Se sigue el método hipotético-deductivo, dado que las hipótesis y sus criterios de decisión se registran antes de su cálculo y luego se contrastan con los datos. Asimismo, como se aprecia en la Figura 1, el trabajo se organiza en un flujo de procesamiento reproducible, desde la ingesta de los datos hasta la priorización, cuyos siete primeros pasos ya se ejecutaron.

Figura 1. Flujo de procesamiento y estado de cada paso a noviembre de 2026



Fuente: elaboración propia.

4.4 Población y muestra

La unidad de análisis es la epicrisis, una por hospitalización, y la población comprende las 331 793 epicrisis de 145 914 pacientes del archivo descargado de MIMIC-IV-Note v2.2, una unidad menos en cada caso que en PhysioNet (Johnson, Pollard, et al., 2023).

Para el desarrollo del modelo y la HE1 se construyó un corpus de 70 000 epicrisis de 48 669 pacientes, limitado por la memoria de acceso aleatorio (RAM) del equipo, de 15.6 GB. Este incluye 37 692 epicrisis con evento (53.8 %) y negativas sorteadas y emparejadas por época de codificación. El corpus se separó por paciente en 55 915 epicrisis de entrenamiento y 14 085 de prueba, y la HE1 se evalúa en las 12 321 de prueba sin etiqueta dudosa.

Para la HE2 y el VPP, la población está formada por las 98 931 epicrisis de MIMIC-IV de pacientes que no figuran en el corpus, es decir, que no participaron en el desarrollo del modelo, aunque proceden del mismo hospital. Ninguna de ellas tiene filas en las tablas de la etiqueta ni códigos de las familias de causa explícita o de efecto adverso de medicamento. El

modelo adoptado, reentrenado con las 61 319 epicrisis que la variante D2 conserva en todo el corpus, marcó 15 731 de las 98 931 como detecciones y dejó 83 200 sin marcar.

Mediante un muestreo estratificado no proporcional, de cada grupo se sortearon al azar 151 detecciones y 90 controles, es decir, 241 epicrisis, cuyo tamaño se fijó antes de iniciar la revisión ciega. La muestra de las detecciones se calculó para estimar el VPP con la fórmula de una proporción, $n = z^2 \cdot p \cdot (1 - p) / e^2$. Con $z = 1.96$ (95 % de confianza), una proporción supuesta (p) de 0.5 y un margen de error (e) de 0.08, resultan 151.

Según un cálculo binomial exacto, con un VPP supuesto de 0.35, menor que los de la sección 2.2, la potencia de la HE2 sería de 0.94 con una proporción supuesta de 0.15 en los controles, y de 0.71 con una de 0.20. Con la de 0.15, bajaría a 0.77 con un VPP de 0.30, y a 0.45 con uno de 0.25. Por ello, con el tamaño ya fijado, un VPP de 0.35 y una potencia de 0.80, la diferencia mínima detectable es de 0.164 (ver limitación 11).

Asimismo, 100 de las 241 (63 detecciones y 37 controles, en la proporción de la muestra) tendrán una segunda lectura ciega. Con un kappa supuesto de 0.70 y una prevalencia de 0.28 a 0.29, la de los supuestos de la HE2, la semiamplitud de su IC 95 % sería de 0.16 (Cohen, 1960).

4.5 Tipo de diseño

Según el mapa de diseños que la guía toma de Hernández Sampieri (Universidad Nacional de Ingeniería [UNI], 2023, p. 30), el diseño es no experimental y transversal, dado que no se interviene en los pacientes y los datos se recolectan una sola vez. Asimismo, es retrospectivo, pues los registros ya existen.

4.6 Técnicas e instrumentos de recolección de datos

La técnica es el análisis documental de MIMIC-IV, con cuatro instrumentos:

1) *Pipeline* reproducible en Python, que extrae las epicrisis y las variables de MIMIC-IV y construye el corpus, la etiqueta y los atributos.
2) Etiqueta débil, construida con los códigos CIE de causa explícita de cada hospitalización, que en la época CIE-10 comprenden los de la tabla del proyecto y sus equivalencias CIE-10-CM (modificación clínica), y en la época CIE-9, cinco familias completas de códigos. Sus códigos CIE-10 se contrastaron con los eventos del Anexo N.° 02 mediante una equivalencia validada código por código.

3) Ficha de revisión ciega, en una aplicación propia con un usuario por evaluador, con el manual de anotación (*codebook* v2), en la cual el evaluador registra si la epicrisis tiene al menos un evento adverso y cuál, sin saber si el modelo la marcó. La aplicación presenta las epicrisis en orden aleatorio y sin la opción de no evaluable. Su confiabilidad se mide con el kappa de Cohen intraevaluador, en 30 epicrisis revisadas de nuevo a ciegas al menos dos semanas después, y, si hay segunda lectura, con el kappa interevaluador y los acuerdos positivo y negativo en las 100 previstas para ella. En estas, las discrepancias se discutirán sin conocer la marca del modelo y, si no hay acuerdo, prevalecerá la lectura del segundo evaluador.
4) Matriz GEMSES de la Directiva (num. 19.10 a 19.12 y Anexos N.° 02 y 03).

En cuanto a los aspectos éticos, el 28 de abril de 2026 se solicitó la credencial de PhysioNet. En la misma fecha, se aprobaron dos cursos de ética del programa CITI (Collaborative Institutional Training Initiative), “Data or Specimens Only Research” y el curso básico de ética en investigación de EsSalud, vigente hasta abril de 2029. Asimismo, se firmó el acuerdo de uso, *PhysioNet Credentialed Health Data Use Agreement* 1.5.0, y el 10 y el 11 de mayo de 2026 se firmó el de MIMIC-IV-Note y se descargaron sus archivos. El segundo evaluador obtendrá su propia credencial y firmará a su nombre ese acuerdo antes de leer cualquier epicrisis, dado que el acceso no puede compartirse (PhysioNet, s. f., cláusula 3).

Según PhysioNet, el comité de ética del Beth Israel Deaconess Medical Center otorgó la exención del consentimiento informado (Johnson et al., 2024). Las epicrisis se desidentificaron según la disposición de puerto seguro (*Safe Harbor*) de la ley estadounidense HIPAA (*Health Insurance Portability and Accountability Act*) (Johnson, Pollard, et al., 2023).

Para cumplir el acuerdo, los datos no se redistribuyen, y ni el texto clínico ni los modelos entrenados se publican (ver limitación 7). Asimismo, la aplicación de la revisión ciega solo admite evaluadores con credencial, y en las exposiciones se usa una epicrisis inventada.

4.7 Técnicas e instrumentos de análisis y procesamiento de datos

El procesamiento se hace en Python 3.13, con scikit-learn (Pedregosa et al., 2011) para el *pipeline* y Optuna 5.0.0 para los hiperparámetros (Akiba et al., 2019), con la semilla 42 y la configuración versionada. El modelo adoptado es una regresión logística con pesos balanceados y C de 1 sobre A, B y C (20 000 palabras y 20 000 bigramas), con la variante D2.

Las decisiones de modelado usan validación cruzada con 5 *folds* estratificados por la etiqueta y agrupados por paciente. La prueba, una evaluación interna, se midió en el análisis exploratorio y tras cada experimento, con un IC 95 % de 200 remuestreos de pacientes.

En la HE1 se calcula la ROC-AUC global del modelo adoptado y la del modelo de contexto, y su diferencia se acompaña del IC 95 % de percentiles, con 2 000 remuestreos de pacientes, los mismos para ambos modelos. Como sensibilidad, se calcula con todas las epicrisis y la etiqueta original, y en cada estrato con 200 epicrisis o más y al menos 30 de cada clase, contadas en el conjunto de prueba de cada análisis, igual que los deciles de largo.

Asimismo, ambos modelos se reentrenan en cinco particiones por paciente adicionales, con las semillas 43 a 47, y en cada una el límite inferior del IC debe ser mayor que cero. Además, como sensibilidad, la HE1 se repite con la configuración candidata bayesiana, de C de 1.87, 60 000 palabras y 40 000 bigramas, sin pesos, y un modelo de contexto de igual regularización. La regla de adopción prerregistrada la eligió después del sorteo del lote de la revisión ciega, que usó la de C de 1, con la cual se contrastan la HE1 y la HE2.

El criterio de la HE1, estas definiciones y la hipótesis general se registraron el 12 de noviembre de 2026 (*commit* ad116a5), antes del cálculo, como enmienda del prerregistro del 5 de noviembre (*commit* fda6828). Dicha enmienda pasó a sensibilidad el criterio por estrato del prerregistro, y como la ROC-AUC de 0.8706 ya se conocía, la condición de 0.05 solo falla si la del modelo de contexto supera 0.8206. Los umbrales de 0.05 y de 0.10 no proceden de una fuente, por lo cual se informan los intervalos completos.

En la HE2 se comparan la proporción de las 151 detecciones con al menos un evento confirmado (p1) y la de los 90 controles (p0). Para ello, se calculan su diferencia, con el IC 95 % de Newcombe, y su razón, cuyo IC se obtiene en escala logarítmica. Como resultado descriptivo del OE2, p1 es el VPP de las detecciones, que se informa con su IC 95 % de Wilson, por época de codificación (CIE-9 o CIE-10) y por número de eventos por epicrisis.

Como análisis secundario, para separar el aporte del texto, la comparación se ajusta por el puntaje del modelo de contexto, mediante una regresión logística del evento sobre el grupo y ese puntaje. Asimismo, si hay segunda lectura, la HE2 y el VPP se recalcularán en las 100 previstas con la del segundo evaluador, y si un paciente aporta más de una epicrisis a la muestra, los intervalos se recalculan con remuestreo por paciente. Por otra parte, la revisión ciega empezó antes del 5 de noviembre de 2026 con el *codebook* v2, que no ha cambiado, y sus resultados se abren al terminar, para no sesgar la lectura de los casos que faltan.

Con las mismas proporciones se estiman, como datos descriptivos, las epicrisis con evento no registrado entre las 98 931 sin código, 15 731·p1 + 83 200·p0, con su IC 95 % por el método delta. Asimismo, se estiman la fracción que el modelo detecta, 15 731·p1 / (15 731·p1 + 83 200·p0), y la razón frente a la revisión al azar, p1 / p, donde p = (15 731·p1 + 83 200·p0) / 98 931. Dado que p1 − p = (83 200 / 98 931)·(p1 − p0), la HE2 equivale a superar la revisión al azar del objetivo general. Como medida de viabilidad, se deriva cuántas epicrisis deben leerse por cada una con evento, 1 / p1 con el modelo y 1 / p al azar.

En la aplicación de la Matriz GEMSES se calculan, para cada grupo de eventos, el índice de frecuencia, el impacto, el valor de riesgo, el índice de gestión y el nivel, con las ponderaciones, las adaptaciones y la regla de la sección 3.1.4. Dado que la muestra no es aleatoria simple, cada caso se pondera por el inverso de su fracción de muestreo, 15 731/151 en las detecciones y 83 200/90 en los controles (Cochran, 1977). Por consiguiente, el índice de frecuencia de un evento es la suma de los pesos de sus casos confirmados, dividida entre la de todos los eventos confirmados en el proceso de Hospitalización.

4.8 Etapas de intervención del estudio

En la Tabla 4 se presentan las etapas del estudio, su producto y su estado al mes de noviembre de 2026. Al cierre de la etapa 4, en la evaluación interna, el modelo adoptado alcanzó, frente a la etiqueta débil, una PR-AUC de 0.8671 (IC 95 %: 0.8589 a 0.8749) y una ROC-AUC de 0.8706 en las 12 321 epicrisis de prueba sin etiqueta dudosa.

Tabla 4. Etapas de intervención del estudio

Etapa	Actividades	Producto	Estado
1. Acceso y ética	Cursos CITI, credencial y acuerdos de PhysioNet	Acceso a datos	Ejecutada
2. Corpus y etiqueta	Corpus, etiqueta débil, partición por paciente y experimentos iniciales	Corpus y modelo de referencia	Ejecutada
3. *Pipeline* y análisis exploratorio	*Pipeline* reproducible y análisis exploratorio de los datos	Variantes de los datos y HE1 formulada	Ejecutada
4. Experimentos	Atributos y datos; solo los hiperparámetros con reglas de adopción prerregistradas	Modelo adoptado (A+B+C, D2)	Ejecutada
5. Contraste de la HE1	Cálculo global, en cinco particiones adicionales y por estrato	Resultado de la HE1	Por ejecutar
6. Revisión ciega	Revisión de 241 epicrisis, re-revisión de 30 y segunda lectura de 100	Datos de la HE2 y del VPP; kappa	En curso
7. Contraste de la HE2 y la HG	Cálculo de los intervalos, del VPP y de las estimaciones descriptivas	Resultado de la HE2 y de la HG	Por ejecutar

Etapa	Actividades	Producto	Estado
8. Aplicación GEMSES	Índices y niveles exploratorios de la Matriz, con los pesos del diseño	Niveles de gestión potenciales	Por ejecutar
9. Informe final	Redacción, revisión del jurado y sustentación	Tesis	Por ejecutar

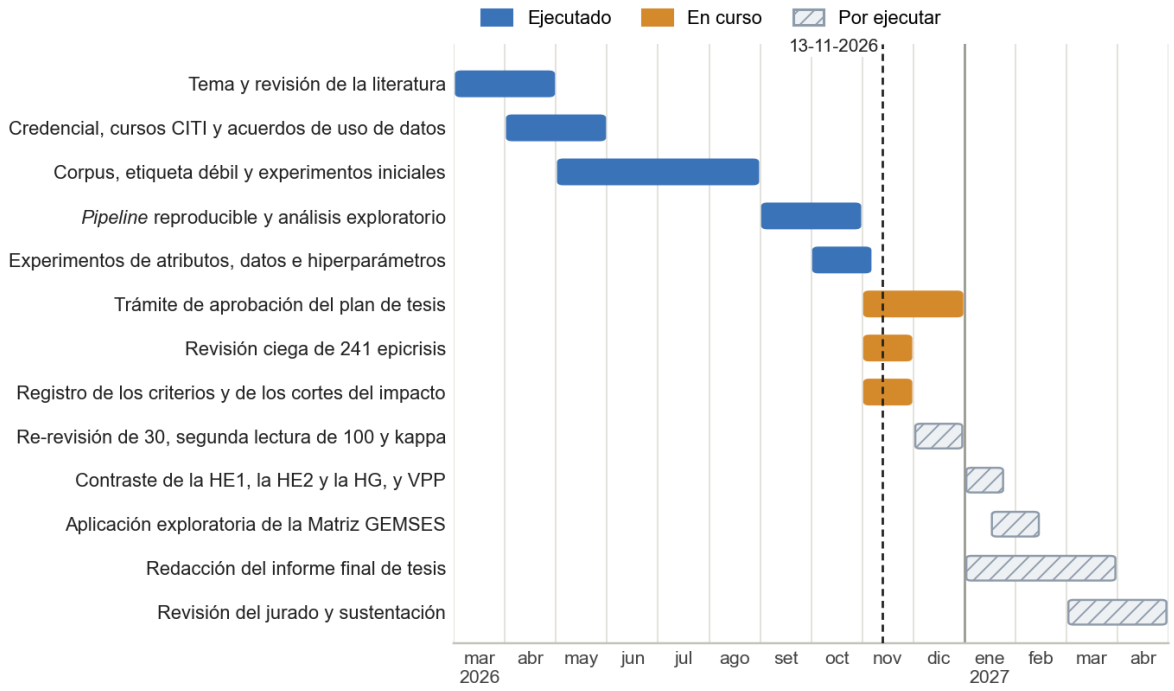
Fuente: elaboración propia.

CAPÍTULO V. ADMINISTRACIÓN DEL PLAN DE TESIS

5.1 Cronograma

En la Figura 2 se presenta el cronograma de la tesis, de marzo de 2026 a abril de 2027, con el estado de cada actividad a noviembre de 2026. Las actividades ejecutadas corresponden a los cursos de investigación de la maestría, mientras que las que faltan se concentran entre noviembre de 2026 y abril de 2027. Asimismo, el Anexo B detalla cada actividad con su periodo, su producto verificable y su estado. Asimismo, la segunda lectura depende de la credencial del segundo evaluador, con los plazos de la limitación 2.

Figura 2. Cronograma de la tesis



Fuente: elaboración propia. La línea discontinua marca el 13 de noviembre de 2026, fecha de corte del estado de las actividades, y las fechas de las actividades por ejecutar son estimadas.

5.2 Presupuesto

Como se aprecia en la Tabla 5, el presupuesto se organiza en los cuatro rubros de la guía de la Escuela de Posgrado y asciende a S/ 7 212.87. El rubro de mayor monto es el de

servicios, debido a los derechos universitarios de las fases I y II, que suman S/ 3 909.40, es decir, el 54.2 % del total.

Tabla 5. Presupuesto de la tesis (en soles)

Rubro y concepto	Cantidad	Costo unitario	Total
a) Equipos y bienes duraderos			0.00
Computadora personal con GPU de 4 GB (equipo propio ya existente)	1	0.00	0.00
b) Materiales, instrumentos e insumos			700.00
Útiles de escritorio e impresiones de trabajo	1	150.00	150.00
Bibliografía sin acceso abierto	1	200.00	200.00
Impresión y empastado de cinco ejemplares, cuatro CD y cuatro fotografías (fase II)	1	350.00	350.00
c) Servicios tecnológicos, análisis estadístico y recolección de datos			5 169.40
Internet, proporción de uso (meses)	14	60.00	840.00
Energía eléctrica, proporción de uso (meses)	14	30.00	420.00
Software de código abierto y acceso a PhysioNet	1	0.00	0.00
Segundo evaluador clínico (participación *ad honorem*)	1	0.00	0.00
Derechos de la fase I: carpeta y aprobación del tema de tesis	1	100.00	100.00
Derechos de la fase II: grado de maestría y constancia de no adeudos	1	3 809.40	3 809.40
d) Pasajes, viáticos, eventos y publicación			1 000.00
Traducción y corrección de estilo de un artículo derivado de la tesis	1	1 000.00	1 000.00
Subtotal			6 869.40
Imprevistos (5 %)			343.47
Total			7 212.87

Fuente: elaboración propia. Los derechos universitarios proceden de la Cartilla de información para obtener el grado académico de maestro (FIIS-UPGM-OD-001): carpeta, S/ 70.00; aprobación del tema de tesis, S/ 30.00; grado de maestría, S/ 3 743.40, y constancia de no adeudos, S/ 66.00. Los demás montos son estimados. Asimismo, los derechos se incluyen en el rubro c), dado que la guía no les asigna un rubro.

5.3 Financiamiento

La tesis es autofinanciada, es decir, se cubre con recursos propios. Es preciso tomar en consideración que el acceso a MIMIC-IV y el *software* son gratuitos y que el equipo de cómputo ya existe, por lo cual el gasto se concentra en los derechos universitarios y en los materiales de la fase de grado.

PARTE II. PROTOCOLO DE INVESTIGACIÓN Y AVANCE EXPERIMENTAL

La Parte II presenta el protocolo experimental con el que se desarrolló el modelo y el avance obtenido en los cursos de investigación de la maestría. Es preciso tomar en consideración que el desarrollo mide la concordancia del modelo con la etiqueta de los códigos, al igual que la HE1, que se contrasta en *test* frente a esa etiqueta. En cambio, según el contraste descrito en el Capítulo IV, la HE2 y el VPP de las detecciones dependen de la revisión ciega, y la HG, de las dos hipótesis específicas.

6. Datos y material de estudio

6.1 Origen, condiciones de uso y trazabilidad

Los datos provienen de MIMIC-IV v3.1 (Johnson et al., 2024) y de MIMIC-IV-Note v2.2 (Johnson, Pollard, et al., 2023), publicados en PhysioNet con acceso por credencial, bajo la licencia *PhysioNet Credentialed Health Data License* 1.5.0. El periodo, la población y las limitaciones de los datos se exponen en la sección 1.2.2, mientras que la credencial, los cursos de ética y los acuerdos de uso se describen en la sección 4.6.

Al firmar el acuerdo de uso de datos (DUA, *Data Use Agreement*), el usuario se compromete a no compartir con nadie más el acceso a los datos restringidos (PhysioNet, s. f., cláusula 3). Asimismo, se compromete a que, si difunde abiertamente sus resultados, aportará el código que los produjo a un repositorio abierto a la comunidad de investigación (cláusula 9). Por ello, el repositorio del curso es público y contiene el código, la configuración y resultados agregados, mientras que los datos de MIMIC-IV y los modelos entrenados permanecen fuera del control de versiones.

En cuanto a la trazabilidad, la ingesta verifica sus fuentes y registra en una bitácora versionada la fecha, el tamaño y la huella SHA-256 (*Secure Hash Algorithm* de 256 bits) de cada una. Como se aprecia en la Tabla 6, el registro del 2 de octubre de 2026 comprende seis fuentes, entre ellas las epicrisis y los diagnósticos, cuyos archivos tienen fecha del 11 y del 14 de mayo de 2026.

Tabla 6. Archivos de entrada registrados en la bitácora de datos

Fuente	Rol	Fecha del archivo	Tamaño (bytes)	Huella SHA-256 (primeros 12 caracteres)
Epicrisis (*discharge*, MIMIC-IV-Note v2.2)	Dato externo bajo el DUA	11-05-2026	1 139 203 149	27bc552edaf8
Diagnósticos (*diagnoses_icd*, MIMIC-IV v3.1)	Dato externo bajo el DUA	14-05-2026	33 564 802	47665a41b2a3

Fuente	Rol	Fecha del archivo	Tamaño (bytes)	Huella SHA-256 (primeros 12 caracteres)
Primera tabla de la etiqueta	Etiqueta copiada al proyecto	26-07-2026	10 763 103	778b9d3993c9
Segunda tabla de la etiqueta	Etiqueta copiada al proyecto	29-07-2026	3 070 012	1f130393a004
Tercera tabla de la etiqueta	Etiqueta copiada al proyecto	29-07-2026	4 034 353	4d481fbb48da
Época de codificación	Derivado de la ingesta	30-09-2026	2 572 188	a8b53ea73a98

Fuente: elaboración propia a partir de la bitácora de datos del repositorio del curso, registrada el 2 de octubre de 2026.

Es preciso tomar en consideración que las demás tablas de MIMIC-IV que usa el bloque de contexto no figuran en la bitácora. De ellas, *admissions*, *patients*, *icustays* y *services* tienen su tamaño y su huella SHA-256 en el resumen del análisis exploratorio, mientras que *transfers*, *prescriptions* y *microbiologyevents* todavía no tienen su huella registrada. Por consiguiente, el registro de todas ellas en la bitácora, con su huella SHA-256, se incluye en el trabajo futuro de la sección 9.3.

6.2 Estructura, diccionario de datos y análisis exploratorio

Como se aprecia en la Tabla 7, el texto procede del módulo de notas, mientras que la etiqueta y las variables de contexto proceden de los módulos de hospitalización y de cuidados intensivos. Cada epicrisis se une con sus tablas por el identificador de la hospitalización, y la unidad de análisis es la epicrisis, una por hospitalización.

Tabla 7. Fuentes, tamaño y uso de los datos

Fuente y tabla	Registros	Uso en el proyecto
MIMIC-IV-Note v2.2: epicrisis (*discharge*)	331 793 epicrisis de 145 914 pacientes	Texto de los bloques A y B, y largo de la nota
MIMIC-IV v3.1: diagnósticos (*diagnoses_icd*)	545 497 hospitalizaciones con diagnóstico	Etiqueta débil y época de codificación
MIMIC-IV v3.1: *admissions*, *patients*, *services*, *transfers*, *icustays*, *prescriptions* y *microbiologyevents*	Las hospitalizaciones del corpus	18 variables de contexto del bloque C
Corpus de modelado	70 000 epicrisis de 48 669 pacientes, 37 692 con evento (53.8 %)	*Train*: 55 915; *test*: 14 085, sin pacientes compartidos

Fuente: elaboración propia a partir de la documentación del repositorio del curso (secciones de datos y de análisis exploratorio).

El corpus se limitó a 70 000 epicrisis por la memoria del equipo, y en él el 53.8 % de las epicrisis tiene evento. Esa proporción no es la de la base, en la que tiene código de evento el 27.59 % de las 331 604 hospitalizaciones con epicrisis y diagnóstico, y el 20.12 % de las

545 497 con diagnóstico. Por consiguiente, el VPP frente a la etiqueta se calcula siempre con la prevalencia de la etiqueta en la base (ver Tabla 1 y sección 3.1.3).

En cuanto a las variables, el modelo usa el texto de la epicrisis, con una mediana de 9 932 caracteres y 1 515 palabras, y 18 variables de contexto agrupadas en paciente, servicio, hospitalización y atención, además del largo de la nota (ver Anexo C). Entre ellas, las horas en emergencia faltan en el 33.2 % del corpus, con un faltante que no es aleatorio, el destino al alta falta en el 12.5 % y los conteos de medicamentos y de cultivos tienen cola larga.

Por otra parte, el análisis exploratorio de datos (EDA) dejó cuatro hallazgos que condicionaron el diseño experimental (ver Figuras E1 y E2 del Anexo E). En primer lugar, la etiqueta tiene ruido, dado que 6 296 positivas lo son solo por una caída y apenas 159 tienen el hospital como lugar de ocurrencia. Además, 1 739 de las 2 736 positivas de úlcera en CIE-9 no tienen código de úlcera por presión, y 805 de las 9 345 negativas CIE-10 tienen un código de evento fuera de la tabla.

En segundo lugar, el tipo de paciente anticipa parte de la etiqueta, ya que sin leer la nota se alcanza una ROC-AUC de 0.693 con datos del ingreso y de 0.760 con datos del alta, frente a 0.864 al leer la epicrisis. En tercer lugar, el largo de la nota por sí solo da una ROC-AUC de 0.606, y la proporción de positivas sube de 44.0 % en el decil más corto a 76.5 % en el más largo.

En cuarto lugar, de los 231 eventos del Anexo N.° 02 de la Directiva, 128 tienen código CIE-10 en las tablas, 78 se observan en MIMIC-IV y solo 22 llegan a las positivas del corpus. Por ello, la frecuencia de cada evento no alcanza para entrenar un clasificador por evento, y en el diseño de la tesis el modelo solo detecta si hubo evento, mientras que la revisión ciega identifica cuál (ver sección 4.6).

De esta manera, el primer hallazgo dio origen a las variantes de los datos, el segundo y el tercero a la HE1, y el cuarto, a descartar un clasificador por evento. Los sesgos que se derivan de ellos se discuten en la sección 8.5.

6.3 Ética, privacidad y seguridad

La exención del consentimiento informado y la desidentificación de las epicrisis conforme a la disposición de puerto seguro de la ley HIPAA se exponen en la sección 4.6. Al respecto, en las epicrisis cada dato de salud protegido se reemplazó por tres guiones bajos, y una revisión manual no halló datos de salud protegidos (Johnson, Pollard, et al., 2023).

Los datos se usan bajo el DUA de PhysioNet, y para cumplir ese acuerdo y reforzar la privacidad se adoptaron seis controles de acceso y de difusión:

1) El acceso a los datos es personal, con la credencial de PhysioNet, y las rutas locales de los archivos se declaran en un archivo de entorno que no se versiona.
2) Los datos no se redistribuyen ni se publica texto clínico, y el control de versiones excluye los archivos de datos.
3) Cuando se muestran términos del modelo, pasan antes un filtro de privacidad. Dicho filtro exige solo letras, al menos 100 pacientes y el 1 % de las epicrisis de *train*, y ninguna palabra con mayúscula inicial en más del 50 % de sus apariciones.
4) Los modelos entrenados no se publican, por lo expuesto en la limitación 7 de la sección 1.2.2.
5) La revisión ciega se hace en una aplicación propia, con un usuario por evaluador, que solo admite evaluadores con credencial de PhysioNet y presenta las epicrisis en orden aleatorio, sin agrupar detecciones y controles.
6) En las exposiciones se usa una epicrisis inventada y no una real.

6.4 Preprocesamiento y control de fuga de información

El preprocesamiento sigue cinco pasos, todos con registro de conteos en cada corrida:

1) Etiqueta. Vale 1 si la hospitalización tiene un código de causa explícita de evento adverso, que en la época CIE-10 son los de ese tipo en la tabla del proyecto y sus equivalencias CIE-10-CM, y en la época CIE-9, cinco familias completas de códigos. Los códigos de condiciones como la neumonía o la sepsis no dan etiqueta, porque la tabla de diagnósticos de MIMIC-IV no indica si la condición ya estaba presente al ingreso.
2) Negativas. Se sortean entre las hospitalizaciones sin ningún código de la tabla, emparejadas por época de codificación con las positivas.
3) Texto. Se conservan las epicrisis de más de 100 caracteres. El corpus no tiene nulos ni duplicados, y las 1 933 notas atípicas por largo (2.8 %) se conservan porque son notas reales.
4) Partición. Se separa por paciente, con el 20 % para *test* y semilla 42, y se verifica con una aserción que ningún paciente quede en dos partes. La corrida final registró 0 pacientes compartidos, con 53.89 % de positivas en *train* y 53.65 % en *test*.

5) Transformaciones. Toda imputación, escalado, codificación y vectorización se ajusta dentro del *pipeline*, solo con las filas de entrenamiento de cada *fold*.

En cuanto a la fuga de información, las operaciones que aprenden de los datos se ajustan exclusivamente con las filas de entrenamiento de cada *fold*. Dichas operaciones son la mediana de la imputación, el escalado, los percentiles 1 y 99 del recorte, las categorías del *one-hot*, con la agrupación de las de menos de 50 casos, y el vocabulario y los pesos del TF-IDF. Por consiguiente, a las filas de validación y de *test* solo se les aplican esos parámetros ya aprendidos, mientras que las operaciones que no aprenden de los datos, como las minúsculas, la supresión de tildes y el log1p, se aplican igual a todas las filas.

Asimismo, la depuración de la etiqueta de las variantes D1 a D3 (ver Tabla 9) solo cambia las filas de entrenamiento, y la validación y el *test* conservan la etiqueta original. Además, se excluyeron como predictores el número de diagnósticos, la severidad según los APR-DRG (*All Patient Refined Diagnosis Related Groups*) y los procedimientos CIE, porque salen de la codificación de facturación, y los dos primeros también están contaminados por la etiqueta. De igual forma, se excluyeron el fallecimiento y el reingreso, que son desenlaces y no predictores.

Por último, se descartó una fuga de códigos en el texto, dado que los códigos de las familias de la etiqueta aparecen escritos en solo 44 notas, es decir, el 0.10 % de las positivas y el 0.02 % de las negativas. De esta manera, se controlan las tres vías de fuga identificadas, es decir, el paciente compartido, las variables de la codificación y los códigos escritos en la nota.

7. Protocolo experimental

El protocolo fija la partición, la validación, las métricas y, salvo en la línea de base, la regla de adopción de cada experimento, de modo que cada cambio se compara con su referencia en las mismas condiciones. Es preciso tomar en consideración que solo en las búsquedas de hiperparámetros de las semanas 7 y 8 hay constancia con fecha de que la regla se escribió antes de correr, en el registro de la corrida y en un *commit* anterior, respectivamente.

En cambio, en la semana 5 la documentación del repositorio declara que la regla se fijó antes de correr, y en la variante D3 la regla figura en el encabezado del *script*. Sin embargo, en ninguno de los dos casos hay una constancia con fecha anterior a la corrida. Lo mismo ocurre con la regla de la semana 6, que consta por primera vez en un *commit* posterior a su corrida.

7.1 Preguntas de evaluación y criterios de éxito

El protocolo contrasta dos tipos de afirmaciones. Por un lado, en la tesis se contrastan las hipótesis específicas con la diferencia global de ROC-AUC (HE1) y la diferencia de proporciones (HE2), cuyos criterios se presentan en la Tabla 2, mientras que el VPP, resultado descriptivo del OE2, se estima sin umbral. Por otro, en el desarrollo del modelo se pregunta si cada cambio mejora la PR-AUC frente a su referencia, con las preguntas y los criterios siguientes:

1) Línea de base (semana 3). ¿La regresión logística sobre las palabras supera a los modelos *dummy* y al modelo previo de la tesis? Se compara en *test*, sin regla de adopción.
2) Atributos (semana 5). ¿Los bigramas y el contexto mejoran la PR-AUC? Se adopta la configuración con mayor PR-AUC media de 5 *folds*.
3) Filas de entrenamiento (semana 6). ¿Quitar las epicrisis de etiqueta dudosa mejora la PR-AUC? Se adopta la variante con mayor PR-AUC media de 5 *folds* sobre las mismas epicrisis, revisando en cuántos *folds* supera a D0.
4) Negativas liberadas (semana 7). ¿La variante D3 mejora la PR-AUC de D2 en la evaluación ampliada, que cuenta como negativas a una muestra de las hospitalizaciones liberadas? Se considera mejor si supera a D2 en al menos 4 de 5 *folds* y su mejora media supera 1 desviación estándar de las diferencias por *fold*.
5) Hiperparámetros (semanas 7 y 8). ¿Otra configuración del espacio de búsqueda mejora la PR-AUC? Se adopta solo si cumple esas mismas dos condiciones en los 5 *folds* de la confirmación.

Las reglas de los ítems 4 y 5 se fijaron para que una mejora solo se considere si se repite entre *folds* y supera su propia variabilidad. En cambio, como se expone en la sección 2.2, el VPP de las detecciones no tiene umbral, dado que los VPP de referencia de Melton y Hripcsak (2005) y de Musy et al. (2018) no se restringen a las detecciones sin código.

7.2 Diseño de particiones y validación

Como se aprecia en la Tabla 8, la partición se hace por paciente, de modo que ningún paciente queda en dos conjuntos, y la validación cruzada se hace dentro de *train* con StratifiedGroupKFold, estratificada por la etiqueta y agrupada por paciente. La semilla es 42 en la partición, los *folds*, el modelo y la búsqueda, y el *test* se midió en el análisis exploratorio y tras cada experimento, para las configuraciones que se comparan.

Tabla 8. Conjuntos de datos, criterio de separación y uso permitido

Conjunto / *fold*	Criterio de separación	Tamaño / período	Uso permitido
Train	Partición por paciente (80 %), semilla 42	55 915 epicrisis, de las cuales la variante D2 conserva 48 998	Ajustar el *pipeline*, comparar configuraciones y buscar hiperparámetros
Validación cruzada de 5 *folds*	StratifiedGroupKFold dentro de *train*, por etiqueta y por paciente	Por *fold*, de 38 888 a 39 320 filas de entrenamiento con D2 y de 11 018 a 11 572 epicrisis de validación (de 9 678 a 10 110 sin etiqueta dudosa)	Adoptar o descartar cada cambio con su regla
Búsqueda de 3 *folds*	El mismo criterio, con 3 *folds*	Por *fold*, unas 32 650 filas de entrenamiento con D2 y unas 18 600 epicrisis de validación, evaluadas sin las de etiqueta dudosa	Explorar el espacio de hiperparámetros (semanas 7 y 8)
Test	Partición por paciente (20 %)	14 085 epicrisis, de las cuales 12 321 no tienen etiqueta dudosa	Medir en el análisis exploratorio y tras cada experimento, sin usarlo para elegir
Población de la HE2 y del VPP	Pacientes que no figuran en el corpus	98 931 epicrisis sin código, con una muestra de 151 detecciones y 90 controles	Revisión ciega, con el modelo reentrenado con las 61 319 epicrisis que D2 conserva en todo el corpus

Fuente: elaboración propia a partir de los registros del preprocesado y de los experimentos de las semanas 6 a 8 del repositorio del curso, y del diseño de la muestra de la revisión ciega (sección 4.4).

La partición no es temporal, y la época de codificación (CIE-9 o CIE-10) se controla al emparejar las negativas con las positivas. Asimismo, las variantes de los datos cambian las filas con que se entrena, pero se evalúan sobre las mismas epicrisis, es decir, las de validación y de *test* que ninguna variante quita, con la etiqueta original.

A este conjunto se le denomina evaluación común, y en *test* comprende 12 321 de las 14 085 epicrisis, que son las que no tienen etiqueta dudosa. Por consiguiente, la comparación no depende de que cada variante se mida en casos distintos.

En cuanto a las repeticiones, la variabilidad se mide entre los 5 *folds*, el IC 95 % de *test* se obtiene al remuestrear pacientes 200 veces y la importancia por permutación usa 30 permutaciones por *fold*. Sin embargo, todas las corridas del desarrollo usan una sola semilla, por lo cual la HE1 exige, además, que el límite inferior de su IC sea mayor que cero en cinco particiones por paciente adicionales (limitación 5 de la sección 1.2.2).

7.3 Métricas y análisis estadístico

La métrica primaria del desarrollo es la PR-AUC, por las razones expuestas en la sección 3.1.3. Como métricas secundarias se registran la ROC-AUC, la sensibilidad, la especificidad

y el F1 de la clase positiva con el corte de 0.5, así como el puntaje de Brier, que es el error cuadrático medio de la probabilidad.

Asimismo, el VPP frente a la etiqueta se calcula con la prevalencia de la etiqueta en la base, $\pi = 0.2759$, mediante la fórmula de la sección 3.1.3. Es preciso tomar en consideración que este VPP se mide frente a la etiqueta de los códigos, por lo que no equivale al VPP de las detecciones sin código, que se mide con la revisión ciega.

En cuanto a la incertidumbre, cada configuración se resume con la media y la desviación estándar (DE) de los 5 *folds*, y cada cambio, con la diferencia por *fold* frente a su referencia, su media, su DE y el número de *folds* en que mejora. En *test*, la PR-AUC se acompaña de su IC 95 % por paciente, y se informa tanto en la evaluación común como con todas las epicrisis y la etiqueta original.

Por otra parte, en la sección 4.7 se describen la diferencia global de ROC-AUC con IC 95 % por paciente (HE1), la diferencia de proporciones con IC de Newcombe (HE2) y el VPP con IC de Wilson, resultado descriptivo del OE2.

7.4 *Baseline* y variantes

Como se aprecia en la Tabla 9, la línea de base mínima son dos modelos *dummy*, y la línea de base sólida, una regresión logística sobre el TF-IDF de las palabras, mientras que el LinearSVC de la etapa previa de la tesis sirve de referencia. A partir de ella, cada experimento cambia una sola cosa respecto de su referencia, de modo que cada diferencia puede atribuirse a ese cambio.

Tabla 9. Línea de base, variantes e hipótesis de cambio

Código	Modelo / configuración	Diferencia frente a su referencia	Hipótesis de cambio
B0	*Dummy* de la clase más frecuente y *dummy* estratificado	Sin aprendizaje	Cota inferior que cualquier modelo útil debe superar
B1	Regresión logística sobre TF-IDF de palabras (bloque A), línea de base	Referencia de las variantes de atributos	Un modelo que entrega probabilidad discrimina al menos como el modelo previo
R	LinearSVC sobre TF-IDF, modelo de la etapa previa de la tesis	Otro clasificador lineal, sin probabilidad	Referencia reproducida con la misma partición
F1	A+B	Frente a B1, añade el bloque de bigramas	Las expresiones de dos palabras agregan señal que una palabra suelta no distingue
F2	A+C	Frente a B1, añade el bloque de contexto	El paciente y su paso por el hospital agregan señal al texto
F3	A+B+C (D0)	Frente a B1, añade ambos bloques	Los dos bloques se complementan

Código	Modelo / configuración	Diferencia frente a su referencia	Hipótesis de cambio
D1	A+B+C sin negativas dudosas	Frente a D0, quita filas de entrenamiento	Las negativas con un código de evento fuera de la tabla confunden al modelo
D2	A+B+C sin negativas ni positivas dudosas	Frente a D0, quita además las positivas dudosas	Las caídas sin el hospital como lugar y las úlceras CIE-9 sin código de presión no son eventos de la atención
D3	D2 con negativas liberadas por la equivalencia validada	Frente a D2, reemplaza el 2.7 % de las filas de entrenamiento	Las hospitalizaciones liberadas son negativas válidas
H7	D2 con búsqueda aleatoria y bayesiana, 15 ensayos cada una	Frente a D2, cambia los hiperparámetros	Otra configuración del espacio mejora la PR-AUC
H8	D2 con búsqueda aleatoria y bayesiana con *pruning*, 30 ensayos cada una	Frente a D2, cambia los hiperparámetros con el doble de ensayos	El *pruning* reduce el costo por ensayo, lo cual permite explorar más configuraciones

Fuente: elaboración propia a partir de la documentación de cada experimento en el repositorio del curso. Las hipótesis de cambio resumen el motivo de cada experimento.

Los controles comunes de todas las variantes son la misma partición por paciente, la semilla 42 y la PR-AUC como métrica de decisión. Asimismo, las variantes de las semanas 5 a 7 y las confirmaciones de las búsquedas usan los mismos 5 *folds*. Desde la semana 6, además, todas se evalúan sobre la evaluación común, aunque la regla de D3 se aplicó a la evaluación ampliada (ver sección 7.1).

7.5 Ingeniería de atributos o componentes

Los atributos se organizan en tres bloques, y todos se calculan dentro del *pipeline* de scikit-learn, de modo que se ajustan solo con el *train* de cada *fold*:

1) Bloque A, palabras. TF-IDF de palabras sueltas, con 20 000 términos como máximo, frecuencia mínima de 3 epicrisis, frecuencia sublineal, minúsculas y sin tildes.
2) Bloque B, bigramas. TF-IDF de pares de palabras consecutivas, con los mismos parámetros, para captar expresiones de dos palabras que una palabra suelta no distingue.
3) Bloque C, contexto. Las 18 variables de la hospitalización y el largo de la nota (ver Anexo C), con el tratamiento que se describe a continuación.

En el bloque C, los conteos con cola larga se imputan con la mediana, con una columna que marca el faltante, y luego se transforman con log1p, se recortan a los percentiles 1 y 99 de *train* y se escalan. Las demás numéricas se imputan con la mediana y se escalan, también con su columna de faltante, y las binarias se imputan con 0.

Asimismo, las categóricas se codifican en *one-hot*, con las categorías de menos de 50 casos agrupadas y el faltante como categoría propia. Por su parte, el largo de la nota pasa por log1p, recorte, escalado y una marca de nota atípica.

La configuración actual, A+B+C, suma 40 091 atributos en el primer *fold* de la confirmación con 5 *folds*. Sobre ellos, el modelo es una regresión logística con el solucionador liblinear, pesos balanceados y C de 1, cuyo puntaje se usa con el corte de 0.5. Por su parte, la elección de un modelo lineal sobre el texto completo, frente a los *transformers*, se fundamenta en la sección 3.1.2.

7.6 Optimización y presupuesto de búsqueda

En la Tabla 10 se presenta el espacio de búsqueda, cuya última columna corresponde a la configuración actual, es decir, la de los atributos de la semana 5 entrenada con D2, de cuyas marcas se sortean las epicrisis de la revisión ciega. Se compararon la búsqueda aleatoria y la bayesiana con el estimador TPE (*Tree-structured Parzen Estimator*) de Optuna 5.0.0 (Akiba et al., 2019).

Tabla 10. Espacio de búsqueda y configuración actual

Hiperparámetro	Qué controla	Valores probados	Actual
C	Inverso de la fuerza de la regularización	Log-uniforme entre 0.001 y 100	1
Máximo de palabras (A)	Tamaño del vocabulario de palabras	10 000, 20 000, 40 000 y 60 000	20 000
Frecuencia mínima (A)	Mínimo de epicrisis en que aparece una palabra	2, 3 y 5	3
Máximo de bigramas (B)	Tamaño del vocabulario de bigramas	10 000, 20 000 y 40 000	20 000
Frecuencia mínima (B)	Mínimo de epicrisis en que aparece un bigrama	2, 3 y 5	3
Peso de las clases	Compensación del desbalance	Balanceado o sin pesos	Balanceado
Frecuencia sublineal	Contar las repeticiones como 1 + log(frecuencia)	Sí o no	Sí

Fuente: elaboración propia a partir de la configuración versionada del repositorio del curso.

Como se aprecia en la Tabla 11, la semana 7 asignó 15 ensayos a cada método, y la semana 8, a pedido del material del curso, 30 ensayos con *pruning*, también denominado poda de ensayos. El *pruning* detiene un ensayo cuando su PR-AUC en los *folds* ya evaluados queda por debajo de la mediana de los ensayos completos, y dado que la regresión logística no tiene detención temprana nativa, se aplica *fold* por *fold*.

Tabla 11. Estrategia y presupuesto de cada búsqueda

Búsqueda	Estrategia	Presupuesto	Ensayos completos y podados	Tiempo de la búsqueda
Semana 7, aleatoria	Muestreo al azar del espacio	15 ensayos con 3 *folds*	15 completos	1 972.5 s
Semana 7, bayesiana	TPE multivariado, con 5 ensayos iniciales al azar que coinciden con los de la aleatoria	15 ensayos con 3 *folds*	15 completos	2 270.9 s
Semana 8, aleatoria	Muestreo al azar, con *pruning* activo desde que hay 5 ensayos completos	30 ensayos con 3 *folds*, hasta 600 s por ensayo y 240 min por búsqueda	15 completos y 15 podados	4 233 s
Semana 8, bayesiana	TPE multivariado, con 10 ensayos iniciales al azar que coinciden con los de la aleatoria, y el mismo *pruning*	El mismo de la aleatoria	18 completos y 12 podados	3 053 s

Fuente: elaboración propia a partir de los registros de ensayos y de los resultados de las semanas 7 y 8 del repositorio del curso.

En ambas semanas, la mejor configuración de las dos búsquedas se confirmó luego con los 5 *folds* de la validación cruzada y se adoptaba solo si cumplía la regla, de modo que la búsqueda y la confirmación usan solo *train*. Además, el diseño, el presupuesto y la regla se escribieron antes de correr la búsqueda.

En la semana 7, la única constancia de ello es el registro de la corrida, escrito antes del primer ensayo, y el presupuesto se fijó primero en 18 ensayos por método y se redujo a 15 antes de iniciar la búsqueda. En cambio, en la semana 8 el diseño quedó en un *commit* anterior a la corrida, y el *test* se midió solo después de que la regla adoptó a la candidata.

7.7 Reproducibilidad y registro de experimentos

El repositorio del curso es público y se encuentra en https://github.com/carlosperez100/mia14-trabajo-investigacion-ii-tesis-gemses-mimic. El trabajo se organiza en ramas por *sprint* o por experimento, y la de la semana 8, que contiene el código y los resultados de este informe, es sprint3-hiperparametros-pruning, en el *commit* fda6828 del 5 de noviembre de 2026.

La última rama es sprint4-informe-parcial, y contiene, además del contenido de la semana 8, la enmienda fechada del prerregistro, la presentación del examen parcial y este informe (ver Anexo F). Para reproducir los resultados se requieren cinco condiciones:

1) Credencial de PhysioNet con acceso a MIMIC-IV v3.1 y MIMIC-IV-Note v2.2, cuyas rutas locales se declaran en un archivo de entorno que no se versiona.

2) Python 3.13, con scikit-learn 1.7.2, Optuna 5.0.0 y las demás versiones fijadas en el repositorio. El flujo se probó en Windows 11, con 15.6 GB de memoria RAM, y el modelo se entrena en la CPU (unidad central de procesamiento).
3) Un comando único, documentado en el repositorio, que ejecuta la ingesta, el preprocesado, el análisis exploratorio, la línea de base y los atributos, así como los comandos de cada experimento de las semanas 6 a 8, también documentados en el repositorio.
4) La semilla 42 y la configuración versionada, en la que también quedan prerregistradas las decisiones, como la configuración de la HE1.
5) Tiempo de cómputo. A partir de los registros de cada corrida, se estima que las etapas del comando único suman unas 3 horas, de las cuales la línea de base toma unos 44 minutos y los atributos unas 2 horas y 8 minutos (ver Anexo D). La documentación del repositorio conserva una estimación anterior de unos 45 minutos, inferior a la que se obtiene de los registros.

En cuanto al registro, cada corrida deja un archivo con su fecha y su hora, sus métricas y sus controles. Asimismo, llevan su huella SHA-256 las seis fuentes de la Tabla 6, la partición y los modelos guardados de la semana 8, así como otras seis tablas de MIMIC-IV y los dos catálogos del Anexo N.° 02, que figuran en el resumen del EDA. Adicionalmente, los ensayos de las búsquedas quedan en un registro acumulado con sus parámetros, su semilla, su partición, su métrica, sus *folds* evaluados, su estado y su tiempo, y el Anexo D resume las corridas que sustentan este informe.

Por otra parte, los controles de reproducción confirmaron que el *pipeline* vuelve a obtener el modelo de la etapa previa de la tesis, un LinearSVC con sensibilidad de 0.7623, especificidad de 0.7699 y ROC-AUC de 0.8426, con diferencia de 0.0000. Asimismo, la semana 7 reproduce la PR-AUC de la semana 6 en los 5 *folds* hasta el sexto decimal, y la semana 8 reproduce la de la semana 7 en los 3 *folds* de la búsqueda, también sin diferencias.

Es preciso tomar en consideración que, según el *script* de la semana 8, la confirmación de la configuración actual con 5 *folds* no se recalculó, sino que se tomó de la caché de resultados de la semana 7.

Asimismo, el modelo adoptado de este informe es la configuración actual del repositorio, es decir, la del lote de la revisión ciega, mientras que la candidata que adoptó la regla de la semana 8 se usa solo como sensibilidad de la HE1.

Por último, la configuración de la HE1, sus estratos y sus mínimos se prerregistraron el 5 de noviembre de 2026 (*commit* fda6828). Asimismo, la enmienda de ese prerregistro, del 12 de noviembre de 2026 (*commit* ad116a5), registró el criterio y las definiciones de la HE1 y la hipótesis general. También registró la regla del resultado no concluyente de la HE2, la adjudicación, los plazos del segundo evaluador y el proceso asistencial de la aplicación GEMSES, antes del cálculo de la HE1 y de la apertura de los resultados de la revisión ciega.

8. Resultados parciales y evidencia

Los resultados de esta sección corresponden a las corridas registradas entre el 30 de setiembre y el 4 de noviembre de 2026. La fecha de corte de los resultados experimentales es el 5 de noviembre de 2026, en que se decidió la configuración de la HE1. Todas las métricas miden la concordancia con la etiqueta de los códigos, y ninguna hipótesis tiene todavía resultado (ver sección 9.1).

8.1 Estado de implementación del *pipeline*

Como se aprecia en la Figura 1 y en la Tabla 4, las etapas de acceso, corpus, *pipeline* y experimentos están ejecutadas. En cambio, el criterio de la HE1 ya está registrado y la revisión ciega está en curso, mientras que el contraste de las hipótesis, el VPP y la aplicación de la Matriz GEMSES están por ejecutar.

En cuanto a la implementación, el comando único ejecuta la ingesta, el preprocesado, el análisis exploratorio, la línea de base y los atributos. Por su parte, los comandos de cada experimento ejecutan las variantes de los datos, las búsquedas de hiperparámetros, la importancia por permutación, la curva de aprendizaje y la calibración. Asimismo, el *pipeline* ya generó la muestra de 241 epicrisis de la revisión ciega, mientras que faltan el cálculo de las dos hipótesis específicas, del VPP y de los kappa, la recalibración de la probabilidad y la aplicación de la Matriz GEMSES.

Las pruebas de ejecución son los controles que registra cada corrida (ver Anexo D). Entre ellos, la aserción de la partición dio 0 pacientes compartidos, la línea de base reprodujo el modelo previo sin diferencias y la semana 5 reprodujo la línea de base de la semana 3. Asimismo, las semanas 7 y 8 reprodujeron los resultados de su semana anterior, y los modelos guardados en la semana 8 dieron las mismas probabilidades que la caché, con una diferencia máxima menor que 3×10^{-15} en 2 000 filas.

8.2 Comparación cuantitativa del *baseline* y variantes

Como se aprecia en la Tabla 12, la regresión logística sobre las palabras superó a los dos modelos *dummy* y al LinearSVC de la tesis, reproducido con la misma partición (ROC-AUC de 0.864 frente a 0.843). Es preciso tomar en consideración que el *dummy* que clasifica todo como positivo obtiene un F1 de 0.698, por lo que el F1 por sí solo no basta para evaluar el modelo.

Tabla 12. Línea de base en *test* (semana 3)

Modelo	F1 (+)	Sensibilidad	PR-AUC	ROC-AUC
Dummy, clase más frecuente	0.698	1.000	0.537	0.500
Dummy, estratificado	0.550	0.555	0.541	0.510
Regresión logística, TF-IDF de palabras (A)	0.791	0.771	0.879	0.864
Referencia: LinearSVC de la tesis	0.778	0.762	0.861	0.843

Fuente: elaboración propia a partir de los resultados de la semana 3 del repositorio del curso.

En la Tabla 13 se presenta, para cada experimento de las semanas 5 a 8, la PR-AUC por *fold* de cada configuración, su media y su desviación estándar, el tiempo de la corrida o de las búsquedas, según se indica, y la decisión. En primer lugar, las tres variantes de atributos superan a la línea de base en los 5 *folds* (ver Figura E3 del Anexo E).

De las cuatro configuraciones, A+B+C es la mejor, con una mejora de +0.0065 que casi cuadruplica su propia variabilidad entre *folds* (± 0.0017). Asimismo, el bloque de contexto aporta más que los bigramas (+0.0047 frente a +0.0021), y en *test* se mantiene el mismo orden, aunque los intervalos se solapan (ver Tabla 14).

Tabla 13. PR-AUC por *fold* de las configuraciones comparadas en las semanas 5 a 8

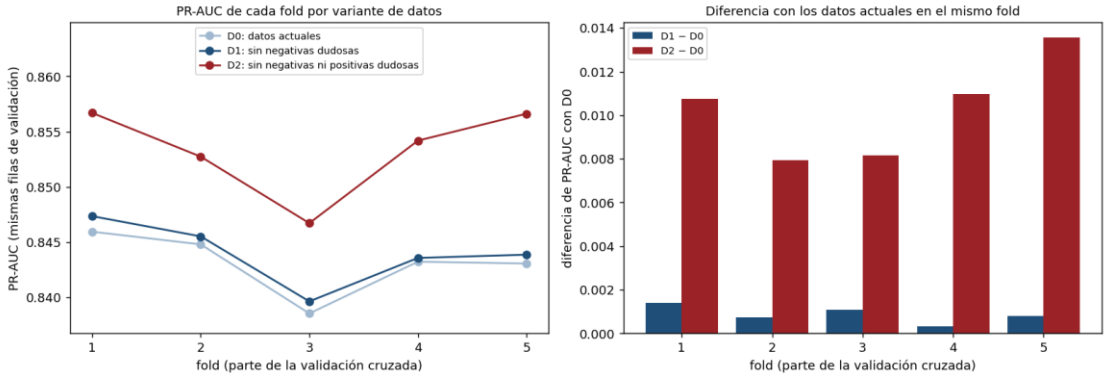
Experimento y configuración	PR-AUC por *fold* (1 a 5)	Media ± DE	Tiempo / costo	Decisión
Semana 5, A, palabras (línea de base)	0.8712 · 0.8685 · 0.8630 · 0.8633 · 0.8676	0.8667 ± 0.0035	2 h 08 min para las cuatro configuraciones	Referencia
Semana 5, A+B	0.8732 · 0.8700 · 0.8646 · 0.8663 · 0.8698	0.8688 ± 0.0034		+0.0021 ± 0.0006 (5 de 5 *folds*)
Semana 5, A+C	0.8742 · 0.8717 · 0.8689 · 0.8698 · 0.8722	0.8714 ± 0.0021		+0.0047 ± 0.0016 (5 de 5)
Semana 5, A+B+C	0.8764 · 0.8731 · 0.8696 · 0.8723 · 0.8744	0.8732 ± 0.0025		+0.0065 ± 0.0017 (5 de 5); se adopta
Semana 6, D0, todas las filas de entrenamiento	0.8459 · 0.8448 · 0.8385 · 0.8432 · 0.8431	0.8431 ± 0.0028	2 h 58 min para las tres variantes	Referencia
Semana 6, D1	0.8474 · 0.8455 · 0.8396 · 0.8436 · 0.8439	0.8440 ± 0.0029		+0.0009 ± 0.0004 (5 de 5)
Semana 6, D2	0.8567 · 0.8527 · 0.8467 · 0.8542 · 0.8566	0.8534 ± 0.0041		+0.0103 ± 0.0023 (5 de 5); se adopta

Experimento y configuración	PR-AUC por *fold* (1 a 5)	Media ± DE	Tiempo / costo	Decisión
Semana 7, D3	0.8555 · 0.8503 · 0.8470 · 0.8536 · 0.8544	0.8522 ± 0.0035	1 h 23 min	−0.0012 ± 0.0011 frente a D2 (1 de 5); en la ampliada, +0.0022 ± 0.0016 (5 de 5), regla cumplida; se mantiene D2 (29-10-2026)
Semana 7, mejor de la búsqueda (bayesiana, ensayo 14)	0.8567 · 0.8513 · 0.8435 · 0.8521 · 0.8562	0.8519 ± 0.0053	1 h 11 min las dos búsquedas	−0.0014 ± 0.0013 frente a D2 (0 de 5); se mantiene la actual
Semana 8, mejor de la búsqueda con *pruning* (bayesiana, ensayo 25)	0.8587 · 0.8539 · 0.8487 · 0.8548 · 0.8575	0.8547 ± 0.0039	2 h 01 min las dos búsquedas	+0.0014 ± 0.0006 frente a D2 (5 de 5); la regla la adopta

Fuente: elaboración propia a partir de los resultados y de los registros de las semanas 5 a 8 del repositorio del curso. La semana 5 se evaluó con todas las epicrisis de validación, y las semanas 6 a 8, con la evaluación común, por lo que las cifras solo son comparables dentro de cada semana. La regla de D3 se aplicó a la evaluación ampliada (ver sección 8.2), y en el primer *fold* la bayesiana del ensayo 14 queda 0.00003 por debajo de D2, diferencia que no se aprecia con cuatro decimales. La configuración actual es la D2 de la semana 6. En la semana 7, la corrida completa tomó 1 h 30 min, más 20 min de conteo previo (ver Anexo D).

En segundo lugar, como se aprecia también en la Figura 3, D2 supera a D0 en los 5 *folds*, entre +0.0079 y +0.0136, mientras que D1 sube apenas +0.0009. En promedio, D0, D1 y D2 se entrenaron con 44 732, 44 238 y 39 198 filas por *fold*. Dado que D1 solo quita negativas dudosas, casi toda la mejora proviene de quitar las positivas dudosas, es decir, las caídas sin el hospital como lugar y las úlceras CIE-9 sin código de úlcera por presión.

Figura 3. PR-AUC por *fold* de las variantes y diferencia con D0



Fuente: elaboración propia a partir de los resultados de la semana 6 del repositorio del curso. En la figura, 'datos actuales' designa a D0, la referencia de la semana 6.

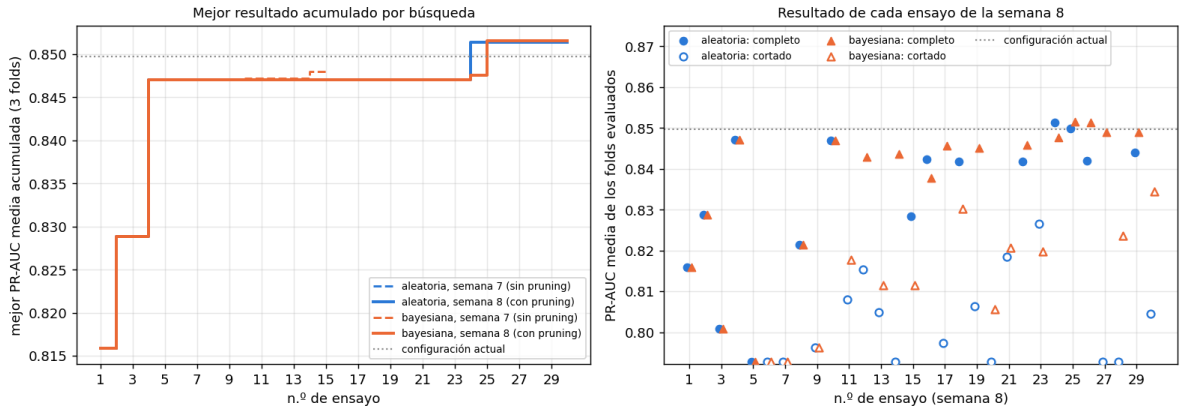
En tercer lugar, la equivalencia validada de los códigos con el Anexo N.° 02 liberaría del sorteo de negativas a 16 189 hospitalizaciones, cambio que solo se probó en la variante D3, sin modificar D2. Dicha variante reemplaza al azar, en cada entrenamiento, una parte de las negativas de la época CIE-10 por esas hospitalizaciones liberadas, entre 1 043 y 1 059 filas por *fold* (2.7 % del entrenamiento).

Según la regla del experimento, D3 se considera mejor que D2 en la evaluación ampliada, que supone que las liberadas son negativas verdaderas, con +0.0022 ± 0.0016 y mejora en 5 de 5 *folds*. En cambio, en la evaluación común D3 quedó por debajo de D2 (−0.0012 ± 0.0011, mejor en 1 de 5). Dado que la regla no establecía si D3 debía reemplazar a D2, el 29 de octubre de 2026 se decidió mantener D2 como referencia.

En cuarto lugar, en la semana 7 ninguna de las 25 configuraciones distintas superó a la actual en la PR-AUC media de los 3 *folds*. Además, la mejor, la bayesiana del ensayo 14, no superó a la actual en ninguno de los 5 *folds* de la confirmación, de modo que la regla mantuvo la configuración actual. En cambio, en la semana 8, con 30 ensayos por método y *pruning*, la mejor configuración fue la del ensayo 25 de la búsqueda bayesiana, con C de 1.87, 60 000 palabras, 40 000 bigramas con frecuencia mínima de 5 y sin pesos.

Dicha configuración obtuvo una PR-AUC de 0.8515 en 3 *folds*, frente a 0.8498 de la actual, y, como se aprecia en la Figura 4, la mejor configuración de la semana 7 había llegado a 0.8480. Luego superó a la actual en los 5 *folds* de la confirmación, con una diferencia media de +0.0014 y una desviación estándar de 0.0006, por lo que la regla la adoptó.

Figura 4. Mejor resultado acumulado de cada búsqueda y resultado de cada ensayo de la semana 8



Fuente: elaboración propia a partir de los registros de ensayos de las semanas 7 y 8 del repositorio del curso. En el gráfico derecho, los 10 ensayos con PR-AUC menor que 0.793 (entre 0.7583 y 0.7858) se dibujan sobre el borde inferior, para no comprimir la escala.

Sin embargo, como se aprecia en la Tabla 14, en *test* la candidata de la semana 8 obtuvo una PR-AUC de 0.8670, frente a 0.8671 de la actual, con intervalos que se solapan. Por consiguiente, el cambio no tiene efecto práctico en *test*. En la misma tabla se observa que, con todas las epicrisis y la etiqueta original, D2 queda por debajo de D0 (0.8580 frente a 0.8830), resultado desfavorable que se analiza en la sección 8.3.

Tabla 14. PR-AUC en *test* de las configuraciones comparadas (IC 95 % por paciente)

Configuración	Evaluación común (12 321 epicrisis)	Todas las epicrisis y etiqueta original (14 085)
A (semana 5)	No se midió	0.8787 (0.8709 a 0.8861)
A+B (semana 5)	No se midió	0.8798 (0.8719 a 0.8869)
A+C (semana 5)	No se midió	0.8822 (0.8747 a 0.8892)
A+B+C con D0 (semanas 5 y 6)	0.8562 (0.8475 a 0.8651)	0.8830 (0.8754 a 0.8905)
D1 (semana 6)	0.8575 (0.8487 a 0.8662)	0.8828 (0.8751 a 0.8902)
D2, configuración actual (semana 6)	0.8671 (0.8589 a 0.8749)	0.8580 (0.8493 a 0.8664)
D3 (semana 7)	0.8652 (0.8571 a 0.8735)	No se midió
Mejor de la búsqueda de la semana 7 (bayesiana, ensayo 14)	0.8645 (0.8567 a 0.8719)	0.8555 (0.8464 a 0.8637)
Mejor de la búsqueda de la semana 8 (bayesiana, ensayo 25)	0.8670 (0.8593 a 0.8745)	0.8581 (0.8489 a 0.8664)

Fuente: elaboración propia a partir de los resultados de las semanas 5 a 8 del repositorio del curso.

Por otra parte, el 5 de noviembre de 2026 se decidió evaluar la HE1 con la configuración actual y usar la candidata como análisis de sensibilidad, por tres razones. Entre ellas no figura el resultado de *test*, dado que el *test* no se usa para elegir.

Primero, las epicrisis de la revisión ciega de la HE2 y del VPP se sortearon de las marcas de la actual, que no se regeneran. Dado que la HG solo se cumple si se cumplen a la vez las dos hipótesis, ambas se evalúan sobre el mismo modelo.

Segundo, la HE1 se formula sobre el modelo adoptado de la matriz de consistencia del 2 de noviembre de 2026, y de dos hechos se deriva que ese modelo es la configuración actual. Por un lado, la matriz se guardó ese día a las 12:08, antes de que empezara la corrida de la semana 8, a las 13:14. Por otro, la ROC-AUC de 0.871 que registra su nota corresponde a la actual (0.8706) y no a la candidata (0.8699).

Tercero, la actual es más parsimoniosa, con 40 091 atributos frente a 91 296. Por último, esta decisión quedó prerregistrada en la configuración versionada antes de calcular cualquier estrato.

Asimismo, el criterio de la HE1 es global, con un umbral de 0.05 para la diferencia de ROC-AUC, el límite inferior de su IC 95 % por paciente mayor que cero y la estabilidad en cinco particiones por paciente adicionales. Los estratos, la candidata y la etiqueta original son análisis de sensibilidad. El umbral de 0.05 no procede de una fuente, y el criterio y las definiciones del cálculo se registraron en la enmienda del prerregistro del 12 de noviembre de 2026, antes de ejecutar el cálculo de la HE1 (sección 4.7).

En cuanto al costo, como se aprecia en la Figura E6 del Anexo E, el *pruning* cortó 15 de 30 ensayos de la búsqueda aleatoria y 12 de 30 de la bayesiana. Así, evaluó 102 de los 150

folds que habrían requerido las 50 configuraciones distintas, con un ahorro estimado de unos 56 minutos.

Asimismo, sobre los mismos 15 ensayos de la aleatoria de la semana 7, evaluó 31 de 45 *folds* sin cortar ninguno de los cinco mejores. Por otra parte, según el evaluador de importancia de hiperparámetros de Optuna, denominado PED-ANOVA, C concentra la mayor importancia (0.83), seguido del máximo de bigramas (0.09).

8.3 Ablaciones y análisis de sensibilidad

Como se aprecia en la Tabla 15, cada fila cambia un solo componente frente a un control. Al permutar cada bloque en el modelo ya entrenado, el de las palabras es el de mayor peso (0.1274), seguido del contexto (0.1106) y de los bigramas (0.0331), en el mismo orden en los 5 *folds* (ver Figura E5 del Anexo E).

Tabla 15. Ablaciones y análisis de sensibilidad

Componente cambiado	Control	Resultado	Interpretación
Bloque A permutado (30 permutaciones por *fold*)	Configuración actual sin permutar	Caída de la PR-AUC de 0.1274 ± 0.0028	Es el bloque de mayor peso
Bloque B permutado	La misma	Caída de 0.0331 ± 0.0013; al reentrenar sin el bloque, 0.0018	El modelo usa los bigramas, aunque uno reentrenado sin ellos pierde poco
Bloque C permutado	La misma	Caída de 0.1106 ± 0.0034; al reentrenar sin el bloque, 0.0044	El contexto pesa casi tanto como las palabras
Bloques A y B permutados juntos	La misma	Caída de 0.2349 ± 0.0046, mayor que la suma de ambos por separado (0.1605)	Es coherente con que compartan información, aunque no lo demuestra
Solo el contexto, sin el contenido del texto	Texto solo (bloque A)	PR-AUC de 0.777 frente a 0.867	La mayor parte de la señal está en el texto
Largo de la nota añadido al resto del contexto	Contexto sin el largo	+0.0004 de PR-AUC	El largo no agrega información una vez conocidas las demás variables
D2 evaluado con todas las epicrisis y la etiqueta original	D0	PR-AUC de 0.8477 frente a 0.8732 en validación cruzada, y de 0.8580 frente a 0.8830 en *test*	D2 deja de marcar las caídas y úlceras que la etiqueta original cuenta como positivas
D3 en la evaluación ampliada, que cuenta las liberadas como negativas	D2	+0.0022 ± 0.0016 (5 de 5 *folds*), frente a −0.0012 en la evaluación común	La regla se cumple en la ampliada, pero el resultado depende de cómo se etiqueten las liberadas

Fuente: elaboración propia a partir de los resultados de las semanas 5 a 7 del repositorio del curso.

Es preciso tomar en consideración que la ablación por reentrenamiento da caídas mucho menores, porque mide cuánto pierde un modelo reentrenado sin el bloque, y no cuánto se

apoya en él el modelo ya entrenado. Además, esa ablación se midió con D0 y con todas las filas de validación. Dentro del contexto, las variables de mayor peso son la estancia (0.0132), el servicio al ingreso (0.0061) y el largo de la nota (0.0054), lo cual refuerza la necesidad de la HE1, que mide el aporte del texto más allá del contexto.

Por otra parte, sin leer el texto, las variables de contexto alcanzan una PR-AUC de 0.777, frente a 0.867 del texto solo. Al sumarlas por grupos, después de las variables del paciente (0.6552), el servicio (+0.0575) y el paso por el hospital (+0.0557) aportan casi todo el resto. En cambio, el largo de la nota prácticamente no agrega información (+0.0004) una vez que se conocen las demás variables.

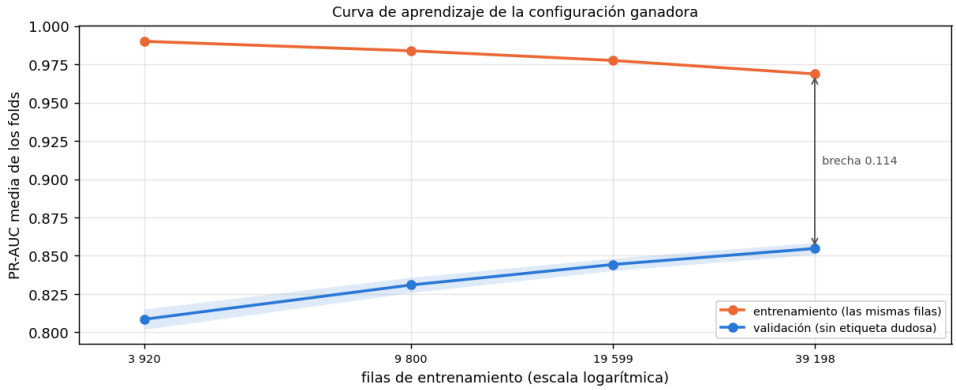
En cuanto a la sensibilidad de la variante adoptada, con todas las epicrisis el modelo con D2 marcó como evento el 52.9 % de las 1 576 positivas dudosas, frente al 88.4 % del modelo con D0. Ambas cifras se derivan de las sensibilidades de *test* con todas las epicrisis (7 557 positivas) y sin etiqueta dudosa (5 981 positivas).

Es decir, adoptar D2 supone aceptar, a partir del EDA, que esas positivas no son eventos de la atención, supuesto que el experimento no demuestra. Asimismo, en validación cruzada, D2 marcó como evento al 42.61 % de las liberadas, frente al 18.73 % de las negativas CIE-10 de la evaluación común (41.79 % y 17.25 % en *test*).

8.4 Sobreajuste, errores y robustez

En la Figura 5 se observa la curva de aprendizaje de la candidata en los 5 *folds*. Con todas las filas, la PR-AUC fue 0.9687 en entrenamiento y 0.8547 en validación, una brecha de 0.1140, mientras que con 3 920 filas la brecha era de 0.1815. Entre 19 599 y 39 198 filas, la validación subió +0.0105 en promedio y en los 5 *folds*, de modo que la curva todavía no se aplana.

Figura 5. Curva de aprendizaje de la configuración candidata, rotulada como ganadora en el gráfico



Fuente: elaboración propia a partir de los resultados de la semana 8 del repositorio del curso.

Con la configuración actual, la curva de la semana 6, medida solo en el primer *fold*, dio una brecha de 0.078 (0.9351 en entrenamiento y 0.8567 en validación), frente a 0.110 de la candidata en su primer *fold* (0.9685 y 0.8587). La diferencia concuerda con la regularización más fuerte de la actual (C de 1 frente a 1.87) y con su menor número de atributos, aunque las dos configuraciones también difieren en los pesos de las clases.

Como se aprecia en la Tabla 16, la configuración actual obtuvo en *test* una PR-AUC de 0.8671 y una ROC-AUC de 0.8706 en la evaluación común, y con las 14 085 epicrisis y la etiqueta original ambas bajaron a 0.8580 y 0.8398. En cuanto a la calibración, las probabilidades siguen la diagonal en el corpus del estudio (Brier de 0.1533 en validación cruzada y de 0.1462 en *test*), como se aprecia en la Figura E4 del Anexo E. Sin embargo, el corpus tiene más positivas que la base (53.8 % frente a 27.6 %), por lo que la probabilidad debe recalibrarse antes de usarse como riesgo (limitación 9 de la sección 1.2.2).

Tabla 16. Configuración actual en *test* (corte de 0.5)

Métrica	**12 321 epicrisis sin etiqueta dudosa**	**14 085 epicrisis con la etiqueta original**
PR-AUC	0.8671	0.8580
ROC-AUC	0.8706	0.8398
Sensibilidad	0.7689	0.7189
Especificidad	0.8038	0.7950
F1 (+)	0.7779	0.7584
VPP frente a la etiqueta, con su prevalencia en la base	0.5989	0.5720
Puntaje de Brier	0.1462	No se calculó

Fuente: elaboración propia a partir de los resultados de las semanas 6 y 8 del repositorio del curso. El VPP de esta tabla se mide frente a la etiqueta de los códigos y no es el de la revisión ciega.

En la Tabla 17 se aplican esas tasas a 10 000 hospitalizaciones con epicrisis y la prevalencia de la etiqueta, es decir, a 2 759 con evento según los códigos. Con la configuración actual,

de cada 100 alertas unas 60 tendrían un evento codificado en la evaluación común, y unas 57 con todas las epicrisis, frente a unas 28 de cada 100 epicrisis revisadas al azar. Por consiguiente, el modelo más que duplica los eventos codificados que se hallan por epicrisis revisada, al multiplicarlos por 2.2 en la evaluación común y por 2.1 con todas las epicrisis.

Tabla 17. Eventos por cada 10 000 hospitalizaciones con epicrisis (prevalencia de la etiqueta de 27.6 %)

Epicrisis evaluadas	Eventos detectados	Eventos que se escapan	Falsas alarmas	De cada 100 alertas, con evento
Sin etiqueta dudosa	2 121	638	1 421	60
Todas, etiqueta original	1 983	776	1 484	57

Fuente: elaboración propia a partir de los resultados de las semanas 6 y 7 del repositorio del curso.

Estos eventos son los que marcan los códigos CIE y no una revisión clínica de cada epicrisis. Además, el cálculo supone que las tasas de *test* valen para toda la base, por lo que se toma como orden de magnitud. Por otra parte, la revisión al azar de esta comparación abarca todas las epicrisis, de modo que no es el comparador de la HG, que es la revisión al azar de las epicrisis sin código.

Por otra parte, la desviación estándar de la PR-AUC de la configuración actual entre *folds* es de 0.0041, mayor que la mejora de la candidata (+0.0014), aunque esta mejoró en los 5 *folds* y su diferencia por *fold* varía poco (DE de 0.0006).

En cuanto a los errores, las falsas alarmas y los eventos que se escapan se conocen frente a la etiqueta (ver Tabla 17). En cambio, el análisis por estrato de servicio, edad y largo de la nota corresponde a la sensibilidad de la HE1 y todavía no tiene resultado, por lo que no se presenta. Asimismo, los casos de fallo se describirán una vez terminada la revisión ciega, sin reproducir texto de las epicrisis (ver sección 6.3).

8.5 Interpretación y amenazas a la validez

Los resultados muestran, en primer lugar, que la mayor parte de la señal está en el texto. Sin leer la nota, el contexto llega a una PR-AUC de 0.777, frente a 0.867 del texto solo, y al permutar el texto completo la PR-AUC cae 0.2349, frente a 0.1106 del contexto. Sin embargo, el contexto también pesa, de manera que la HE1 es necesaria para medir cuánto aporta el texto a la discriminación más allá del tipo de paciente.

En segundo lugar, aunque cada experimento se midió frente a su propia referencia, la depuración de la etiqueta tuvo más efecto que el ajuste del modelo. La variante D2 mejoró la PR-AUC en +0.0103 en la evaluación común, frente a +0.0065 de los atributos y +0.0014 de los hiperparámetros, y esta última mejora no se apreció en *test*. Por ello, mientras la curva de

aprendizaje siga subiendo, ampliar las epicrisis de entrenamiento y mejorar la etiqueta tienen más recorrido que nuevas búsquedas en este espacio.

En tercer lugar, la PR-AUC mide la concordancia con los códigos y no con los eventos reales. Por consiguiente, el modelo cumple una función de tamizaje que orienta la revisión, y su valor para la gestión depende de la revisión ciega, que compara sus detecciones sin código con las epicrisis sin código que no marca. En cuanto a las amenazas a la validez, se reconocen las siguientes:

1) Tamaño de la muestra. Con 151 detecciones, el margen de error del VPP es de 0.08. Asimismo, según un cálculo binomial exacto, si el VPP de las detecciones fuera de 0.35, la potencia de la HE2 sería de 0.94 con una proporción de 0.15 en los 90 controles, y de 0.71 con una de 0.20. Por ello, una diferencia real menor de 0.164 podría no cumplir su criterio, y para una de 0.10 la potencia es de 0.37. En consecuencia, si no se cumple, se descarta una diferencia de 0.10 o mayor solo si el límite superior de su IC es menor que esa cifra, y en otro caso el resultado es no concluyente (ver sección 4.4 y limitación 11).
2) Contaminación. Se controló con la partición por paciente, el *pipeline* ajustado en *train*, la exclusión de las variables de facturación y la revisión de los códigos escritos en la nota. Sin embargo, el *test* se midió en el análisis exploratorio y tras cada experimento, y en él se compararon varias configuraciones, aunque sin usarlo para elegir, por lo cual la HE1 no es ciega respecto de su dirección (sección 4.7). Por ello, al fijar el umbral de 0.05 ya se conocía la magnitud aproximada de la diferencia, y la decisión confirmatoria de la HG recae en la HE2.
3) Generalización. Los datos proceden de un solo hospital de los Estados Unidos y están en inglés, y el corpus tiene 53.8 % de positivas, frente al 27.6 % de la base.
4) Reproducibilidad. Las corridas del desarrollo usan una sola semilla, por lo cual la HE1 exige, además, que el límite inferior de su IC sea mayor que cero en cinco particiones por paciente adicionales. Asimismo, la confirmación de la configuración actual en la semana 8 se tomó de la caché de la semana 7.
5) Interpretabilidad. La importancia se mide por bloques y por variables de contexto, y los términos del modelo solo se muestran después del filtro de privacidad.
6) Sesgos. La etiqueta sale de los códigos de facturación, el tipo de paciente y el largo de la nota anticipan parte de ella, y la revisión ciega la hace el propio investigador, con una segunda lectura independiente prevista solo en 100 de las 241 epicrisis.

Además, si al 31 de diciembre de 2026 ningún segundo evaluador tiene credencial propia, no habrá kappa interevaluador, la referencia será la lectura del investigador en las 241 y las conclusiones descansarán en ella, sin confirmación independiente.

9. Conclusiones del avance y próximos pasos

9.1 Conclusiones sustentadas por evidencia

Una vez analizados los resultados, se concluye lo siguiente:

1) El *pipeline* es reproducible por etapas, con el comando único y los comandos de cada experimento (ver sección 7.7 y Anexo D). Asimismo, la partición es por paciente, las transformaciones se ajustan solo en *train* y las reglas de adopción de las búsquedas de las semanas 7 y 8 se escribieron antes de correr. Además, el *test* no se usó para elegir, aunque se midió en el análisis exploratorio y tras cada experimento.
2) El modelo actual, una regresión logística sobre palabras, bigramas y contexto entrenada con la variante D2, alcanzó en la evaluación común de *test* una PR-AUC de 0.8671 (IC 95 %: 0.8589 a 0.8749) y una ROC-AUC de 0.8706. Con todas las epicrisis y la etiqueta original, alcanzó 0.8580 y 0.8398, y con la prevalencia de la etiqueta unas 60 de cada 100 alertas tendrían un evento codificado en la evaluación común.
3) Cada mejora se midió frente a su propia referencia, y la mayor fue la depuración de la etiqueta, con +0.0103 en 5 de 5 *folds* de la evaluación común, aunque con todas las epicrisis D2 queda por debajo de D0 en *test*. Los atributos (+0.0065) y los hiperparámetros (+0.0014) aportaron mejoras pequeñas, y la última no se apreció en *test*.
4) La mayor parte de la señal está en el texto de la epicrisis, aunque el contexto del paciente también pesa, por lo cual la HE1 debe confirmar que el texto aporta discriminación más allá del contexto.
5) Permanece indeterminado el cumplimiento de las hipótesis. Como se aprecia en la Tabla 18, la HE1 está registrada y por ejecutar, y la revisión ciega de la HE2 está en curso, de modo que la mejora de la detección frente a la revisión al azar todavía no se ha demostrado.

Tabla 18. Estado de las hipótesis, del VPP y de la aplicación GEMSES al 13 de noviembre de 2026

Componente	Estado	Siguiente paso
HE1	Registrada: configuración actual, estratos y mínimos de 200 epicrisis y 30 por clase en el prerregistro del 5 de noviembre de 2026, y criterio global, estabilidad en cinco particiones adicionales y definiciones del cálculo en su enmienda del 12 de noviembre de 2026. Cálculo por ejecutar	Ejecutar el cálculo global y en las cinco particiones adicionales, con los estratos, la candidata y la etiqueta original como sensibilidad
HE2 y VPP	Revisión ciega en curso de 241 epicrisis sin código (151 detecciones y 90 controles), sorteadas de 15 731 detecciones y 83 200 no detecciones, con el modelo actual reentrenado con las 61 319 epicrisis que la variante D2 conserva en todo el corpus	Terminar la revisión de las 241 y repetir 30 casos a ciegas al menos dos semanas después (kappa intraevaluador). Obtener la segunda lectura de 100 por otro evaluador con su propia credencial (kappa interevaluador), adjudicar las discrepancias sin conocer la marca del modelo y abrir los resultados
Aplicación GEMSES	Por ejecutar. El proceso, el periodo y la regla del nivel quedaron fijados en el plan	Registrar los cortes del impacto antes de abrir los resultados de la revisión ciega y aplicar en forma exploratoria la Matriz GEMSES a los grupos de eventos confirmados, con los pesos del diseño
HG	Depende de la HE1 y de la HE2, y su decisión confirmatoria recae en la HE2, según la enmienda del prerregistro	Declararla cumplida solo si se cumplen a la vez la HE1 y la HE2

Fuente: elaboración propia a partir de la matriz de consistencia (Anexo A), del diseño de la muestra (sección 4.4) y de la configuración versionada y la enmienda del prerregistro del repositorio del curso.

Los resultados de la revisión ciega se abren solo al terminar, para no sesgar la lectura de los casos que faltan. Por ello, este informe no presenta ningún resultado parcial de la revisión. Asimismo, según la enmienda del prerregistro, la revisión empezó antes del 5 de noviembre de 2026 con el manual de anotación (*codebook* v2), que no ha cambiado, y nadie ha visto los veredictos separados por detecciones y controles.

9.2 Riesgos y plan de mitigación

En la Tabla 19 se presentan los riesgos científicos, de datos, técnicos, éticos y operativos, agrupados en ese orden, con su impacto, su mitigación y su evidencia. El responsable de todas las mitigaciones es el tesista.

Tabla 19. Riesgos, impacto, mitigación y evidencia

Riesgo	Impacto	Mitigación	Evidencia / responsable
Etiqueta débil (científico)	El desempeño mide la concordancia con la codificación y no con los eventos reales	Revisión ciega de las detecciones sin código y de los controles (HE2 y VPP)	Revisión en curso
Atajo por tipo de paciente (científico)	Sin texto se llega a una ROC-AUC de 0.760, y la estancia y el servicio pesan en el modelo	HE1 global frente al modelo de contexto (bloque C), con un umbral de 0.05, el límite inferior del IC 95 % mayor que cero y los estratos de servicio, edad y decil de largo como sensibilidad	Criterio de la HE1 registrado; cálculo por ejecutar
Evaluador principal (científico)	Fuera de las 100 epicrisis con segunda lectura prevista, la referencia es la lectura del propio investigador, quien desarrolló el modelo	Cegamiento, manual de anotación, kappa intraevaluador en 30 casos y segunda lectura independiente de 100, con kappa interevaluador y adjudicación de las discrepancias	Revisión en curso; si el segundo evaluador no tiene su propia credencial al 30 de noviembre de 2026, se invita a otro evaluador clínico, y si ninguno la tiene al 31 de diciembre de 2026, la referencia es la lectura del investigador en las 241, sin confirmación independiente
Tamaño de la muestra (científico)	Con 151 detecciones, 90 controles y un VPP supuesto de 0.35, una diferencia real menor de 0.164 podría no cumplir el criterio de la HE2	Detecciones calculadas para el VPP con $n = z^2 \cdot p \cdot (1 - p) / e^2$ ($z = 1.96$, $p = 0.5$ y $e = 0.08$). Potencia de la HE2 de 0.94 o de 0.71 según la proporción en los controles, y de 0.37 para una diferencia de 0.10 (sección 4.4 y limitación 11)	241 epicrisis sorteadas; si no se cumple el criterio, se descarta una diferencia de 0.10 o mayor solo si el límite superior del IC es menor que esa cifra, y en otro caso el resultado es no concluyente
Ruido en positivas y negativas (datos)	6 296 positivas solo por caída y 805 negativas con un código fuera de la tabla	Variantes D1, D2 y D3, y se adoptó D2	Ejecutado (Tabla 13)
Atajo por largo de la nota (datos)	El largo solo da una ROC-AUC de 0.606	Deciles de largo en la sensibilidad de la HE1 y largo como variable explícita del bloque C	Criterio de la HE1 registrado; cálculo por ejecutar
Sobreajuste (técnico)	Brecha de 0.078 con la actual y de 0.110 con la candidata en el primer *fold* (0.114 de media en 5 *folds*)	Regularización, frecuencia mínima del TF-IDF, *pruning* y curva de aprendizaje	Ejecutado, con más datos como siguiente paso
Calibración (técnico)	El corpus tiene 53.8 % de positivas y la base, 27.6 %	VPP con la prevalencia de la etiqueta y recalibración obligatoria antes del uso operativo	Recalibración pendiente
Fuga de información (técnico)	Pacientes compartidos, variables de la codificación o códigos en el texto	Partición por paciente con aserción, *pipeline* ajustado en *train* y variables de facturación excluidas	Controlado: 0 pacientes compartidos y códigos escritos en solo 44 notas

Riesgo	Impacto	Mitigación	Evidencia / responsable
Una sola semilla (técnico)	La variabilidad por semilla no se midió en el desarrollo	Se informa la variabilidad entre *folds*, y la HE1 exige un límite inferior mayor que cero en cinco particiones por paciente adicionales	Registrado; cálculo por ejecutar
Licencia y privacidad (ético)	El firmante del DUA se compromete a no compartir el acceso a los datos	Datos y modelos fuera del repositorio, y solo agregados y términos filtrados	Controlado
Memoria del equipo (operativo)	Con 15.6 GB de RAM el corpus se limitó a 70 000 epicrisis, y la curva de aprendizaje todavía no se aplana	Cálculos por *fold* con caché de resultados, y la ampliación del corpus queda como trabajo futuro	Pendiente

Fuente: elaboración propia a partir del EDA y de los resultados de las semanas 5 a 8 del repositorio del curso.

9.3 Trabajo futuro para el siguiente sprint

En la Tabla 20 se presentan las actividades que siguen, en el orden en que se recomienda ejecutarlas, con su entregable, su criterio de aceptación y su fecha según el cronograma de la sección 5.1. Todas están a cargo del tesista.

Tabla 20. Actividades, entregables, criterios de aceptación y fechas

Actividad	Entregable	Criterio de aceptación	Fecha
Terminar la revisión ciega de las 241 epicrisis	Fichas de revisión completas	Las 241 epicrisis revisadas sin abrir los resultados	Noviembre de 2026
Registrar en el prerregistro los cortes del impacto	Registro fechado de los cortes	El registro queda en un *commit* antes de abrir los resultados de la revisión ciega	Noviembre de 2026
Repetir a ciegas 30 casos y obtener la segunda lectura de 100 por otro evaluador con su propia credencial	Kappa intra e interevaluador y lectura adjudicada	La repetición ocurre al menos dos semanas después de la primera lectura, y las discrepancias se discuten sin conocer la marca del modelo; si no hay acuerdo, prevalece la lectura del segundo evaluador	Diciembre de 2026
Ejecutar la HE1 con la configuración actual, en la evaluación global y en las cinco particiones adicionales, con los estratos, la candidata y la etiqueta original como sensibilidad	Resultado de la HE1	Los criterios registrados en la enmienda del prerregistro se aplican sin cambios	Enero de 2027
Calcular la HE2, el VPP y la HG	Diferencia de proporciones con IC de Newcombe, VPP con IC de Wilson y decisión sobre la HG	Los criterios de la Tabla 2 se aplican sin cambios	Enero de 2027

Actividad	Entregable	Criterio de aceptación	Fecha
Aplicar en forma exploratoria la Matriz GEMSES a los grupos de eventos confirmados, con los pesos del num. 19.11 y los del diseño	Niveles de gestión potenciales de los grupos de eventos	La regla del nivel, el proceso y el periodo quedan fijados en el plan, y los cortes del impacto, registrados antes de abrir los resultados de la revisión ciega, se aplican sin cambios	De mediados de enero a mediados de febrero de 2027
Redactar el informe final de la tesis	Informe final	Integra los resultados de las dos hipótesis, del VPP y de la aplicación GEMSES	De enero a marzo de 2027

Fuente: elaboración propia a partir del cronograma de la Figura 2. Las fechas son estimadas.

Adicionalmente, se recomienda recalibrar la probabilidad a la prevalencia de la etiqueta en la base, con la configuración que se fije antes de medir, y registrar en la bitácora, con su huella SHA-256, las tablas de MIMIC-IV que usa el bloque de contexto. Asimismo, se recomienda empaquetar el código, el entorno y el contrato de entrada y salida, de modo que quien tenga credencial entrene el modelo en local sin que el modelo se publique, y repetir los experimentos principales con varias semillas. Como línea posterior, se recomienda evaluar la transferencia a notas clínicas en español.

REFERENCIAS

Akiba, T., Sano, S., Yanase, T., Ohta, T., y Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (pp. 2623–2631). ACM. https://doi.org/10.1145/3292500.3330701

Aranaz-Andrés, J. M., Aibar-Remón, C., Limón-Ramírez, R., Amarilla, A., Restrepo, F. R., Urroz, O., Sarabia, O., García-Corcuera, L. V., Terol-García, E., Agra-Varela, Y., Gonseth-García, J., Bates, D. W., Larizgoitia, I., y IBEAS team. (2011). Prevalence of adverse events in the hospitals of five Latin American countries: Results of the 'Iberoamerican Study of Adverse Events' (IBEAS). *BMJ Quality & Safety, 20*(12), 1043–1051. https://doi.org/10.1136/bmjqs.2011.051284

Brennan, T. A., Leape, L. L., Laird, N. M., Hebert, L., Localio, A. R., Lawthers, A. G., Newhouse, J. P., Weiler, P. C., y Hiatt, H. H. (1991). Incidence of adverse events and negligence in hospitalized patients: Results of the Harvard Medical Practice Study I. *New England Journal of Medicine, 324*(6), 370–376. https://doi.org/10.1056/NEJM199102073240604

Brown, L. D., Cai, T. T., y DasGupta, A. (2001). Interval estimation for a binomial proportion. *Statistical Science, 16*(2), 101–133. https://doi.org/10.1214/ss/1009213286

Camacho-Rodríguez, D. E., Carrasquilla-Baza, D. A., Dominguez-Cancino, K. A., y Palmieri, P. A. (2022). Patient safety culture in Latin American hospitals: A systematic review with meta-analysis. *International Journal of Environmental Research and Public Health, 19*(21), Artículo 14380. https://doi.org/10.3390/ijerph192114380

Cheligeer, C., Wu, G., Lee, S., Pan, J., Southern, D. A., Martin, E. A., Sapiro, N., Eastwood, C. A., Quan, H., y Xu, Y. (2024). BERT-based neural network for inpatient fall

detection from electronic medical records: Retrospective cohort study. *JMIR Medical Informatics, 12*, Artículo e48995. https://doi.org/10.2196/48995

Classen, D. C., Resar, R., Griffin, F., Federico, F., Frankel, T., Kimmel, N., Whittington, J. C., Frankel, A., Seger, A., y James, B. C. (2011). 'Global trigger tool' shows that adverse events in hospitals may be ten times greater than previously measured. *Health Affairs, 30*(4), 581–589. https://doi.org/10.1377/hlthaff.2011.0190

Cochran, W. G. (1977). *Sampling techniques* (3.ª ed.). John Wiley & Sons.

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement, 20*(1), 37–46. https://doi.org/10.1177/001316446002000104

De Micco, F., Di Palma, G., Ferorelli, D., De Benedictis, A., Tomassini, L., Tambone, V., Cingolani, M., y Scendoni, R. (2025). Artificial intelligence in healthcare: Transforming patient safety with intelligent systems—A systematic review. *Frontiers in Medicine, 11*, Artículo 1522554. https://doi.org/10.3389/fmed.2024.1522554

de Vries, E. N., Ramrattan, M. A., Smorenburg, S. M., Gouma, D. J., y Boermeester, M. A. (2008). The incidence and nature of in-hospital adverse events: A systematic review. *Quality and Safety in Health Care, 17*(3), 216–223. https://doi.org/10.1136/qshc.2007.023622

Ferrara, M., Bertozzi, G., Di Fazio, N., Aquila, I., Di Fazio, A., Maiese, A., Volonnino, G., Frati, P., y La Russa, R. (2024). Risk management and patient safety in the artificial intelligence era: A systematic review. *Healthcare, 12*(5), Artículo 549. https://doi.org/10.3390/healthcare12050549

Frénay, B., y Verleysen, M. (2014). Classification in the presence of label noise: A survey. *IEEE Transactions on Neural Networks and Learning Systems, 25*(5), 845–869. https://doi.org/10.1109/TNNLS.2013.2292894

Hanley, J. A., y McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology, 143*(1), 29–36. https://doi.org/10.1148/radiology.143.1.7063747

Henry, S., Buchan, K., Filannino, M., Stubbs, A., y Uzuner, O. (2020). 2018 n2c2 shared task on adverse drug events and medication extraction in electronic health records. *Journal of the American Medical Informatics Association, 27*(1), 3–12. https://doi.org/10.1093/jamia/ocz166

Hohl, C. M., Karpov, A., Reddekopp, L., Doyle-Waters, M., y Stausberg, J. (2014). ICD-10 codes used to identify adverse drug events in administrative data: A systematic review. *Journal of the American Medical Informatics Association, 21*(3), 547–557. https://doi.org/10.1136/amiajnl-2013-002116

Johnson, A., Bulgarelli, L., Pollard, T., Gow, B., Moody, B., Horng, S., Celi, L. A., y Mark, R. (2024). *MIMIC-IV* (versión 3.1) [Conjunto de datos]. PhysioNet. https://doi.org/10.13026/kpb9-mt58

Johnson, A., Pollard, T., Horng, S., Celi, L. A., y Mark, R. (2023). *MIMIC-IV-Note: Deidentified free-text clinical notes* (versión 2.2) [Conjunto de datos]. PhysioNet. https://doi.org/10.13026/1n74-ne17

Johnson, A. E. W., Bulgarelli, L., Shen, L., Gayles, A., Shammout, A., Horng, S., Pollard, T. J., Hao, S., Moody, B., Gow, B., Lehman, L.-W. H., Celi, L. A., y Mark, R. G. (2023). MIMIC-IV, a freely accessible electronic health record dataset. *Scientific Data, 10*(1), Artículo 1. https://doi.org/10.1038/s41597-022-01899-x

Melton, G. B., y Hripcsak, G. (2005). Automated detection of adverse events using natural language processing of discharge summaries. *Journal of the American Medical Informatics Association, 12*(4), 448–457. https://doi.org/10.1197/jamia.M1794

Modi, S., Kasmiran, K. A., Mohd Sharef, N., y Sharum, M. Y. (2024). Extracting adverse drug events from clinical notes: A systematic review of approaches used. *Journal of Biomedical Informatics, 151*, Artículo 104603. https://doi.org/10.1016/j.jbi.2024.104603

Murff, H. J., FitzHenry, F., Matheny, M. E., Gentry, N., Kotter, K. L., Crimin, K., Dittus, R. S., Rosen, A. K., Elkin, P. L., Brown, S. H., y Speroff, T. (2011). Automated identification of postoperative complications within an electronic medical record using natural language processing. *JAMA, 306*(8), 848–855. https://doi.org/10.1001/jama.2011.1204

Musy, S. N., Ausserhofer, D., Schwendimann, R., Rothen, H. U., Jeitziner, M.-M., Rutjes, A. W. S., y Simon, M. (2018). Trigger tool-based automated adverse event detection in electronic health records: Systematic review. *Journal of Medical Internet Research, 20*(5), Artículo e198. https://doi.org/10.2196/jmir.9901

Newcombe, R. G. (1998). Interval estimation for the difference between independent proportions: Comparison of eleven methods. *Statistics in Medicine, 17*(8), 873–890. https://doi.org/10.1002/(SICI)1097-0258(19980430)17:8<873::AID-SIM779>3.0.CO;2-I

Office of Inspector General. (2012). *Hospital incident reporting systems do not capture most patient harm* (OEI-06-09-00091). U.S. Department of Health and Human Services. https://oig.hhs.gov/oei/reports/oei-06-09-00091.pdf

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*(85), 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

Pérez Pérez, C. (2021). *Modelo de excelencia: Gestión moderna de los servicios de salud (GEMSES)*.

PhysioNet. (s. f.). *PhysioNet credentialed health data use agreement 1.5.0*. https://physionet.org/content/mimic-iv-note/view-dua/2.2/

Saerens, M., Latinne, P., y Decaestecker, C. (2002). Adjusting the outputs of a classifier to new a priori probabilities: A simple procedure. *Neural Computation, 14*(1), 21–41. https://doi.org/10.1162/089976602753284446

Saito, T., y Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE, 10*(3), Artículo e0118432. https://doi.org/10.1371/journal.pone.0118432

Seguro Social de Salud. (2020). *Directiva de Gerencia General N.° 7-OGCyH-ESSALUD-2020 V.01: Registro, notificación y gestión de los eventos*

relacionados con la seguridad del paciente en ESSALUD. Aprobada por la Resolución de Gerencia General N.° 402-GG-ESSALUD-2020, del 4 de marzo de 2020. Primera edición impresa: Lima, marzo de 2021.

Stausberg, J., y Hasford, J. (2010). Identification of adverse drug events: The use of ICD-10 coded diagnoses in routine hospital data. *Deutsches Ärzteblatt International, 107*(3), 23–29. https://doi.org/10.3238/arztebl.2010.0023

Tsuchiya, M., Kawazoe, Y., Shimamoto, K., Seki, T., Imai, S., Kizaki, H., Shinohara, E., Yada, S., Wakamiya, S., Aramaki, E., y Hori, S. (2025). Elucidating celecoxib's preventive effect in capecitabine-induced hand-foot syndrome using medical natural language processing. *JCO Clinical Cancer Informatics, 9*, Artículo e2500096. https://doi.org/10.1200/CCI-25-00096

Universidad Nacional de Ingeniería. (2023). *Guía N.° 1. Guía metodológica para la elaboración y presentación del plan de tesis (para maestrías y doctorados)*. Escuela de Posgrado. Ratificada y aprobada por la Resolución Rectoral N.° 3144-2023-UNI, del 16 de octubre de 2023.

Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., y Steyerberg, E. W. (2019). Calibration: The Achilles heel of predictive analytics. *BMC Medicine, 17*, Artículo 230. https://doi.org/10.1186/s12916-019-1466-7

Whitaker, B., Pizarro, J., Deady, M., Williams, A., Ezzeldin, H., Belov, A., Kanderian, S., Billings, D., Cook, K., Hettinger, A. Z., y Anderson, S. (2022). Detection of allergic transfusion-related adverse events from electronic medical records. *Transfusion, 62*(10), 2029–2038. https://doi.org/10.1111/trf.17069

Yasrebi-de Kom, I. A. R., Dongelmans, D. A., de Keizer, N. F., Jager, K. J., Schut, M. C., Abu-Hanna, A., y Klopotowska, J. E. (2023). Electronic health record-based prediction models for in-hospital adverse drug event diagnosis or prognosis: A systematic review. *Journal of the American Medical Informatics Association, 30*(5), 978–988. https://doi.org/10.1093/jamia/ocad014

Zheng, Y., Dickson, V. V., Blecker, S., Ng, J. M., Rice, B. C., Melkus, G. D., Shenkar, L., Mortejo, M. C. R., y Johnson, S. B. (2022). Identifying patients with hypoglycemia using natural language processing: Systematic literature review. *JMIR Diabetes, 7*(2), Artículo e34681. https://doi.org/10.2196/34681

Zhou, Z.-H. (2018). A brief introduction to weakly supervised learning. *National Science Review, 5*(1), 44–53. https://doi.org/10.1093/nsr/nwx106

ANEXOS

Los anexos reúnen la matriz de consistencia (Anexo A), el cronograma detallado (Anexo B), el diccionario de datos (Anexo C) y el registro de las corridas (Anexo D). Asimismo, reúnen la evidencia de ejecución, con las figuras complementarias de la Parte II (Anexo E), y el enlace a la última rama del repositorio (Anexo F).

Anexo A. Matriz de consistencia

En la Tabla A1 se resume la matriz de consistencia, con la correspondencia entre el problema, el objetivo, la hipótesis, las variables y el indicador de cada componente. Por su parte, el tipo, el nivel, el método, el diseño, la población y las técnicas de la investigación se exponen en las secciones 4.1 a 4.7.

Tabla A1. Matriz de consistencia

Problema	Objetivo	Hipótesis (si aplica)	Variable	Indicador medible
General. ¿En qué medida un *pipeline* de procesamiento de lenguaje natural y aprendizaje automático, aplicado a las epicrisis de MIMIC-IV, mejora, frente a la revisión al azar de las epicrisis sin código, la detección de los eventos adversos no registrados en la codificación hospitalaria?	General. Mejorar, frente a la revisión al azar de las epicrisis sin código, la detección de los eventos adversos no registrados en la codificación hospitalaria mediante un *pipeline* de procesamiento de lenguaje natural y aprendizaje automático aplicado a las epicrisis de MIMIC-IV.	HG. El *pipeline* mejora la detección de los eventos adversos no registrados en la codificación hospitalaria, lo cual se considera cumplido si se cumplen a la vez la HE1 y la HE2. Su decisión confirmatoria recae en la HE2.	VI: *pipeline* de detección frente a sus comparadores. VD: detección de los eventos adversos. Variable descriptiva de la aplicación exploratoria de la Matriz GEMSES: nivel de gestión potencial de los grupos de eventos confirmados.	Cumplimiento simultáneo de los criterios de decisión de la HE1 y la HE2 (ver Tabla 2). En la aplicación exploratoria, frecuencia ponderada por el diseño en el proceso de Hospitalización, impacto parcial y nivel verde, amarillo o rojo de cada grupo (EsSalud, 2020, num. 19.6, 19.11 y 19.12)
PE1. ¿En qué medida el contenido textual de la epicrisis aporta capacidad discriminativa adicional a la de las variables clínicas y administrativas de contexto para detectar los eventos adversos?	OE1. Superar, con el texto de la epicrisis, la capacidad discriminativa de las variables clínicas y administrativas de contexto en la detección de los eventos adversos.	HE1. La incorporación del contenido textual de la epicrisis aporta capacidad discriminativa incremental para identificar hospitalizaciones asociadas con eventos adversos, respecto de un modelo basado exclusivamente en las características clínicas y administrativas de contexto. Se contrasta frente a la etiqueta de la codificación, en las 12 321 epicrisis de prueba sin etiqueta dudosa, entre el modelo adoptado (A+B+C, variante D2) y el modelo de contexto (bloque C, entrenado con las mismas filas).	VI: configuración del modelo (A+B+C o solo C). VD, dimensión 1: discriminación frente a la etiqueta débil. Variables intervinientes, como sensibilidad: servicio al ingreso, grupo de edad y decil de largo de la nota.	Diferencia global de ROC-AUC con IC 95 % por paciente. Se cumple si es de al menos 0.05 y su límite inferior es mayor que cero, y si ese límite también es mayor que cero en cada una de cinco particiones por paciente adicionales (semillas 43 a 47). Los estratos, la candidata y la etiqueta original se informan como sensibilidad

Problema	Objetivo	Hipótesis (si aplica)	Variable	Indicador medible
PE2. ¿El modelo concentra las epicrisis con eventos no registrados más que las epicrisis sin código que no marca?	OE2. Lograr que las epicrisis sin código que el modelo marca contengan eventos no registrados en mayor proporción que las que no marca.	HE2. La proporción de epicrisis con al menos un evento adverso confirmado en la revisión ciega es mayor entre las detecciones sin código que entre las epicrisis sin código que el modelo no marca.	VI: marca del modelo (detección o no detección). VD, dimensión 2: epicrisis con eventos adversos no registrados confirmados en la revisión ciega.	Proporciones con evento en las 151 detecciones (p1) y en los 90 controles sorteados (p0), su diferencia con IC 95 % de Newcombe y su razón. Se cumple si el límite inferior de la diferencia es mayor que cero. Si no se cumple, se descarta una diferencia de 0.10 o mayor solo si el límite superior es menor que esa cifra, y en otro caso el resultado es no concluyente. Como resultado descriptivo, VPP de las 151 detecciones con IC 95 % de Wilson, sin umbral de decisión, y kappa intraevaluador (30 epicrisis) e interevaluador (100 epicrisis, si hay segunda lectura)

Fuente: elaboración propia a partir de las Tablas 2 y 3 y de la matriz de consistencia del plan de tesis.

Anexo B. Cronograma detallado

En la Tabla B1 se detalla el cronograma de la Figura 2, con el periodo, el producto verificable y el estado de cada actividad al 13 de noviembre de 2026, fecha de presentación del plan y de este informe. Salvo el tema y la revisión de la literatura, las actividades ejecutadas coinciden con las etapas 1 a 4 de la Tabla 4. Asimismo, salvo el hito del 13 de noviembre y el trámite de aprobación del plan, las demás corresponden a las etapas 5 a 9.

Tabla B1. Actividades, hitos, periodos y productos verificables

Actividad / hito	Periodo	Producto verificable	Estado
Tema y revisión de la literatura	Marzo y abril de 2026	Antecedentes y marco teórico (Capítulos I y III)	Ejecutado
Credencial, cursos CITI y acuerdos de uso de datos	Abril y mayo de 2026	Credencial de PhysioNet, certificados de los cursos y acuerdos firmados (sección 4.6)	Ejecutado
Corpus, etiqueta débil y experimentos iniciales	Mayo a agosto de 2026	Corpus de 70 000 epicrisis, etiqueta débil y modelo de referencia	Ejecutado
Pipeline reproducible y análisis exploratorio	Setiembre y octubre de 2026	*Pipeline* de un solo comando en el repositorio del curso y hallazgos del EDA (sección 6.2)	Ejecutado
Experimentos de atributos, datos e hiperparámetros	Octubre y primera semana de noviembre de 2026	Modelo adoptado y registro de corridas (Tabla 13 y Anexo D)	Ejecutado
Hito: presentación del plan de tesis y del informe parcial	13-11-2026	Plan de tesis e informe parcial	Hito
Trámite de aprobación del plan de tesis	Noviembre y diciembre de 2026	Plan de tesis aprobado	En curso
Revisión ciega de 241 epicrisis	Noviembre de 2026	Fichas de revisión completas	En curso
Registro de los criterios y de los cortes del impacto	Noviembre de 2026	Criterios de las hipótesis, registrados el 12 de noviembre de 2026 (*commit* ad116a5), y cortes del impacto, por registrar antes de abrir los resultados de la revisión ciega	En curso
Re-revisión de 30, segunda lectura de 100 y kappa	Diciembre de 2026	Kappa intraevaluador e interevaluador	Por ejecutar
Contraste de la HE1, la HE2 y la HG, y VPP	Enero de 2027	Resultado de las hipótesis y del VPP	Por ejecutar
Aplicación exploratoria de la Matriz GEMSES	De mediados de enero a mediados de febrero de 2027	Niveles de gestión potenciales de los grupos de eventos confirmados	Por ejecutar
Redacción del informe final de tesis	Enero a marzo de 2027	Informe final de tesis	Por ejecutar
Revisión del jurado y sustentación	Marzo y abril de 2027	Tesis sustentada	Por ejecutar

Fuente: elaboración propia. Todas las actividades están a cargo del tesista, y las fechas de las actividades por ejecutar son estimadas.

Anexo C. Diccionario de datos

En la Tabla C1 se resumen las variables que usa el modelo, con su tabla de origen en MIMIC-IV. Es preciso tomar en consideración que todas cubren la hospitalización completa, igual que la epicrisis, por lo que sirven para detectar el evento al alta y no para predecirlo durante la estancia.

Tabla C1. Diccionario de las variables del modelo

Grupo	Variables	Tabla de MIMIC-IV	Tipo	Observación
Texto	Epicrisis (informe de alta)	*discharge*	Texto libre	Mediana de 9 932 caracteres y 1 515 palabras
Etiqueta	Evento adverso según los códigos de causa explícita	*diagnoses_icd*	Binaria	Variable objetivo; etiqueta débil
Paciente	Edad, horas en emergencia, sexo, tipo de ingreso, procedencia y seguro	*patients* y *admissions*	Numéricas y categóricas	Las horas en emergencia faltan en el 33.2 %, que corresponde a los pacientes que no pasaron por emergencia, de modo que el faltante no es aleatorio
Servicio	Servicio al ingreso y al alta, n.° de servicios distintos y paso por un servicio quirúrgico	*services*	Categóricas, conteo y binaria	El servicio al ingreso define los estratos de sensibilidad de la HE1
Hospitalización	Estancia, n.° de traslados, n.° de unidades distintas, días en la unidad de cuidados intensivos (UCI), paso por UCI y destino al alta	*admissions*, *transfers* e *icustays*	Numéricas, categórica y binaria	Destino al alta falta en el 12.5 %
Atención	N.° de medicamentos distintos prescritos y n.° de muestras para cultivo	*prescriptions* y *microbiologyevents*	Conteos	Cola larga
Nota	Largo de la epicrisis	*discharge*	Numérica	Define los deciles de sensibilidad de la HE1

Fuente: elaboración propia a partir de la documentación del repositorio del curso (secciones de análisis exploratorio y de ingeniería de atributos).

Por otra parte, el paso por un servicio quirúrgico agrupa, a partir del nombre del código, los servicios SURG, CSURG, NSURG, VSURG, TSURG, PSURG, ORTHO y TRAUM. Las transformaciones de cada grupo se describen en la sección 7.5, y las variables excluidas como predictores, en la sección 6.4.

Anexo D. Registro de corridas

En la Tabla D1 se presenta la corrida final de cada etapa, en orden cronológico, con el *commit* que versiona su resultado, la semilla y la partición, su métrica principal y el artefacto que deja. Cada corrida escribe un registro con su fecha y su hora, y las corridas de prueba y las anteriores de cada etapa no se incluyen.

Tabla D1. Corridas que sustentan los resultados del informe

Corrida (inicio y duración)	*Commit* que versiona el resultado	Semilla / partición	Métrica principal	Artefacto
Preprocesado, 30-09-2026 17:05 (90 s)	147c3e8	42; partición por paciente en 55 915 y 14 085 epicrisis	0 pacientes compartidos; 53.89 % de positivas en *train* y 53.65 % en *test*	Partición, con huella SHA-256 a252913516c7
Línea de base, 30-09-2026 17:06 (44 min)	147c3e8	42; *test*	PR-AUC de 0.879 y ROC-AUC de 0.864 en *test*; el LinearSVC de referencia se reproduce con diferencia de 0.0	Resultados de la línea de base (Tabla 12)
Ingesta, 02-10-2026 17:55 (23 s)	4055a0e	No aplica	331 793 epicrisis de 145 914 pacientes	Bitácora de datos con seis fuentes (Tabla 6)
Atributos, 15-10-2026 19:25 (2 h 08 min)	0567bf9	42; 5 *folds* y *test*	PR-AUC media de A+B+C de 0.8732; la configuración A reproduce la PR-AUC de *test* de la línea de base (0.8787) con diferencia de 0.0	Resultados por *fold* y Figura E3
Análisis exploratorio, 16-10-2026 09:51 (2 min 40 s)	c14f8e4	No aplica	Tres decisiones de diseño	Resumen del EDA y Figura E2 (la E1 se compuso con sus cifras)
Variantes D0 a D2, 22-10-2026 14:34 (2 h 58 min)	d47d8c5	42; 5 *folds* y *test*	PR-AUC media de D2 de 0.8534 en la evaluación común	Resultados por *fold*, Figura 3 y Figura E4
Hiperparámetros, semana 7, 28-10-2026 08:47 (1 h 30 min)	1de737d	42; 3 *folds* de búsqueda y 5 de confirmación	Mejor ensayo con 0.8480 en 3 *folds*; la configuración actual reproduce la semana 6 con diferencia de 0.0	Registro de ensayos
Importancia por permutación, 28-10-2026 11:31 (20 min)	cf4178b	42; 5 *folds* y 30 permutaciones	Caída de 0.1274 al permutar el bloque A	Importancia por bloque y por variable (Figura E5)
Variante D3, 29-10-2026 11:12 (1 h 23 min)	f90d266	42; 5 *folds* y *test*	+0.0022 ± 0.0016 frente a D2 en la evaluación ampliada, con la regla cumplida, y −0.0012 ± 0.0011 en la común	Resultados por *fold*
Hiperparámetros con *pruning*, semana 8, 02-11-2026 13:14 (8 h 46 min)	d29a4b6 (prerregistro) y abb4a81 (resultados)	42; 3 *folds* de búsqueda y 5 de confirmación	Mejor ensayo con 0.8515 en 3 *folds*; +0.0014 ± 0.0006 en la confirmación	Registro de ensayos y Figuras 4 y E6
Corrida retomada de la semana 8, 04-11-2026 13:38 (1 h 04 min)	abb4a81	42; los mismos *folds*	La curva con todas las filas reproduce la confirmación, con una diferencia máxima de 3.4×10^{-7}	Curva de aprendizaje (Figura 5) y tres modelos guardados fuera del repositorio, con huella SHA-256

Fuente: elaboración propia a partir de los registros de cada corrida y del historial de *commits* de la rama de la semana 8 del repositorio del curso. Los datos de todas las corridas son los de MIMIC-IV v3.1 y MIMIC-IV-Note v2.2 (ver Tabla 6).

Es preciso tomar en consideración que la ingesta se volvió a correr el 2 de octubre de 2026 para registrar los conteos del conjunto de datos en el resumen de la ingesta, por lo que figura después del preprocesado. Asimismo, la corrida de la semana 8 se detuvo a las 21:59, al comenzar el paso de los modelos, y el registro de eventos del equipo anota un reinicio a las 22:01, del cual se infiere que la detuvo.

En esa misma corrida, un paso de la curva de aprendizaje figura con 19 335 s, dado que coincidió con una suspensión del equipo entre las 16:06 y las 21:26. La corrida retomada el 4 de noviembre de 2026 tomó de la caché los ensayos y la confirmación, con su tiempo original, y calculó de nuevo el *test* y la curva, y por primera vez los modelos. Estos últimos, es decir, la ganadora y dos de respaldo, dieron las mismas probabilidades que la caché.

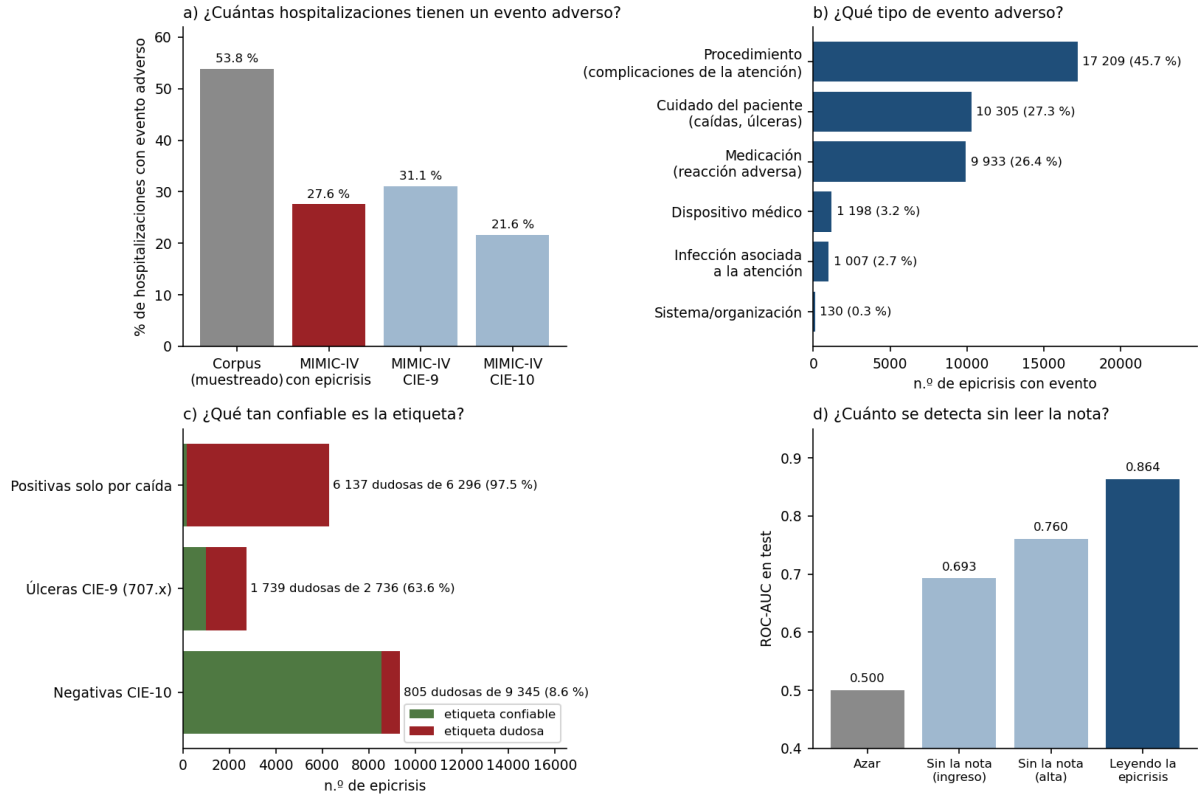
Asimismo, la corrida se retomó con el *script* corregido en la lectura del hiperparámetro C. En el registro del 2 de noviembre, esa lectura impidió reconocer algunas configuraciones de la semana 7 como iguales a las de la semana 8, por lo que el control de las mismas configuraciones dio falso. Según la documentación del repositorio, la corrección cambió ese control y la importancia de los hiperparámetros, pero no los ensayos, la decisión, el *test* ni el respaldo.

Anexo E. Evidencia de ejecución, repositorio y figuras

El repositorio público del curso (ver sección 7.7) contiene, en sus ramas, el código, la configuración versionada, los registros de cada corrida, los resultados agregados y las figuras. Asimismo, la documentación del repositorio describe los comandos de reproducción, y algunos cuadernos leen los resultados sin volver a entrenar. Por su parte, las tareas de los dos primeros *sprints*, con su responsable y su plazo, se registraron en los *issues* y *milestones* del repositorio.

Las pruebas de ejecución son los controles que registra cada corrida, resumidos en la sección 8.1 y en el Anexo D. Por su parte, las Figuras E1 a E6 complementan los resultados de la Parte II.

Figura E1. Prevalencia de la etiqueta, naturaleza del evento, calidad de la etiqueta y discriminación sin leer la nota

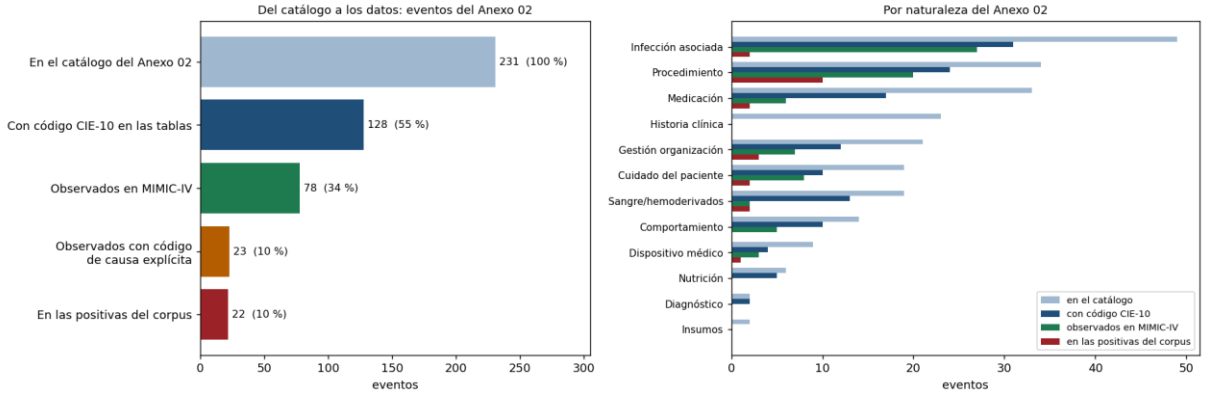


Fuente: elaboración propia a partir del EDA de la semana 4 del repositorio del curso. En el panel b), los paréntesis dan ejemplos de algunas naturalezas.

En la Figura E1 se observa, en el panel a), que la prevalencia de la etiqueta en la base es de 27.6 %, frente al 53.8 % del corpus. En el b), la naturaleza más frecuente es la de procedimiento (45.7 %), que en la época CIE-9 agrupa las complicaciones de la atención y los incidentes asistenciales.

En el panel c), tienen etiqueta dudosa el 97.5 % de las positivas solo por caída, el 63.6 % de las úlceras CIE-9 y el 8.6 % de las negativas CIE-10. En el d), el contexto sin el contenido del texto alcanza una ROC-AUC de 0.693 al ingreso y de 0.760 al alta, frente a 0.864 al leer la epicrisis.

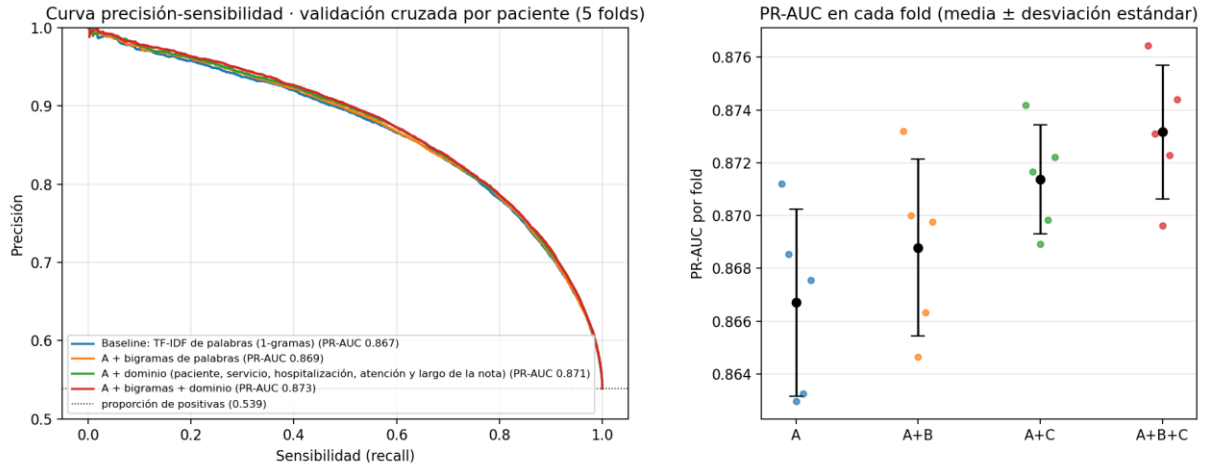
Figura E2. Del catálogo de 231 eventos del Anexo N.° 02 a los datos



Fuente: elaboración propia a partir del EDA de la semana 4 y del catálogo del Anexo N.° 02 de la Directiva N.° 7-OGCyH-ESSALUD-2020.

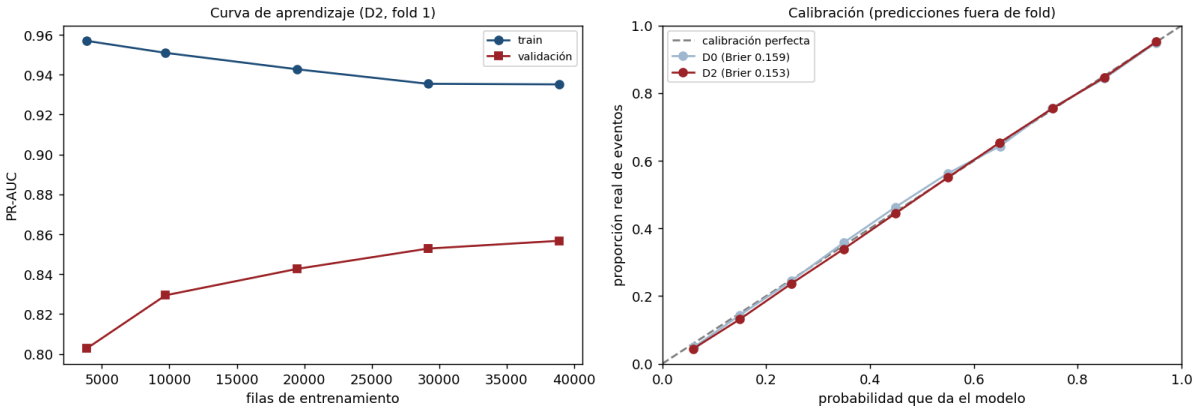
Como se aprecia en la Figura E2, solo 22 de los 231 eventos del catálogo llegan a las positivas del corpus, y los eventos de historia clínica y de insumos no tienen código de diagnóstico. Por ello, la frecuencia de cada evento no alcanza para un clasificador por evento, y en el diseño de la tesis el modelo detecta si hubo evento y la revisión ciega identifica cuál. De este modo, la Matriz GEMSES se aplica, en forma exploratoria, a los eventos confirmados.

Figura E3. Curvas de precisión y sensibilidad y PR-AUC por *fold* de la ablación de atributos



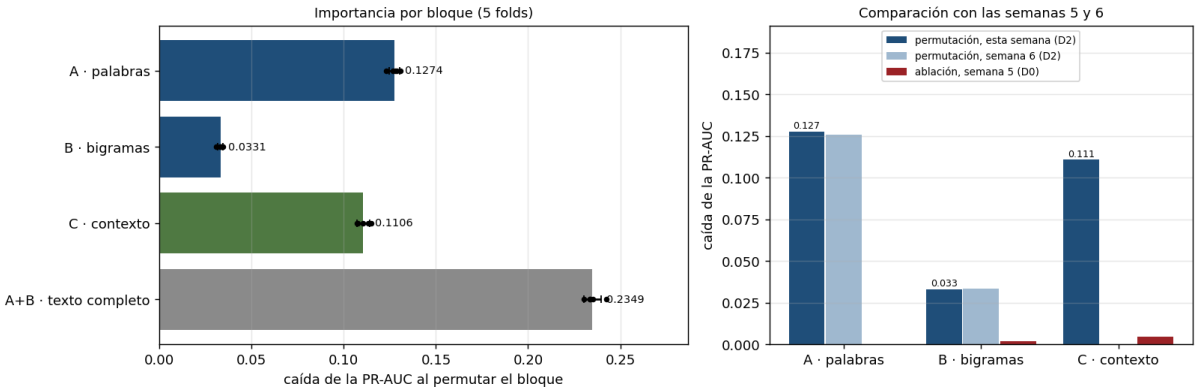
Fuente: elaboración propia a partir de los resultados de la semana 5 del repositorio del curso. En la leyenda, la línea de base figura como *baseline* y el bloque C de contexto, como ‘dominio’.

Figura E4. Curva de aprendizaje con D2 (primer *fold*) y calibración con D0 y D2 de la configuración actual



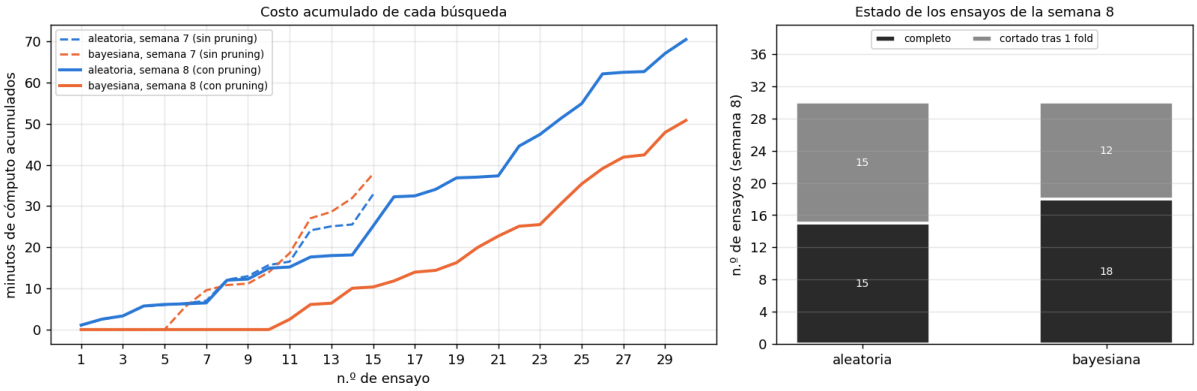
Fuente: elaboración propia a partir de los resultados de la semana 6 del repositorio del curso.

Figura E5. Caída de la PR-AUC al permutar cada bloque y comparación con las semanas 5 y 6



Fuente: elaboración propia a partir de los resultados de importancia de variables de la semana 7 del repositorio del curso. En el gráfico derecho, 'esta semana' corresponde a la semana 7.

Figura E6. Costo acumulado de cada búsqueda y estado de los ensayos de la semana 8



Fuente: elaboración propia a partir de los registros de ensayos de las semanas 7 y 8 del repositorio del curso. En el gráfico izquierdo, el costo de la bayesiana es nulo en sus primeros ensayos, 5 en la semana 7 y 10 en la semana 8, porque coinciden con los de la aleatoria y se evaluaron una sola vez.

Anexo F. Enlace a la última rama del repositorio

La última rama del repositorio público del curso es sprint4-informe-parcial, y en su carpeta del examen parcial se encuentran este informe, en formato Word y PDF, y la presentación del examen parcial, en formato PDF. El enlace a dicha carpeta es https://github.com/carlosperez100/mia14-trabajo-investigacion-ii-tesis-gemses-mimic/tree/sprint4-informe-parcial/slides/examen_parcial.